

PROBABILIDAD I

alessandro.ferreiro@vam.es

coordinador:

Julian de la Horra

1^{er} PARCIAL - 15 marzo
2^o PARCIAL - 26 abril

} media ≥ 5 y nota en cada uno ≥ 4

APROBADOS

T1. - Espacios de probabilidad
- Teorema de Bayes

T2. - Variables aleatorias

- Función de distribución
- Modelo de probabilidades (quizá en tema 3)

→ normal o gaussiana
→ Binomial
→ Poisson

T3. - Vectores aleatorios

- Es el estudio de la relación entre diferentes variables aleatorias

- Covarianza y correlación

- Dependencia e independencia de variables aleat.

T4. - Teorema Central y Convergencias de variables aleatorias

- Teorema Central Límite
- Convergencias de variables aleatorias (OPCIONAL)

TEMA 1 ESPACIOS DE PROBABILIDAD

DEFINICIÓN: Un ESPACIO MUESTRAL Ω es el conjunto de todos los posibles resultados del fenómeno aleatorio que deseamos estudiar.

Ejemplos: ① Espacio muestral Ω de lanzar una moneda.

$$\Omega = \{ "cara", "cruz" \}$$

② Lanzar un dado

$$\Omega = \{ 1, 2, 3, 4, 5, 6 \}$$

DEFINICIÓN: Una σ -ÁLGEBRA DE SUCESO, \mathcal{S} , es un subconjunto de partes de Ω que verifica las siguientes propiedades:

a) Si $A \in \mathcal{S} \Rightarrow A^c = \Omega \setminus A \in \mathcal{S}$.

b) Si $A_1, A_2, \dots \in \mathcal{S} \Rightarrow \bigcup_{m=1}^{\infty} A_m \in \mathcal{S}$.

La σ -álgebra representa las informaciones disponibles sobre el fenómeno aleatorio

Ejemplos: ① Si $\Omega = \{ 1, 2, 3, 4, 5, 6 \}$ es el espacio muestral asociado al fenómeno aleatorio "lanzar un dado", entonces $\mathcal{S} = \mathcal{P}(\Omega)$.

Para cualquier evento, e.d. $A \in \mathcal{P}(\Omega)$, sabemos su probabilidad de ocurrencia.

PROPIEDADES:

1.- $\emptyset \in \mathcal{S}$ y $\Omega \in \mathcal{S}$ (si $\mathcal{S} \neq \emptyset$) \Rightarrow la σ -álgebra mínima es $\{ \emptyset, \Omega \}$

2.- Si $A_1, A_2, \dots \in \mathcal{S} \Rightarrow \bigcap_{m=1}^{\infty} A_m \in \mathcal{S}$

Demostración 2:

$A_1^c, A_2^c, \dots \in \mathcal{S}$ por a) $\xRightarrow{(b)} \bigcup_m A_m^c \in \mathcal{S}$

$$\bigcup_m A_m^c = \left(\bigcap_m A_m \right)^c$$

$$\xRightarrow{(a)} \bigcap_m A_m \in \mathcal{S}$$

3.- Si $A_1, A_2 \in \mathcal{S} \Rightarrow A_1 \cup A_2 \in \mathcal{S}$, $A_1 \cap A_2 = A_1 \cap A_2$

4.- Si $A_1, A_2, \dots \in \mathcal{S} \Rightarrow \overline{\lim_{m \rightarrow \infty} A_m} := \bigcap_{m=1}^{\infty} \left[\bigcup_{i=m}^{\infty} A_i \right] \in \mathcal{S}$ y

tambi n $\underline{\lim_{m \rightarrow \infty} A_m} := \bigcup_{m=1}^{\infty} \left[\bigcap_{i=m}^{\infty} A_i \right] \in \mathcal{S}$.

Observaci n: $\lim_{m \rightarrow \infty} A_m$ se define como $\lim A_m$ si $\overline{\lim A_m} = \underline{\lim A_m} = A$

y si $\exists \lim_{m \rightarrow \infty} A_m \Rightarrow \lim_{m \rightarrow \infty} A_m \in \mathcal{S}$.

5.- La intersecci n de una familia de σ - lgebras \mathcal{S}_α es una σ - lgebra, e.d. $\bigcap_\alpha \mathcal{S}_\alpha$ es σ - lgebra.

DEFINICI N: Se define la σ - lgebra generada por un subconjunto

$B \subset \mathcal{P}(\Omega)$: $\sigma(B) := \bigcap \{ \mathcal{S} : \mathcal{S} \supset B \text{ y } \mathcal{S} \text{ } \sigma\text{- lgebra} \}$

• $\sigma(B)$ es la σ - lgebra m s peque a que contiene a B .

► Si Ω es finito   discreto, normalmente la σ - lgebra utilizada es $\mathcal{S} = \mathcal{P}(\Omega)$

► Si Ω es continua, por ejemplo $\Omega = \mathbb{R}$, la σ - lgebra m s utilizada es la σ - lgebra de BOREL, que es la $\sigma\left(\{(-\infty, x] : x \in \mathbb{R}\}\right)$.

► Si $\Omega = \mathbb{R}^n$, se utiliza la σ - lgebra $\sigma\left(\{(-\infty, x_1] \times \dots \times (-\infty, x_n] : x_1, \dots, x_n \in \mathbb{R}\}\right)$

Definición: Sea Ω un espacio muestral y \mathcal{S} un σ -álgebra sobre Ω . Una FUNCIÓN DE PROBABILIDAD \mathbb{P} , es una función $\mathbb{P}: \mathcal{S} \rightarrow [0,1]$ que verifica:

$P: S \rightarrow [0,1]$ que verifica:

$$T = (v)P(v)$$

b) Si $A_1, A_2, \dots \in \mathcal{S}$ son disjuntos $\Rightarrow \mathbb{P}\left(\bigcup_{m=1}^{\infty} A_m\right) = \sum_{m=1}^{\infty} \mathbb{P}(A_m)$

b) Si $A_1, A_2, \dots \in \mathcal{S}$ disjuntos $\Rightarrow \mathbb{P}\left(\bigcup_{m=1}^{\infty} A_m\right) = \sum_{m=1}^{\infty} \mathbb{P}(A_m)$.

PROPIEDADES:

$$\text{A. - S: } A \in \mathcal{S}, \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

decomposition

$$A \cup A^c = \Omega$$

(b) por lo anterior

$$\tau = (\sigma)\pi$$

$$A \cap A^c = \emptyset \text{ (e.d. son disjuntos)}$$

$$\mathbb{R}(A \cup A^c) = \mathbb{R}(A) + \mathbb{R}(A^c)$$

$$= 1 - P(A)$$

$$= \mathbb{P}(A^c)$$

$$0 = (\phi) \mathbb{R}(\phi) = 0$$

3. - Si: $A_1, A_2 \in \mathcal{S}$, y $A_1 \subset A_2$ $\Rightarrow P(A_1) \leq P(A_2)$ y ademàs

$$P(A_2 \setminus A_1) = P(A_2) - P(A_1)$$


demonstration

demonstración
 $A_2 = (A_2 \setminus A_1) \cup A_1 \Rightarrow \underbrace{P(A_2)}_{\text{unión de conjuntos disjuntos}} = P(A_2 \setminus A_1) + P(A_1) \Rightarrow$

$$\Rightarrow P(A_2 \setminus A_1) = P(A_2) - P(A_1)$$

4. - Si $A_1, A_2 \in S$, $P(A_1 \cup A_2) = P(A_1) + P(A_2) - P(A_1 \cap A_2)$

demonstración



$$P(A_2 \cup A_3) = P(A_2 \setminus A_3 \cup A_3) = P(A_2 \setminus A_3) + P(A_3)$$

$$\Rightarrow P(A_1 \cap A_2) = P(A_1) + P(A_2) - P(A_1 \cup A_2)$$

$$5.- \text{ Si } A_1, A_2, A_3 \in \mathcal{S} \Rightarrow P(A_1 \cup A_2 \cup A_3) = P(A_1) + P(A_2) + P(A_3) - P(A_1 \cap A_2) - P(A_1 \cap A_3) - P(A_2 \cap A_3) + P(A_1 \cap A_2 \cap A_3)$$

$$6.- \text{ Si } A_1, \dots, A_n \in \mathcal{S} \Rightarrow P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{i_1 < i_2} P(A_{i_1} \cap A_{i_2}) + \sum_{i_1 < i_2 < i_3} P(A_{i_1} \cap A_{i_2} \cap A_{i_3}) - \dots + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right)$$

$$7.- \text{ Si } A_1, \dots, A_n \in \mathcal{S} \Rightarrow P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i)$$

TEOREMA : a) Sea $A_1, A_2, \dots \in \mathcal{S}$ una sucesión creciente ($A_n \subseteq A_{n+1} \forall n \in \mathbb{N}$)

Entonces, $P\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} P(A_n)$

b) Sea $A_1, A_2, \dots \in \mathcal{S}$ una sucesión decreciente ($A_n \supseteq A_{n+1}, \forall n \in \mathbb{N}$)

Entonces, $P\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} P(A_n)$

demonstración

$$a) \lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n \quad \left(\text{¿por qué?} \right) \quad \lim A_n = \bigcap_{n=1}^{\infty} \left(\bigcup_{i=n}^{\infty} A_i \right) \xrightarrow{\text{sucesión creciente}} \bigcap_{n=1}^{\infty} \left(\bigcup_{i=1}^{\infty} A_i \right) = \bigcup_{i=1}^{\infty} A_i$$

$$B_1 := A_1 \quad ; \quad B_2 := A_2 \setminus A_1 \quad ; \quad B_3 := A_3 \setminus A_2 \quad ; \quad \dots \quad B_i \text{ disjuntos!}$$

$$P\left(\lim_{n \rightarrow \infty} A_n\right) = P\left(\bigcup_{n=1}^{\infty} A_n\right) = P\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} P(B_n) = \lim_{n \rightarrow \infty} \sum_{i=1}^n P(B_i) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=1}^n B_i\right) = \lim_{n \rightarrow \infty} P(A_n) \quad \square$$

TEOREMA: Sean $A_1, A_2, \dots \in \mathcal{S}$. Entonces $\mathbb{P}(\underline{\lim} A_n) \leq \underline{\lim} \mathbb{P}(A_n)$ y, además, $\underline{\lim} \mathbb{P}(A_n) \stackrel{(2)}{\leq} \mathbb{P}(\underline{\lim} A_n)$.

Demostración (1)

$$\mathbb{P}(\underline{\lim} A_n) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{i=n}^{\infty} A_i\right) = \mathbb{P}\left(\lim_{n \rightarrow \infty} \bigcap_{i=n}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcap_{i=n}^{\infty} A_i\right) \leq (*)$$

por otro lado: $\forall i \geq n, \mathbb{P}\left(\bigcap_{i=n}^{\infty} A_i\right) \leq \mathbb{P}(A_i)$. Por tanto obtenemos:

$$\mathbb{P}\left(\bigcap_{i=n}^{\infty} A_i\right) \leq \inf_{i \geq n} \mathbb{P}(A_i)$$

Entonces:

$$(*) \leq \lim_{n \rightarrow \infty} \underbrace{\inf_{i \geq n} \mathbb{P}(A_i)}_{\substack{\text{ii} \\ a_n \\ a_1 \leq a_2 \leq a_3 \dots}} = \sup_{n \geq 1} \inf_{i \geq n} \mathbb{P}(A_i) = \underline{\lim}_{n \rightarrow \infty} \mathbb{P}(A_n) \quad \square$$

Observación: como $\underline{\lim} \mathbb{P}(A_n) \leq \overline{\lim} \mathbb{P}(A_n) \Rightarrow$ por el teorema anterior \Rightarrow
 $\Rightarrow \mathbb{P}(\underline{\lim} A_n) \stackrel{(1)}{\leq} \underline{\lim} \mathbb{P}(A_n) \leq \overline{\lim} \mathbb{P}(A_n) \stackrel{(2)}{\leq} \mathbb{P}(\underline{\lim} A_n)$

COROLARIO: Si $A_1, A_2, \dots \in \mathcal{S}$ son una sucesión de eventos que converge, e.d.,
 $\lim A_n \Rightarrow \mathbb{P}(\lim A_n) = \lim \mathbb{P}(A_n)$

ESPACIO MUESTRAL DISCRETO

- $\Omega = \{a_1, a_2, \dots\}$
- $\mathcal{S} = \mathcal{P}(\Omega)$
- $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$

DEFINICIÓN: Una FUNCIÓN DE MASA $p: \Omega \rightarrow [0, 1]$ que verifica $\sum_{n=1}^{\infty} p(a_n) = 1$.
 Una función de masa p define una probabilidad por medio de la relación: si $A \in \mathcal{S}$, $\mathbb{P}(A) := \sum_{a \in A} p(a)$.

si \mathbb{P} es la probabilidad sobre un espacio muestral discreto \Rightarrow

$$\Rightarrow \forall a \in \Omega, p(a) := \mathbb{P}(\{a\}).$$

Si Ω es finito, existe una función de masa estándar (modelo de LAPLACE)

$$p(a) := \frac{1}{\text{card}(\Omega)}, \forall a \in A \Rightarrow \mathbb{P}(A) = \sum_{a \in A} p(a) = \frac{1}{\text{card}(\Omega)} \sum_{a \in A} 1 = \frac{\text{card}(A)}{\text{card}(\Omega)} = \frac{\# \text{ casos favorables}}{\# \text{ casos posibles}}$$

MODELOS SOBRE \mathbb{R}

- $\Omega = \mathbb{R}$
- $S = \mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, x] : x \in \mathbb{R}\})$

DEFINICIÓN: La función de distribución asociada a una probabilidad \mathbb{P} sobre $\Omega = \mathbb{R}$ es la función $F: \mathbb{R} \rightarrow [0, 1]$ definida por $F(x) := \mathbb{P}((-\infty, x])$ ($S = \mathcal{B}(\mathbb{R})$).

PROPIEDADES:

a) $\lim_{x \rightarrow -\infty} F(x) = 0$

b) $\lim_{x \rightarrow \infty} F(x) = 1$

c) F es una función creciente

d) F es continua por la derecha.

demostración a

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{x \rightarrow -\infty} \mathbb{P}((-\infty, x]) = \mathbb{P}\left(\lim_{x \rightarrow -\infty} (-\infty, x]\right) = \mathbb{P}(\emptyset) = 0$$

demostración b

$$\lim_{x \rightarrow \infty} F(x) = \lim_{x \rightarrow \infty} \mathbb{P}((-\infty, x]) = \mathbb{P}\left(\lim_{x \rightarrow \infty} (-\infty, x]\right) = \mathbb{P}(\mathbb{R}) = \mathbb{P}(\Omega) = 1$$

demostración c

$$\begin{aligned} \text{Si } a \leq b, \quad F(b) &= \mathbb{P}((-\infty, b]) = \mathbb{P}((-\infty, a] \cup (a, b]) = \\ &= \mathbb{P}((-\infty, a]) + \mathbb{P}((a, b]) \geq \mathbb{P}((-\infty, a]) = F(a) \end{aligned}$$


demostración d

$$\left[F \text{ es continua a la derecha en } x, F: \mathbb{R} \rightarrow \mathbb{R} \text{ si } \lim_{\substack{h \rightarrow 0 \\ h > 0}} F(x+h) = F(x) \right]$$

$$\lim_{\substack{h \rightarrow 0 \\ h > 0}} F(x+h) = \lim_{h \rightarrow 0^+} F(x+h) = \lim_{h \rightarrow 0^+} \mathbb{P}((-\infty, x+h]) = \mathbb{P}\left(\lim_{h \rightarrow 0^+} (-\infty, x+h]\right) =$$

$$\stackrel{\text{decreciente}}{=} \mathbb{P}\left(\bigcap_{h > 0} (-\infty, x+h]\right) = \mathbb{P}((-\infty, x]) = F(x)$$

Observación: ¿Por qué no se puede utilizar una función de masa sobre $\Omega = \mathbb{R}$?
 $\sum_{a \in \Omega} p(a) \neq 1$ no puede ser porque una serie de una familia infinita no numerable > 0 no converge, es $+\infty$!



Observación: Si F es una función que verifica las anteriores propiedades, entonces se puede definir una probabilidad P asociada a F sobre $\mathcal{B}(\mathbb{R})$ como $P((-\infty, x]) := F(x)$.


Si $\Omega = \mathbb{R}^n$, $\mathcal{S} = \mathcal{B}(\mathbb{R}^n) = \sigma\left(\{(-\infty, \dots, x_i] \times \dots \times (-\infty, \dots, x_n] : x_i \in \mathbb{R}\}\right)$

MODELOS SOBRE \mathbb{R}^n

DEFINICIÓN: Se define la FUNCIÓN DE DISTRIBUCIÓN asociada a P sobre $\mathcal{B}(\mathbb{R}^n)$ como $F: \mathbb{R}^n \rightarrow [0, 1]$.

$$F(x_1, \dots, x_n) := P\left((-\infty, x_1] \times \dots \times (-\infty, x_n]\right)$$

Ejemplo: \mathbb{R}^2



PROPIEDADES:

a) $\lim_{\substack{(x_1, \dots, x_n) \rightarrow -\infty \\ \text{alguno (al menos uno)}}} F(x_1, \dots, x_n) = 0$

b) $\lim_{\substack{(x_1, \dots, x_n) \rightarrow \infty \\ \text{todos}}} F(x_1, \dots, x_n) = 1$

c) F es creciente en cada una de sus variables.

d) F es continua por la derecha en cada una de sus variables.

Observación: Si F es una función de distribución, es decir, F verifica las propiedades anteriores, entonces puedo definir una probabilidad sobre $\mathcal{B}(\mathbb{R}^n)$ por $P\left((-\infty, x_1] \times \dots \times (-\infty, x_n]\right) := F(x_1, \dots, x_n)$

PROBABILIDAD CONDICIONADA Y EVENTOS INDEPENDIENTES

DEFINICIÓN: La probabilidad de un evento A CONDICIONADA a un evento B se define como:

$$P(A|B) := \frac{P(A \cap B)}{P(B)}$$

Ejemplo: $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{S} = \mathcal{P}(\Omega)$, $P(\{x_i\}) = \frac{1}{6} \quad \forall i=1, \dots, 6$.

$A = \text{"sale 1"}$

$B = \text{"sale un número impar"}$

$$\begin{array}{l} P(A) = \frac{1}{6} \\ P(B) = \frac{1}{2} \end{array} \left\{ \begin{array}{l} P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)}{P(B)} = \frac{1/6}{1/2} = \frac{1}{3} \end{array} \right.$$

DEFINICIÓN: Los eventos A y B son INDEPENDIENTES si $P(A \cap B) = P(A)P(B)$

PROPOSICIÓN: Los eventos A y B son independientes \iff

$$\iff P(A|B) = P(A) \quad (\text{o} \quad P(B|A) = P(B))$$

demonstración:

$$\Rightarrow \text{Si } A \text{ y } B \text{ son independientes: } P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) \cdot P(B)}{P(B)} = P(A)$$

$$\Leftarrow P(A \cap B) = P(A|B) \cdot P(B) = P(A) \cdot P(B) \\ (P(B|A) \cdot P(A))$$

Ejemplo: lanzar dos veces una moneda

$$\Omega = \{(c, c), (c, x), (x, c), (x, x)\}$$

$A = \text{"sale cara en el primer lanzamiento"}$

$B = \text{"sale cara en el segundo lanzamiento"}$

$$P(A) = P(\{(c, c), (c, x)\}) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

$$P(B) = P(\{(c, c), (x, c)\}) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

$$P(A \cap B) = P(\{(c, c)\}) = \frac{1}{4}$$

Como $P(A \cap B) = P(A) \cdot P(B)$, ya que $\frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} \Rightarrow A$ y B son independientes.

Ejemplo: lanzar dos veces una moneda

$$\Omega = \{(c,c), (c,x), (x,c), (x,x)\}$$

D = "sale exactamente una cara en los dos lanzamientos"

¿Son D y B independientes?

$$P(D) = P(\{(c,x), (x,c)\}) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

$$P(B \cap D) = P(\{(x,c)\}) = \frac{1}{4}$$

Como $P(B \cap D) = P(B) \cdot P(D)$ porque $\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \Rightarrow B$ y D son independientes

DEFINICIÓN: Los eventos $\{A_i\}_{i \in I}$ son INDEPENDIENTES si $\forall \{i_1, i_2, \dots, i_k\} \subset I$ tenemos $P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdot \dots \cdot P(A_{i_k})$

Ejemplo:

Si $\text{card}(I) = 3$

A, B, C son independientes si:

$$\begin{cases} P(A \cap B \cap C) = P(A) \cdot P(B) \cdot P(C) \\ P(A \cap B) = P(A) \cdot P(B) \\ P(A \cap C) = P(A) \cdot P(C) \\ P(B \cap C) = P(B) \cdot P(C) \end{cases}$$

REGLAS PARA CALCULAR PROBABILIDADES

TEOREMA (Regla de multiplicación): Sean A_1, A_2, \dots, A_n eventos, entonces,

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdot \dots \cdot P(A_n|A_1 \cap \dots \cap A_{n-1})$$

demonstración

Si $n=3$,

$$\underbrace{P(A_3|A_1 \cap A_2)}_{\frac{P(A_1 \cap A_2 \cap A_3)}{P(A_1 \cap A_2)}} \cdot \underbrace{P(A_2|A_1)}_{\frac{P(A_2 \cap A_1)}{P(A_1)}} \cdot P(A_1) = \frac{P(A_1 \cap A_2 \cap A_3)}{P(A_1 \cap A_2)} \cdot \frac{P(A_2 \cap A_1)}{P(A_1)} \cdot P(A_1)$$
$$= P(A_1 \cap A_2 \cap A_3) \quad \square$$

Ejemplo: Una urna con $\left\{ \begin{array}{l} 20 \text{ bolas blancas} \\ 10 \text{ bolas negras} \end{array} \right\}$ y hacemos

3 extracciones sin devolución.

• ¿cuál es la probabilidad de que las 3 bolas sean blancas?

A_i = "La i -ésima bola es blanca" \rightarrow buscamos $P(A_1 \cap A_2 \cap A_3)$

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) = \frac{20}{30} \cdot \frac{19}{29} \cdot \frac{18}{28}$$


TEOREMA (Regla de la probabilidad total): Sean A_1, \dots, A_n eventos tales

que:

a) $\bigcup_{i=1}^n A_i = \Omega$

b) $A_i \cap A_j = \emptyset \quad \forall i, j: i \neq j$ (disjuntos)

Partición de Ω



Entonces:

$$P(B) = \sum_{i=1}^n P(A_i) \cdot P(B|A_i)$$

demonstración:


$$P(B) = P\left(B \cap \left(\bigcup_{i=1}^n A_i\right)\right) = P\left(\bigcup_{i=1}^n (B \cap A_i)\right) \stackrel{A_i \text{ disjuntos}}{=} \sum_{i=1}^n P(B \cap A_i) =$$
$$= \sum_{i=1}^n P(B|A_i) \cdot P(A_i) \quad \square$$

TEOREMA (Regla de Bayes): Sean A_1, \dots, A_n eventos tales que:

a) $\bigcup_{i=1}^n A_i = \Omega$

b) $A_i \cap A_j = \emptyset \quad \forall i, j: i \neq j$ (disjuntos)

Partición de Ω



Entonces:

$$P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{\sum_{k=1}^n P(A_k) \cdot P(B|A_k)}$$

demonstración

$$P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{P(B)}$$

$$= \frac{P(A_i) \cdot P(B|A_i)}{\sum_{k=1}^n P(A_k) \cdot P(B|A_k)} \quad \square$$

Regla de Bayes

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

demonstración

$$\frac{P(B|A) \cdot P(A)}{P(B)} = \frac{\frac{P(B \cap A)}{P(A)} \cdot P(A)}{P(B)} = \frac{P(B \cap A)}{P(B)} = P(A|B) \quad \square$$

Observación ¿Por qué $P(A|B) \neq P(B|A)$?

$A = \text{"sale 1"}$

$$P(A) = 1/6$$

$B = \text{"sale número impar"}$

$$P(B) = 1/2$$

$$P(A|B) = 1/3$$


$$P(A|B) \neq P(B|A)$$

$$P(B|A) = 1$$

Según la Regla de Bayes:

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)} = \frac{1/3 \cdot 1/2}{1/6} = 1$$

Ejemplo: Tenemos dos urnas: urna 1 tiene 3 bolas blancas y 2 negras; urna 2 tiene 2 bolas blancas y 3 negras.



$U1 =$ "meter la mano en la urna 1"
 $U2 =$ "meter la mano en la urna 2"
 $P(U1) = 1/3$, $P(U2) = 2/3$

- ¿Cuál es la probabilidad que la bola extraída sea blanca?
- Si sabemos que la bola extraída es blanca, ¿cuál es la probabilidad que la extracción se haya hecho en la $U1$?

1.
$$P(\underbrace{\text{"bda sea blanca"}}_B) = \underbrace{P(B|U1)}_{3/5} \cdot \underbrace{P(U1)}_{1/3} + \underbrace{P(B|U2)}_{2/5} \cdot \underbrace{P(U2)}_{2/5} = \frac{7}{15}$$

2.
$$P(U1|B) = \frac{P(B|U1) \cdot P(U1)}{P(B)} = \frac{3/5 \cdot 1/3}{7/15} = \frac{1}{3}$$

Ejemplo: Tenemos plantas de flores rojas homocigóticas y heterocigóticas y flores blancas homocigóticas:

rojas $\begin{cases} RR & \text{homocigóticas} \\ Rb & \text{heterocigóticas} \end{cases}$ blancas: bb

- Nos traen una planta de flores rojas.
- La cruzamos con una planta bb (flores blancas) y obtenemos 5 plantas

de flores rojas.
 • ¿cuál es la probabilidad que la planta fuera: RR ?

$P("5 plantas de flores rojas" | RR) = ? = 1$ (cruzando una RR con una $bb \rightarrow Rb$)
 $P("5 plantas de flores rojas" | Rb) = ? = $(\frac{1}{2})^5$ (cruzando una Rb con $bb \rightarrow Rb$)$

$$P(RR | "5 cruces de flores rojas") = \frac{1 \cdot P(RR) \cdot P("5 cruces de flores rojas" | RR)}{1 \cdot P(RR) \cdot P("5 cruces de flores rojas" | RR) + P(Rb) \cdot P("5 cruces de flores rojas" | Rb)} = \frac{1 \cdot \frac{1}{3}}{1 \cdot \frac{1}{3} + \frac{1}{32} \cdot \frac{2}{5}} = 0.932$$

* denominador (regla prob. total) = $P("5 cruces de flores rojas")$

TEMA 2: VARIABLES ALEATORIAS

DEFINICIÓN: Una VARIABLE ALEATORIA X sobre un espacio de probabilidad $(\Omega, \mathcal{S}, \mathbb{P})$ es una función $X: \Omega \rightarrow \mathbb{R}$ tal que $X^{-1}(A) \in \mathcal{S}$, $\forall A \in \mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, x]: x \in \mathbb{R}\})$.

\parallel
 $\{\omega \in \Omega: X(\omega) \in A\}$

DEFINICIÓN: Se define \mathbb{P}_X , una PROBABILIDAD SOBRE $\mathcal{B}(\mathbb{R})$, como:

$$\mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A)) \quad , \quad \forall A \in \mathcal{B}(\mathbb{R})$$

Con esta definición, $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_X)$ es un espacio de probabilidad.

PROPIEDADES:

i) $\mathbb{P}_X(A) \in [0, 1]$, $\forall A \in \mathcal{B}(\mathbb{R})$ (\mathbb{P} es una probabilidad)

ii) $\mathbb{P}_X(\mathbb{R}) = 1$

demostración: $\mathbb{P}_X(\mathbb{R}) = \mathbb{P}(X^{-1}(\mathbb{R})) = \mathbb{P}(\Omega) = 1$

iii) Si $A_1, A_2, \dots, A_n \in \mathcal{B}(\mathbb{R})$ son disjuntos.

$$\mathbb{P}_X\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}_X(A_i)$$

demostración: $\mathbb{P}(X^{-1}(\bigcup_{i=1}^{\infty} A_i)) = \mathbb{P}(\bigcup_{i=1}^{\infty} X^{-1}(A_i)) = \sum_{i=1}^{\infty} \overbrace{\mathbb{P}(X^{-1}(A_i))}^{\mathbb{P}_X(A_i)}$

DEFINICIÓN: La FUNCIÓN DE DISTRIBUCIÓN de una variable aleatoria X es $x \in \mathbb{R}$, $F_X(x) := \mathbb{P}_X((-\infty, x])$

$$X^{-1}((-\infty, x]) = \{\omega \in \Omega: X(\omega) \in (-\infty, x]\} = \{\omega \in \Omega: X(\omega) \leq x\}$$



$$F_X(x) := \mathbb{P}_X((-\infty, x]) = \mathbb{P}(X^{-1}((-\infty, x])) = \mathbb{P}(X \leq x)$$

↖ variable aleatoria
↗ valor

Ejemplo:

$$\Omega = \{ccc, ccx, cxc, xcc, cxx, xc x, xxc, xxx\}$$

$$P(\{w_i\}) = \frac{1}{8}$$

$$S = P(\Omega) \Rightarrow (\Omega, S = P(\Omega), P)$$

► variable aleatoria $X = \text{"nº de caras"} \in \{0, 1, 2, 3\}$

$$P(X=0) = P_X(\{0\}) = \frac{1}{8}$$

$$P(X=1) = P_X(\{1\}) = \frac{3}{8}$$

$$P(X=2) = P_X(\{2\}) = \frac{3}{8}$$

$$P(X=3) = P_X(\{3\}) = \frac{1}{8}$$


$$(\mathbb{R}, B(\mathbb{R}), P_X)$$

↓ en este ejemplo

$$(\overbrace{\{0, 1, 2, 3\}}^{c}, B(c), P_X)$$


$$x \in \mathbb{R}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1/8 & \text{si } 0 \leq x < 1 \\ 1/8 + 3/8 & \text{si } 1 \leq x < 2 \\ 1/8 + 3/8 + 3/8 & \text{si } 2 \leq x < 3 \\ 1 & \text{si } 3 \leq x \end{cases}$$



DEFINICIÓN: Las VARIABLES ALEATORIAS DISCRETAS son las variables aleatorias que pueden tomar solo una cantidad finita o numerable de valores de \mathbb{R} .

• Si X es discreta, la variable aleatoria definida por su función de masa, es decir $p: \{x_1, x_2, \dots\} \rightarrow [0, 1]$, $p(x_i) = P(X=x_i)$



DEFINICIÓN: La MEDIA (o ESPERANZA) de una variable aleatoria discreta X se define como:

$$\mu = E(X) = EX = \sum_{n=1}^{\infty} x_n \cdot P(X=x_n)$$

(si por ejemplo 90% parejas \rightarrow 0 hijos
10% parejas \rightarrow 1 hijo
 $\Rightarrow \mu = 0.90\% + 1.10\% = 0.1$)

DEFINICIÓN: Una MODA de una variable aleatoria ^{discreta} X se define como x_i tal que $p(x_i) = \max\{p(x_k) : k \in \mathbb{N}\}$

DEFINICIÓN: La MEDIANA de una variable aleatoria ^{discreta} X es el valor M tal que $F_X(M^-) = \lim_{\substack{h \rightarrow 0 \\ h > 0}} F_X(M-h) \leq 1/2$ y $F_X(M) \geq 1/2$.

DEFINICIÓN: La VARIANZA de una variable aleatoria discreta X es:

$$\sigma^2 = V(X) = E((X - E(X))^2) = \sum_n (x_n - \mu)^2 \cdot P(X=x_n)$$

DEFINICIÓN: La DESVIACIÓN TÍPICA es $\sigma = \sqrt{\sigma^2} = \sqrt{V(X)}$.

DEFINICIÓN: El MOMENTO NO CENTRADO de ORDEN $k = 1, 2, 3, \dots$ es $E(X^k) = \sum_n x_n^k \cdot P(X=x_n)$



DEFINICIÓN: El MOMENTO CENTRADO es:

$$E((X - E(X))^k) = \sum_n (x_n - \mu)^k \cdot P(X=x_n)$$

VARIABLES ALEATORIAS CONTINUAS

Son las variables aleatorias $X: \Omega \rightarrow \mathbb{R}$ que pueden tomar cualquier valor real, y que existe una función $f_x: \mathbb{R} \rightarrow [0, \infty)$ que se llama densidad tal que

$$\int_{\mathbb{R}} f_x(x) dx = 1 \quad \text{y} \quad P(X \leq x) = \int_{-\infty}^x f_x(y) dy \Rightarrow F'_x(x) = f_x(x)$$



Observación:

- $P(X = x_n)$ si X es v.a. discreta es > 0 .
- Si X es v.a. continua $P(X = x) = 0$.
- $f_x(x) = F'_x(x) = \lim_{h \rightarrow 0} \frac{F_x(x+h) - F_x(x)}{h} = \lim_{h \rightarrow 0} \frac{P(X \leq x+h) - P(X \leq x)}{h}$
 $= \lim_{h \rightarrow 0} \frac{P(x < X \leq x+h)}{h} \rightarrow P(X=x)$

DEFINICIÓN: La MEDIA de una variable aleatoria continua es:


$$\mu = E(X) = \int_{\mathbb{R}} x \cdot \underbrace{f_x(x)}_{= P(X=x)} dx$$

DEFINICIÓN: La VARIANZA de una variable aleatoria continua es:

$$\sigma^2 = E((X - E(X))^2) = \int_{\mathbb{R}} (x - \mu)^2 \cdot f_x(x) dx$$

DEFINICIÓN: El MOMENTO NO CENTRADO de ORDEN $K=1, 2, 3, \dots$ es:



$$E(X^K) = \int_{\mathbb{R}} x^K \cdot f_x(x) dx$$



$$F_x(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_x(y) dy$$

$$F_x(b) - F_x(a) = \mathbb{P}(a < X < b) = \int_a^b f_x(y) dy$$

Observación: Existen variables aleatorias X que no son ni continuas ni discretas.



Todas las variables aleatorias X tienen un conjunto $S_X := \{x \in \mathbb{R} \mid F_x(x) - F_x(x^-) > 0\}$ que es el máximo numerable y $x \in \mathbb{R}$, $F_x(x) = \int_{-\infty}^x f_x(y) dy + \sum_{\substack{x_i \in S_X \\ x_i \leq x}} [F_x(x_i) - F_x(x_i^-)]$ donde $f_x(y) = F_x'(y)$, $\forall y \in \mathbb{R} \setminus S_X$

$$F_x(x^-) = \lim_{\substack{h \rightarrow 0 \\ h < 0}} F(x+h)$$

- Si X es variable continua $\Rightarrow S_X = \emptyset$
- Si X es variable discreta $\Rightarrow S_X = \{x_n\}_{n \in \mathbb{N}}$ y $f_x \equiv 0$.

$$\mathbb{E}(X) = \int_{\mathbb{R} \setminus S_X} x f_x(x) dx + \sum_{x_i \in S_X} x_i \cdot [F_x(x_i) - F_x(x_i^-)]$$

" $\int_{\mathbb{R}} x f_x(x) dx$ porque S_X es al máximo numerable.

$$V(X) = \int_{\mathbb{R} \setminus S_X} [x - E(X)]^2 f_X(x) dx + \sum_{x_i \in S_X} (x_i - E(X))^2 \underbrace{[F_X(x_i) - F_X(x_i^-)]}_{P(X=x_i)}$$

DESIGUALDAD DE CHEBYCHEV

Sea X una variable aleatoria y $g: \mathbb{R} \rightarrow [0, \infty]$ no negativa entonces, $\forall \varepsilon > 0$,

$$\boxed{P_X(\{x \in \mathbb{R} : g(x) \geq \varepsilon\}) \leq \frac{E(g(x))}{\varepsilon}}$$

Demostración

$$E(g(x)) = \int_{\mathbb{R}} x \cdot f_{g(x)}(x) dx = \int_{\mathbb{R}} g(x) \cdot f_X(x) dx =$$

$$= \int_{\{x \in \mathbb{R} : g(x) \geq \varepsilon\}} g(x) \cdot f_X(x) dx + \int_{\{x \in \mathbb{R} : g(x) < \varepsilon\}} g(x) \cdot f_X(x) dx \geq$$

$$\begin{aligned} & \overset{g(x)f(x) \geq 0}{\geq} \int_{\{x \in \mathbb{R} : g(x) \geq \varepsilon\}} g(x) \cdot f_X(x) dx \geq \underset{g(x) \geq \varepsilon}{\varepsilon} \int_{\{x \in \mathbb{R} : g(x) \geq \varepsilon\}} f_X(x) dx = \varepsilon \cdot P_X(\{x \in \mathbb{R} : g(x) \geq \varepsilon\}) \quad \square \end{aligned}$$

COROLARIO: Si $E(X) = \mu$ y $V(X) = \sigma^2 \Rightarrow$

$$\Rightarrow \forall k > 0, \quad P_X(\{x \in \mathbb{R} : |x - \mu| \geq k\sigma\}) \leq \frac{1}{k^2}$$

Demostración

$$g(x) := (x - \mu)^2$$

$$\begin{aligned} P_X(\{x \in \mathbb{R} : |x - \mu| \geq k\sigma\}) &= P(\{x \in \mathbb{R} : (x - \mu)^2 \geq k^2 \sigma^2\}) \leq \\ &\leq \frac{E((x - \mu)^2)}{k^2 \sigma^2} = \frac{\sigma^2}{k^2 \sigma^2} = \frac{1}{k^2} \quad \square \end{aligned}$$

Si $k=2$, $\mathbb{P}_X(\{x \in \mathbb{R} : |x - \mu| \geq 2\sigma\}) \leq \frac{1}{4}$

