



VECTORES ALEATORIOS

DEFINICIÓN: Un vector aleatorio $X = (X_1, X_2, \dots, X_n)$ es una función $X: \Omega \rightarrow \mathbb{R}^n$ tal que $\forall A \in \mathcal{B}(\mathbb{R}^n)$, $X^{-1}(A) \in \mathcal{S}$, donde $(\Omega, \mathcal{S}, \mathbb{P})$ es el espacio de probabilidad.

DEFINICIÓN: Se puede definir \mathbb{P}_X sobre \mathbb{R}^n definido por el vector aleatorio X como, $\forall A \in \mathcal{B}(\mathbb{R}^n)$, $\mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A))$



DEFINICIÓN: Se define la función de distribución de X como $\forall x \in \mathbb{R}^n$, $F_X(x) := \mathbb{P}_X((-\infty, x_1] \times \dots \times (-\infty, x_n]) = \mathbb{P}(X \in (-\infty, x_1] \times \dots \times (-\infty, x_n])$



$(x_1, \dots, x_n) = X$ vector aleatorio	X variable aleatoria
$X: \Omega \rightarrow \mathbb{R}^n$ tal que $X^{-1}(A) \in \mathcal{S}, \forall A \in \mathcal{B}(\mathbb{R}^n)$	$X: \Omega \rightarrow \mathbb{R}$ tal que $X^{-1}(A) \in \mathcal{S}, \forall A \in \mathcal{B}(\mathbb{R})$
$\mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A)) \quad \forall A \in \mathcal{B}(\mathbb{R}^n)$	$\mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A)), \quad \forall A \in \mathcal{B}(\mathbb{R})$
$F_X(x) = \mathbb{P}_X((-\infty, x_1] \times \dots \times (-\infty, x_n])$ $\forall (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$	$F_X(x) = \mathbb{P}_X((-\infty, x])$, $\forall x \in \mathbb{R}$

PROPIEDADES (VARIABLES ALEATORIAS)

$F_X: \mathbb{R} \rightarrow [0,1]$ tal que:

1. $\lim_{x \rightarrow \infty} F_X(x) = 1$

2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$

3. F_X es continua desde la derecha.

4. F_X es monótona creciente.

PROPIEDADES (VECTORES ALEATORIOS)

$F_X: \mathbb{R}^n \rightarrow [0,1]$ tal que:


1. $\lim_{x_i \rightarrow \infty} F_X(x) = 1$

2. $\lim_{x_i \rightarrow -\infty} F_X(x) = 0$

3. F_X es continua por la derecha en cualquier componente x_i , en todos los puntos de \mathbb{R}^n .

4. Si $x, y \in \mathbb{R}^n$, $\begin{cases} y_1 \geq x_1 \\ y_2 \geq x_2 \end{cases} \Rightarrow$

$\Rightarrow F_X(y_1, y_2) - F_X(x_1, y_2) - F_X(y_1, x_2) + F_X(x_1, x_2) \geq 0$



LEOREMA: $X = (X_1, X_2, \dots, X_n)$ función de Ω a valores en \mathbb{R}^n . X es un vector aleatorio $\Leftrightarrow X_i$ es una variable aleatoria $\forall i = 1, \dots, n$.

demostración

\Rightarrow Fijo i en $1, \dots, n$ $X_i^{-1}((-\infty, x]) \in \mathcal{S}, \forall x \in \mathbb{R}$.

$$\overset{||}{X^{-1}}(\mathbb{R} \times \dots \times \mathbb{R} \times (-\infty, x] \times \dots \times \mathbb{R}) \in \mathcal{S}$$

\Leftarrow Fijo $x \in (x_1, \dots, x_n) \in \mathbb{R}^n$, ¿ $X^{-1}((-\infty, x_1] \times \dots \times (-\infty, x_n]) \in \mathcal{S} ? =$
 $= \bigcap_{i=1}^n X_i^{-1}((-\infty, x_i]) \in \mathcal{S}$

VECTORES ALEATORIOS DISCRETOS

Los vectores aleatorios discretos son vectores aleatorios que toman una cantidad finita o numerable de valores.

Ejemplo: "lanzamiento de dos dados" = Ω

(X, Y) vector aleatorio discreto el definido por:

$X = \text{"éxito dado 1"}$ y $Y = \text{"éxito dado 2"}$

$$(X, Y) \in \{(1,1), (1,2), (1,3), \dots, (2,1), (2,2), \dots, (6,5), (6,6)\}$$

Un vector aleatorio $(X_1, X_2, \dots, X_n) = X$ discreto está caracterizado por su función de masa conjunta, que es la función:

$$P_X(X_{i1}^1, X_{i2}^2, \dots, X_{in}^n) = P(X_1 = X_{i1}^1, X_2 = X_{i2}^2, \dots, X_n = X_{in}^n)$$

$$X_{ik}^i \in \mathbb{R}$$

Una función de masa conjunta verifica:

$$1) P_X(X_{i1}^1, \dots, X_{in}^n) \in [0,1] \xrightarrow{\dim 2} P_X(x_i, y_j) \in [0,1] \forall x_i, y_j$$

$$2) \sum_{x_i} \sum_{y_j} P_X(x_i, y_j) = 1$$

En el ejemplo de los dados.

$$P_X(i,j) = P(X=i, Y=j) = 1/36$$

$$\forall i,j = 1, \dots, 6$$

X Y	1	2	3	4	5	6
1	1/36	1/36	1/36	1/36	1/36	1/36
2	1/36	1/36	1/36	1/36	1/36	1/36
3	1/36	1/36	1/36	1/36	1/36	1/36
4	1/36	1/36	1/36	1/36	1/36	1/36
5	1/36	1/36	1/36	1/36	1/36	1/36
6	1/36	1/36	1/36	1/36	1/36	1/36

Ejemplo 2: $\Omega = \text{"lanzamiento de dos dados"}$

$(X, Z): \Omega \rightarrow \mathbb{R}^2$ definido como: $X = \text{"exito dado 1"}$
 $Z = \text{"maximo entre dado 1 y dado 2"}$

X Z	1	2	3	4	5	6
1	1/36	0	0	0	0	0
2	1/36	2/36	0	0	0	0
3	1/36	1/36	3/36	0	0	0
4	1/36	1/36	1/36	4/36	0	0
5	1/36	1/36	1/36	1/36	5/36	0
6	1/36	1/36	1/36	1/36	1/36	6/36

$$(*) = P(X=4, Z=3) = P_{(X,Z)}(4,3)$$

$$P(X=1, Z=1) = P(Z=1|X=1) \cdot P(X=1) = 1/6 \cdot 1/6 = 1/36$$

$$P(X=1, Z=2) = P(Z=2|X=1) \cdot P(X=1) = 1/6 \cdot 1/6 = 1/36$$

$$P(X=2, Z=1) = P(Z=1|X=2) \cdot P(X=2) = 0 \cdot 1/6 = 0$$

$$P(X=2, Z=2) = P(Z=2|X=2) \cdot P(X=2) = 2/6 \cdot 1/6 = 2/36$$

$$P(X=3, Z=3) = P(Z=3|X=3) \cdot P(X=3) = 3/6 \cdot 1/6 = 3/36$$

$$\vdots$$

$$P(X=6, Z=6) = P(Z=6|X=6) \cdot P(X=6) = 6/6 \cdot 1/6 = 6/36$$

Si (X, Y) es un vector aleatorio, entonces X e Y son variables aleatorias.

$$P_X(x_i) = \sum_{y_j} P_{(X,Y)}(x_i, y_j)$$

$$P_Y(y_j) = \sum_{x_i} P_{(X,Y)}(x_i, y_j)$$

Entonces:

$$P_X(1) = P(X=1) = 1/6 \text{ (suma elementos columna 1).}$$

$$P_X(2) = P(X=2) = 1/6 \text{ (suma elementos columna 2).}$$

\vdots

$$P_X(6) = P(X=6) = 1/6 \text{ (suma elementos columna 6).}$$

$$P_Z(1) = P(Z=1) = 1/36 \text{ (suma elementos fila 1).}$$

$$P_Z(2) = P(Z=2) = 3/36 \text{ (suma elementos fila 2).}$$

\vdots

$$P_Z(6) = P(Z=6) = 11/36 \text{ (suma elementos fila 6).}$$

DEFINICIÓN: La DISTRIBUCIÓN de X CONDICIONADA a $Y=y_j$ viene definida por la función de masa condicionada:

$$P_{X|Y=y_j}(x_i) = P(X=x_i | Y=y_j) = \frac{P(X=x_i, Y=y_j)}{P(Y=y_j)} = \frac{P_{(X,Y)}(x_i, y_j)}{P_Y(y_j)}$$

$$\text{En el ejemplo 1: } P_{X|Y=j}(i) = \frac{P_{(X,Y)}(i,j)}{P_Y(j)} = \frac{1/36}{1/6} = 1/6 = P_X(i)$$

$$\text{En el ejemplo 2: } P_{X|Z=j}(i) = \frac{P_{(X,Z)}(i,j)}{P_Z(j)} \Rightarrow \text{Si } i=4, j=2 \Rightarrow$$

$$\Rightarrow \frac{P_{(X,Z)}(4,2)}{P_Z(2)} = \frac{0}{3/36} = 0 \neq P_X(4) = 1/6$$

la MEDIA es:

$$\mathbb{E} \begin{bmatrix} X \\ Y \end{bmatrix} = \begin{bmatrix} \mathbb{E}(X) \\ \mathbb{E}(Y) \end{bmatrix} = \begin{bmatrix} \sum x_i \cdot \mathbb{P}(X=x_i) \\ \sum y_i \cdot \mathbb{P}(Y=y_i) \end{bmatrix}$$

Sea $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ un vector aleatorio discreto, entonces la varianza es: no existe la varianza del vector, solo

la de sus componentes.

$$\text{Var}(X), \text{Var}(Y) \quad \left[\text{Var}(X) = \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \right]$$

la COVARIANZA de X con Y :

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y)))$$

Si X, Y son discretos $\Rightarrow \sum_{x_i} \sum_{y_j} (x_i - \mathbb{E}(X))(y_j - \mathbb{E}(Y)) \cdot \mathbb{P}(X=x_i, Y=y_j)$

la CORRELACIÓN de X con Y es:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} \in [-1, 1]$$

► Si $\text{Cov}(X, Y) = 0$ entonces X y Y son independientes. $\Rightarrow \text{Corr}(X, Y) = 0$

► Si $\text{Cov}(X, Y) > 0$ implica que entre X e Y hay una relación directa.

► Si $\text{Cov}(X, Y) < 0$ implica que entre X e Y hay una relación inversa.

MATRIZ DE COVARIANZAS DE UN VECTOR ALEATORIO (X_1, X_2, \dots, X_n)

$$\Sigma = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Cov}(X_n, X_n) \end{bmatrix}$$

Var(X_1) \leftarrow (Cov(X_1, X_1))
 \nwarrow
 simétrica \leftarrow Var(X_2) \leftarrow (Cov(X_2, X_2)) \leftarrow Var(X_n) \leftarrow (Cov(X_n, X_n))

$$\rho = \begin{bmatrix} \text{Corr}(X_1, X_1) & \text{Corr}(X_1, X_2) & \dots & \text{Corr}(X_1, X_n) \\ \text{Corr}(X_2, X_1) & \text{Corr}(X_2, X_2) & \dots & \text{Corr}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Corr}(X_n, X_1) & \text{Corr}(X_n, X_2) & \dots & \text{Corr}(X_n, X_n) \end{bmatrix}$$

ρ \nwarrow
 simétrica \leftarrow 1 \leftarrow 1 \leftarrow 1 \leftarrow 1

VECTORES ALEATORIOS CONTINUOS

Un vector aleatorio es CONTINUO cuando toma valores en \mathbb{R}^n y su P_X (distribución) está definida por una función de densidad conjunta: $f_{(X,Y)}: \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que:

1. - $f_{(X,Y)}(x,y) \geq 0 \quad \forall (x,y) \in \mathbb{R}^2$

2. - $\iint_{\mathbb{R}^2} f_{(X,Y)}(x,y) dx dy = 1$

• La P_X está definida por $f_{(X,Y)}$ significa $(?) \rightarrow$ el profesor se expresa muy bien

Si $A \in \mathcal{B}(\mathbb{R}^2)$, $P((X,Y) \in A) = \iint_A f_{(X,Y)}(x,y) dx dy$

• $f_X(x)$, que es la densidad marginal de X del vector (X,Y) , es igual a $f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x,y) dy \quad \forall x \in \mathbb{R}$

\Rightarrow Para (X_1, X_2, \dots, X_n) :

$$f_{X_1}(x) = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} f_{(X_1, \dots, X_n)}(x, y_2, \dots, y_n) dy_2 \dots dy_n$$

$$\bullet f_Y(y) = \int_{\mathbb{R}} f_{(X,Y)}(x,y) dx, \quad \forall y \in \mathbb{R}.$$

La distribución CONDICIONADA de X condicionada a $Y=y$
 $x \in \mathbb{R}$, $f_{X|Y=y}(x) = \frac{f_{(X,Y)}(x,y)}{f_Y(y)}$

La COVARIANZA se define como:

$$\text{Cov}(X,Y) = \iint_{\mathbb{R}^2} (X - E(X))(Y - E(Y)) \cdot f_{(X,Y)}(x,y) dx dy$$

INDEPENDENCIA DE VARIABLES ALEATORIAS

DEFINICIÓN: Las variables aleatorias X_1, X_2, \dots, X_n sobre (Ω, \mathcal{S}) son INDEPENDIENTES si $\forall B_i \in \mathcal{B}(\mathbb{R}), i=1, \dots, n$.

$$\bullet P\left(\bigcap_{i=1}^n X_i^{-1}(B_i)\right) = \prod_{i=1}^n P(X_i^{-1}(B_i))$$

$$2. \underbrace{P_X(B_1 \times \dots \times B_n)}_{(X_1, \dots, X_n)} = \prod_{i=1}^n P_{X_i}(B_i)$$

Por la 2ª, como $F_X(x_1, \dots, x_n) = P_X((-\infty, x_1] \times \dots \times (-\infty, x_n])$ y

$F_{X_i}(x_i) = P_{X_i}((-\infty, x_i])$, entonces si X_1, \dots, X_n son independientes

$\Rightarrow F_X(x_1, \dots, x_n) = F_{X_1}(x_1) \cdot \dots \cdot F_{X_n}(x_n)$. Además, si X es discreto,

la independencia es equivalente $P_X(x_1, \dots, x_n) = P_{X_1}(x_1) \cdot \dots \cdot P_{X_n}(x_n)$

y si X es continua, entonces:

$$f_X(x_1, \dots, x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n)$$

$$f_X(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \partial x_2 \dots \partial x_n} F_X(x_1, \dots, x_n)$$

TEOREMA: Si X_1, X_2, \dots, X_n son independientes, entonces

$$E(X_1 X_2 \dots X_n) = E(X_1) \cdot \dots \cdot E(X_n)$$

demostración (si X_i son continuas) $\xrightarrow{\text{recor.}}$

$$E(g(X)) = \int_{\mathbb{R}^n} g(x_1, \dots, x_n) \cdot f_X(x_1, \dots, x_n) dx_1 \dots dx_n$$

$$E(X_1 X_2 \dots X_n) = \iiint \dots \int_{\mathbb{R}^n} X_1 X_2 \dots X_n \cdot f_{(X_1, \dots, X_n)}(x_1, \dots, x_n) dx_1 \dots dx_n =$$

$$= \int_{\mathbb{R}^n} \dots \int_{\mathbb{R}^n} X_1 X_2 \dots X_n \cdot f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n) dx_1 \dots dx_n =$$

$$= \int_{\mathbb{R}} X_1 f_{X_1}(x_1) dx_1 \cdot \int_{\mathbb{R}} X_2 \cdot f_{X_2}(x_2) dx_2 \cdot \dots \cdot \int_{\mathbb{R}} X_n \cdot f_{X_n}(x_n) dx_n =$$

$$= E(X_1) \cdot E(X_2) \cdot \dots \cdot E(X_n) \quad \square$$

TEOREMA: Si X e Y son independientes, entonces X e Y son incorreladas ($E(XY) - E(X)E(Y) = \text{Cov}(X, Y) = 0$).

demostración

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) \stackrel{\text{indep}}{=} E(X)E(Y) - E(X)E(Y) = 0 \quad \square$$

Observación: X e Y incorreladas $\nRightarrow X$ e Y independientes.

Contraejemplo:

Sea (X, Y) un vector aleatorio discreto con función de masa conjunta $f_{(X, Y)}$ definida por:

$Y \backslash X$	-1	0	1	
-1	0	1/4	0	1/4
0	1/4	0	1/4	1/2
1	0	1/4	0	1/4
	1/4	1/2	1/4	

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$\Rightarrow \sum_{x_i, y_j} x_i y_j P(X=x_i, Y=y_j) = 0 \quad \text{Incorrelados}$$

$$P(X=1, Y=1) = 0 \quad \nRightarrow X \text{ e } Y \text{ no son independientes}$$

$$P(X=1) \cdot P(Y=1) = 1/4 \cdot 1/4 = 1/16$$

TEOREMA: Sea $X = (X_1, \dots, X_n)$ vector aleatorio

$$a) \mathbb{E}\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i \mathbb{E}(X_i) + b, \quad a_i, b \in \mathbb{R}$$

$$b) V\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i^2 V(X_i) \quad \text{si } X_i \text{ son independientes}$$

demostración

$$\begin{aligned} a) \mathbb{E}\left(\sum_{i=1}^n a_i X_i + b\right) &= \int_{\mathbb{R}^n} \left(\sum_{i=1}^n a_i X_i + b\right) f_X(x_1, \dots, x_n) dx_1 \dots dx_n = \\ &= \sum_{i=1}^n a_i \int_{\mathbb{R}^n} X_i \cdot f_X(x_1, \dots, x_n) dx_1 \dots dx_n + b \underbrace{\int_{\mathbb{R}^n} f_X(x_1, \dots, x_n) dx_1 \dots dx_n}_{=1} = \\ &= \sum_{i=1}^n a_i \int_{\mathbb{R}} X_i dx_i \cdot \underbrace{\int_{\mathbb{R}^{n-1}} f_X(x_1, \dots, x_n) dx_1 dx_2 \dots dx_{i-1} dx_{i+1} \dots dx_n}_{f_{X_i}(x_i)} + b = \\ &= \sum_{i=1}^n a_i \mathbb{E}(X_i) + b \quad \square \end{aligned}$$

$$\begin{aligned} b) V(\sum a_i X_i + b) &= \mathbb{E}\left(\left[\sum a_i X_i + b - \sum a_i \mathbb{E}(X_i) - b\right]^2\right) = \\ &= \mathbb{E}\left(\left[\sum a_i (X_i - \mathbb{E}(X_i))\right]^2\right) = \\ &= \mathbb{E}\left(\sum_{i=1}^n a_i^2 (X_i - \mathbb{E}(X_i))^2 + 2 \sum_{i < j} a_i a_j (X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))\right) = \\ &= \sum_{i=1}^n a_i^2 V(X_i) + 2 \sum_{i < j} a_i a_j \underbrace{\text{Cov}(X_i, X_j)}_{=0} = \sum a_i^2 V(X_i) \quad \square \end{aligned}$$

MODELOS DE PROBABILIDAD

MODELOS DISCRETOS

1.- MODELO DE BERNOULLI $X \sim \text{Bernoulli}(p)$

$$X: \Omega \longrightarrow \{0, 1\}$$

 ↑ ↑
fracaso éxito

$$P(X=1) = p \in (0, 1)$$

$$P(X=0) = 1-p$$

$$E(X) = 1 \cdot p + 0 \cdot (1-p) = p$$

$$V(X) = (1-p)^2 \cdot p + (0-p)^2 (1-p) = (1-p) [(1-p)p + p^2] = p(1-p)$$

$$\text{Std}(X) = \sqrt{V(X)} = \sqrt{p(1-p)}$$

2.- MODELO BINOMIAL $X \sim \text{Bin}(n; p)$

X = "nº éxitos en n pruebas de Bernoulli(p) independientes"

$$X: \Omega \longrightarrow \{0, 1, 2, \dots, n\}$$

$$P(X=k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}, \quad k=0, 1, \dots, n$$

$$E(X) = \sum_{k=0}^n k \cdot \binom{n}{k} p^k \cdot (1-p)^{n-k}$$

$$X = X_1 + X_2 + \dots + X_n, \quad X_k \sim \text{Bernoulli}(p)$$

$$E(X) = E(X_1 + \dots + X_n) \overset{\uparrow}{=} \sum_{i=1}^n E(X_i) = n \cdot p$$

$$V(X) = V(X_1 + \dots + X_n) \overset{\downarrow}{=} \sum_{i=1}^n V(X_i) = n \cdot p(1-p) \quad X_i \text{ independientes}$$

$$\text{Std}(X) = \sqrt{V(X)} = \sqrt{n \cdot p(1-p)}$$

3.- MODELO DE POISSON

$X \sim \text{Poisson}(\lambda)$

$$X: \Omega \rightarrow \mathbb{N} \cup \{0\} \quad n \rightarrow \infty, p \rightarrow 0 \text{ tal que } np \rightarrow \lambda > 0, \lambda \neq \infty$$

$$P(X=k) = \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0 \\ np \rightarrow \lambda}} \binom{n}{k} p^k (1-p)^{n-k} = \lim \frac{n(n-1)\dots(n-k+1)}{k!} p^k (1-p)^{n-k}$$

$$= \lim \frac{n(n-1)\dots(n-k+1)}{k! n^k} (np)^k (1-p)^{n-k} =$$

$$= \lim \frac{1}{k!} \underbrace{\left(\frac{n}{n} \cdot \frac{n-1}{n} \dots \frac{n-k+1}{n} \right)}_{\text{tiende a 1 cuando } n \rightarrow \infty} (np)^k \underbrace{\frac{(1-p)^n}{(1-p)^k}}_{\text{tiende a 1}} =$$

$$= \frac{\lambda^k}{k!} \cdot \lim (1-p)^n = \frac{\lambda^k}{k!} \lim \left(1 - \underbrace{\left(\frac{\lambda}{n} \right)}_{p} \right)^n = \boxed{\frac{\lambda^k}{k!} e^{-\lambda}}$$

$$E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} \cdot e^{-\lambda} = \sum_{k=1}^{\infty} \lambda \cdot \frac{\lambda^{k-1}}{(k-1)!} \cdot e^{-\lambda} =$$

$$= \lambda \cdot e^{-\lambda} \cdot \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \lambda e^{-\lambda} e^{\lambda} = \underline{\lambda} = \lim np$$

$$V(X) = \lambda = \lim \underbrace{np}_{\lambda} \underbrace{(1-p)}_1$$

$$\text{Std}(X) = \sqrt{V(X)} = \sqrt{\lambda}$$

- Si $X \sim \text{Bin}(n; p)$ con $n \geq 30$, $p \leq 0.1$
 \Rightarrow puedo aproximar $X \sim \text{Poisson}(\lambda)$, $\lambda = np$

4.- MODELO DE LA GEOMÉTRICA

$$X \sim \text{Geométrica}(p)$$

X = "nº de fracasos antes de obtener el primer éxito en pruebas de Bernoulli(p)".

$$X: \Omega \rightarrow \mathbb{N} \cup \{0\}$$

$$P(X=k) = (1-p)^k \cdot p, \quad k=0, 1, \dots$$

$$E(X) = \sum_{k=0}^{\infty} k \cdot (1-p)^k p = \sum_{k=1}^{\infty} k (1-p)^k p =$$

$$= p \left[\begin{array}{c} (1-p) + \\ + (1-p)^2 + (1-p)^2 + \\ + (1-p)^3 + (1-p)^3 + (1-p)^3 + \\ \dots \end{array} \right]$$

sumamos las "columnas"

$$= p \left[\frac{1-p}{1-(1-p)} + \frac{(1-p)^2}{1-(1-p)} + \frac{(1-p)^3}{1-(1-p)} + \dots \right] = (1-p) + (1-p)^2 + (1-p)^3 + \dots$$

$$= \frac{1-p}{1-(1-p)} = \frac{1-p}{p}$$

$$V(X) = \frac{1-p}{p^2}$$

$$\text{Std}(X) = \sqrt{V(X)} = \sqrt{\frac{1-p}{p^2}} = \frac{\sqrt{1-p}}{p}$$

5. - BINOMIAL NEGATIVA

$$X \sim \text{BinNeg}(p, r) \quad r \in \mathbb{N}$$

$X =$ "nº fracasos obtenidos antes de obtener el r-ésimo éxito"

$$X: \Omega \rightarrow \mathbb{N} \cup \{0\}$$

$$P(X=k) = \binom{k+r-1}{k} \cdot p^r \cdot (1-p)^k \quad k=0,1,\dots,$$

$$E(X) = E(X_1 + \dots + X_r) = \sum_{i=1}^r E(X_i) = \frac{r(1-p)}{p}$$

donde $X_i =$ "nº fracasos obtenidos entre el (i-1)ésimo y el i-ésimo éxito." $X_i \sim \text{Geométrica}(p)$

6. - HIPERGEOMÉTRICA

$$X \sim \text{Hipergeométrica}(N; D; n)$$

$$N \in \mathbb{N}, D \in \{0, \dots, N\}$$

$X =$ "nº de éxitos obtenidos en n observaciones sin reemplazamiento de la población, donde D es el número de éxitos y N-D es el número de fracasos"

$$P(X=k) = \frac{\binom{D}{k} \binom{N-D}{n-k}}{\binom{N}{n}} \quad k = \max\{0, n-(N-D)\}, \dots, \min\{n, D\}$$

Observación: Si D y N-D \gg n, entonces tomar "con" o "sin" reemplazamiento no cambia mucho las cosas \Rightarrow

$$\Rightarrow X \sim \text{Binomial}\left(n; \frac{D}{N}\right)$$

$$E(X) = E(X_1 + \dots + X_n), \quad X_i = \begin{cases} 1 & \text{si éxito en la } i\text{-ésima observación} \\ 0 & \text{si fracaso en la } i\text{-ésima observación} \end{cases}$$

$$X_i \sim \text{Bernoulli}\left(\frac{D}{N}\right)$$

¿ $E(X_2) = D/N$? \rightarrow demostración


$$\begin{aligned} E(X_2) &= 1 \cdot P(X_2=1) + 0 \cdot P(X_2=0) = P(X_2=1) = P(X_2=1|X_1=1) \cdot P(X_1=1) + \\ &\quad + P(X_2=1|X_1=0) \cdot P(X_1=0) = \frac{D-1}{N-1} \cdot \frac{D}{N} + \frac{D}{N-1} \cdot \frac{N-D}{N} = \frac{D^2-D+DN-D^2}{N(N-1)} = \\ &= \frac{D(N-1)}{N(N-1)} = \frac{D}{N} \end{aligned}$$

$$V(X) = n \cdot \frac{D}{N} \cdot \frac{N-D}{N} \cdot \frac{N-n}{N-1}$$

MODELOS CONTINUOS

1. - $X \sim \text{Uniforme}(a, b)$ $a < b \in \mathbb{R}$

$$f_X(x) = \begin{cases} \frac{1}{b-a} & , x \in (a, b) \\ 0 & , x \notin (a, b) \end{cases}$$




$$E(X) = \int_{\mathbb{R}} x f_X(x) dx = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{a+b}{2}$$

$$V(X) = \int_{\mathbb{R}} (x - E(X))^2 \cdot f_X(x) dx = \int_a^b \left(x - \frac{a+b}{2}\right)^2 \cdot \frac{1}{b-a} dx = \frac{(b-a)^2}{12}$$

2. - $X \sim \text{Normal}(\mu, \sigma)$; $\mu \in \mathbb{R}$; $\sigma > 0$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} , \quad x \in \mathbb{R}$$



$$E(X) = \mu$$

$$V(X) = \sigma^2$$

PROPIEDADES DE LA NORMAL:

i) Si $X \sim N(\mu; \sigma) \Rightarrow Z := \frac{X-\mu}{\sigma} \sim N(0, 1)$


demonstración:

$$\begin{aligned} f_Z(z) &= f_{\frac{X-\mu}{\sigma}}(z) = f_X(\sigma z + \mu) \overset{\text{jacobiano transform}}{\cdot \sigma} = \\ &= \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(\sigma z + \mu - \mu)^2}{2\sigma^2}} \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \end{aligned}$$

independientes $\Rightarrow \sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i; \sqrt{\sum_{i=1}^n \sigma_i^2}\right)$

3.- $X \sim \text{Exponencial}(\beta)$, $\beta > 0$

$$f_X(x) = \begin{cases} \frac{1}{\beta} e^{-x/\beta}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$



$$E(X) = \beta$$

$$V(X) = \beta^2$$

La exponencial es la única distribución que "no tiene memoria", es decir:

$$P(X \geq x+h | X \geq x) = P(X \geq h), \quad x, h > 0$$

$$\Leftrightarrow X \sim \text{Exp}(\beta)$$

MODELO DE PROBABILIDAD EN \mathbb{R}^n

• $d=2$, \mathbb{R}^2

La distribución Normal en \mathbb{R}^2 es la distribución con función de densidad conjunta con parámetros $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1, \sigma_2 > 0$, $\rho \in (-1, 1)$

$$f_{(X,Y)}(x,y) := \frac{1}{2\pi(1-\rho^2)^{1/2} \cdot \sigma_1 \sigma_2} \cdot e^{\frac{-1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1 \sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right]}$$

PROPIEDADES: $\triangleright X$ e Y son Normales con:

$$\mathbb{E}(X) = \mu_1 \quad \mathbb{E}(Y) = \mu_2$$

$$1. V(X) = \sigma_1^2 \quad V(Y) = \sigma_2^2$$

$$2. \text{Cov}(X,Y) = \rho \cdot \sigma_1 \cdot \sigma_2 \iff \text{Corr}(X,Y) = \rho$$

$$\begin{cases} \Sigma = \begin{bmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix} \\ \Xi = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} \end{cases}$$

$$\begin{aligned} \triangleright \text{Si } \rho=0 &\Rightarrow f_{(X,Y)}(x,y) = \frac{1}{2\pi \sigma_1 \sigma_2} e^{-\frac{1}{2} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right]} = \\ &= f_X(x) \cdot f_Y(y) \end{aligned}$$


\triangleright Si X e Y son marginales de una Normal en \mathbb{R}^2 , entonces, X e Y son independientes \iff son incorreladas.

* TCL - TEOREMA CENTRAL DEL LÍMITE

Sean X_1, X_2, \dots, X_n variables aleatorias independientes e idénticamente distribuidas, $E(X_i) = \mu$, $V(X_i) = \sigma^2$ finitos.

Entonces:

$$\frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{\text{en distribución}} N(0;1)$$



Aplicaciones:

a) Si $n \geq 30$, $TCL \Rightarrow \frac{1}{n} \sum_{i=1}^n X_i \sim N(\mu, \frac{\sigma}{\sqrt{n}})$

b) $\sum_{i=1}^n X_i \sim N(n\mu; \sigma\sqrt{n})$ si $n \geq 30$.

* LGN - LEY DE LOS GRANDES NÚMEROS

Bajo las mismas hipótesis del TCL.

Entonces:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\text{en distribución}} \mu$$

