

ESTIMACIÓN DE DISTRIBUCIÓN DE PROBABILIDAD

ESTIMACIÓN DE PARÁMETROS

Notación:

- Individuo de interés: parámetros de distribución

$$\rightarrow f(x; \theta) = \begin{cases} \text{función de densidad cuando el parámetro es } \theta \\ \text{función de masa cuando el parámetro es } \theta \end{cases}$$

$$\rightarrow \Theta = \begin{matrix} \text{conjunto de parámetros posibles} \\ \text{espacio de parámetros} \end{matrix}$$

$$\rightarrow \text{si } \theta \in \Theta, \text{ el } \text{sop}_{\theta} = \{x: f(x; \theta) > 0\}$$

Ejemplo

(1) X es Bernoulli(p)

$$f(x; p) = \begin{cases} p, & \text{si } x=1 \\ 1-p, & \text{si } x=0 \end{cases}$$

si $x \neq 0, 1 \rightarrow f(x; p) = 0$

$$\Theta = [0, 1]$$

$$\text{sop}_p = \begin{cases} \{0, 1\} & \text{si } p \neq 0 \text{ y } p \neq 1 \\ 0 & \text{si } p = 0 \\ 1 & \text{si } p = 1 \end{cases}$$

(2) X es Exp(λ)

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

$$\Theta = (0, \infty)$$

$\lambda \in \Theta$

$$\text{sop}_{\lambda} = (0, \infty)$$

(3) X es unif($0, a$)

$$f(x; a) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1/a & \text{si } x \in (0, a) \\ 0 & \text{si } x \geq a \end{cases}$$

$$\Theta = (0, \infty)$$

$a \in \Theta$

$$\text{sop}_a = (0, a)$$

$$4) \quad \Theta = \{0, 1\} \rightarrow f(x; 0) = \begin{cases} 1 & \text{si } x \in (0, 1) \\ 0 & \text{en el resto} \end{cases}$$

$$\rightarrow f(x; 1) = \begin{cases} \frac{1}{2\sqrt{x}} & \text{si } x \in (0, 1) \\ 0 & \text{en el resto} \end{cases}$$

$$\text{sup}_{\Theta} = (0, 1)$$

Más notación

$\mathbb{E}_{\theta}(X)$ = esperanza de X suponiendo parámetro θ .
 // si es continua

$$\int_{\text{sup}_{\theta}} x f(x; \theta) dx \Rightarrow \text{función de } \theta, \quad \theta \in \Theta$$

$$\rightarrow \sum_{x \in \text{sup}_{\theta}} x f(x; \theta)$$

$V_{\theta}(X)$ = varianza de X suponiendo parámetro θ

$P_{\theta}(X \in A)$ = probabilidad con parámetro θ

funciones de $\theta \in \Theta$

Ejemplo:

(1) X es $\text{Ber}(p)$

$$p \in (0, 1) \rightarrow \mathbb{E}_p(X) = p$$

(2) X es $\text{Exp}(\lambda)$

$$\lambda > 0 \rightarrow \mathbb{E}_{\lambda}(X) = \frac{1}{\lambda}$$

(3) X es $\text{unif}(0, a)$

$$a \in (0, \infty) \rightarrow \mathbb{E}_a(X) = \frac{a}{2}$$

(4) $\Theta = \{0, 1\}$

$$\theta \in \{0, 1\} \rightarrow \mathbb{E}_\theta(X) = \begin{cases} 1/2 & \text{si } \theta = 0 \\ \int_0^1 x \frac{1}{2\sqrt{x}} dx = \mathbb{E}_1(X) = 1/3 & \text{si } \theta = 1. \end{cases}$$

Más notación: estimaciones y estimadores

$X \quad f(x; \theta) \quad \Theta$

muestra x_1, \dots, x_n

↓ transformación con $h(x_1, \dots, x_n) \quad h: \mathbb{R}^n \rightarrow \mathbb{R}$

$\hat{\theta}$ = estimación de θ

$h(x_1, \dots, x_n)$ → clones indep. = todas las posibles estimaciones de θ

↓ variable aleatoria
ESTADÍSTICO ESTIMADOR ó ESTIMADOR

MÉTODOS DE CONSTRUCCIÓN DE ESTIMADORES → Momentos
→ Máxima verosimilitud

MÉTODO DE MOMENTOS

$X \quad f(x; \theta) \quad \Theta$

x_1, \dots, x_n una muestra

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

dato

debe parecerse a

→ función de θ
 $\mathbb{E}_\theta(X) \leftarrow \theta \in \Theta$
↑ desconocido

↓ método

$$\bar{x} \in \mathbb{E}_\theta(X)$$

ECUACIÓN CON INCÓGNITA θ

Ejemplos

(1) X es uniforme(a)

x_1, \dots, x_n

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

método de momentos

↓
 $\bar{x} = \mathbb{E}_a(X) = \frac{a}{2} \Rightarrow \hat{a} = 2\bar{x}$

muestra estimación

(*) ESTIMADOR POR MOMENTOS DE a :

$$M_a = 2\bar{X}$$

(2) $\exp(\lambda)$

x_1, \dots, x_n muestra

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

método de momentos

$$\bar{x} = E_{\lambda}(X) = \frac{1}{\lambda} \Rightarrow$$

nuestra estimación

$$\hat{\lambda} = \frac{1}{\bar{x}}$$

* ESTIMADOR POR MOMENTOS DE λ :

$$M_{\lambda} = \frac{1}{\bar{x}}$$

(3) X es $\text{Ber}(p)$

x_1, \dots, x_n muestra

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

método de momentos

$$\bar{x} = E_p(X) = p \Rightarrow$$

nuestra muestra

$$\hat{p} = \bar{x}$$

* ESTIMADOR POR MOMENTOS DE p :

$$M_p = \bar{x}$$

(4) (Mal ejemplo)

$$X \quad f(x; \alpha) = \begin{cases} (\alpha+1)x^{\alpha} & , \quad x \in (0, 1) \\ 0 & \text{en el resto} \end{cases}$$

$$\alpha \in (0, \infty) = \mathbb{H}$$


$$E_{\alpha}(X) = \int_0^1 x(\alpha+1)x^{\alpha} dx = \frac{\alpha+1}{\alpha+2}$$

$$\bar{x} = \frac{\alpha+1}{\alpha+2} \Rightarrow (\alpha+2)\bar{x} = \alpha+1 \Rightarrow \alpha\bar{x} + 2\bar{x} = \alpha+1 \Rightarrow \alpha = \frac{1-2\bar{x}}{\bar{x}-1}$$

$$\Rightarrow \text{estimación de } \alpha = \hat{\alpha} = \frac{1-2\bar{x}}{\bar{x}-1}$$

si $\bar{x} < 1/2 \Rightarrow \hat{\alpha} < 0$ y recordemos que $\alpha \in (0, \infty)$

el método de momentos no funcionaría solo puedo despejar si $1/2 < \bar{x} < 1$




Ejemplo / ejercicio

$$X \quad f(x; \theta) = \begin{cases} \frac{1}{\theta} \left(1 - \frac{|x|}{\theta}\right) & \text{si } |x| < \theta \\ 0 & \text{si } |x| \geq \theta \end{cases}$$

$$\theta \in \Theta = (0, \infty)$$

$$\text{sup}_{\theta} = (-\theta, \theta)$$



datos: x_1, \dots, x_n

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

$\bar{x} = E_{\theta}(X) = 0$ para cualquier $\theta \Rightarrow$ no nos sirve para estimar el momento no centrado de grado 1.

Probamos con el momento de grado 2: $\bar{x}^2 = E_{\theta}(X^2)$

$$\bar{x}^2 = \frac{x_1^2 + \dots + x_n^2}{n}$$

$$E_{\theta}(X^2) = \int_{-\theta}^{\theta} x^2 f(x; \theta) dx = \int_{-\theta}^{\theta} x^2 \cdot \frac{1}{\theta} \left(1 - \frac{|x|}{\theta}\right) dx = 2 \int_0^{\theta} x^2 \cdot \frac{1}{\theta} \left(1 - \frac{x}{\theta}\right) dx$$

$$= 2 \int_0^1 y^2 \theta^2 \cdot \frac{1}{\theta} (1 - y) \theta dy = 2\theta^2 \int_0^1 y^2 - y^3 dy = \frac{\theta^2}{6}$$

cambio $y = \frac{x}{\theta} \rightarrow x = y\theta$

$$dy = \frac{1}{\theta} dx \rightarrow dx = \theta dy$$

$$\Rightarrow \bar{x}^2 = \frac{\theta^2}{6} \Rightarrow \boxed{\hat{\theta} = \sqrt{6 \bar{x}^2}} \text{ estimación}$$

En general:

$$M_{\theta} = \sqrt{6 \frac{x_1^2 + \dots + x_n^2}{n}} \rightarrow \text{clones de } \bar{X}$$

\downarrow
estimador

Ejemplo: dos parámetros por momentos

X es $N(\mu, \sigma^2)$

x_1, \dots, x_n

$$E_{(\mu, \sigma^2)}(X) = \mu$$

$$E_{(\mu, \sigma^2)}(X^2) = \sigma^2 + \mu^2$$

Sistema de dos ecuaciones:

$$\bar{x} = E_{(\mu, \sigma^2)}(X) = \mu \Rightarrow \boxed{\hat{\mu} = \bar{x}}$$

$$\bar{x^2} = E_{(\mu, \sigma^2)}(X^2) = \sigma^2 + \mu^2 \Rightarrow \hat{\sigma}^2 = \bar{x^2} - \hat{\mu}^2 = \bar{x^2} - \bar{x}^2 = V_x$$

$$\boxed{\hat{\sigma}^2 = V_x}$$

MÉTODO DE MÁXIMA VEROSIMILITUD

X discreta finita

$\text{sop}_\theta = \text{fijo finito}$

↓ dado θ
 $f(x; \theta) = \text{probabilidad de obtener el valor } x.$

Dado x : $f(x; \theta)$ VEROSIMILITUD DE θ .

Dada la muestra x_1, \dots, x_n , llamamos VEROSIMILITUD de θ dada la muestra:

$$\text{VERO}(\theta; x_1, \dots, x_n) = \prod_{j=1}^n f(x_j; \theta)$$

→ función de verosimilitud está definida en Θ .

Ejemplo: X es $\text{Ber}(p)$ x_1, \dots, x_n (son 0's y 1's)

$$\Theta = [0, 1]$$


$$f(x; p) = \begin{cases} p, & x=1 \\ (1-p), & x=0 \end{cases}$$

$$n^{\circ} \{x_j = 1\} = \sum_{j=1}^n x_j = n\bar{x}$$


$$\text{VERO}(p; x_1, \dots, x_n) = \prod_{j=1}^n f(x_j; p) = p^{n^{\circ} \{x_j=1\}} (1-p)^{n^{\circ} \{x_j=0\}} = p^{n\bar{x}} (1-p)^{n(1-\bar{x})}$$

gráfica de $\text{VERO}(p; x_1, \dots, x_n)$


$\text{VERO}(p)$



si $0 < \bar{x} < 1$



si $\bar{x} = 1$



si $\bar{x} = 0$

Ejemplo: X es $\text{Exp}(\lambda)$


x_1, \dots, x_n

$x_1, \dots, x_n > 0$

$\lambda \in \Theta = (0, \infty)$

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & , x > 0 \\ 0 & , x \leq 0 \end{cases}$$

$$\text{VERO}(\lambda; x_1, \dots, x_n) = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-\lambda n \bar{x}}$$



Ejemplo: X es uniforme $[0, a]$

$a \in (0, \infty)$

$$f(x; a) = \begin{cases} 1/a & , \text{ si } 0 \leq x \leq a \\ 0 & , \text{ en el resto} \end{cases}$$


muestra $x_1, \dots, x_n \rightarrow$ números positivos

$$\text{VERO}(a; x_1, \dots, x_n) = \prod_{j=1}^n f(x_j; a) = \begin{cases} (1/a)^n & \text{ si } x_j \leq a \text{ para } 1 \leq j \leq n \\ 0 & , \text{ en caso contrario} \end{cases}$$

↑
para clave

$$= \begin{cases} (1/a)^n & \text{ si } a \geq \max(x_1, \dots, x_n) \\ 0 & \text{ si } a < \max(x_1, \dots, x_n) \end{cases}$$

↑
dato



Estimador de MÁXIMA VEROSIMILITUD

$$X \quad f(x; \theta) \quad x_1, \dots, x_n$$

$$\theta \in \Theta \longrightarrow \text{VERO}(\theta; x_1, \dots, x_n)$$

Si esta función tiene un ÚNICO MÁXIMO GLOBAL (en todo Θ) en el punto $\hat{\theta}$, a $\hat{\theta}$ lo llamamos ESTIMACIÓN DE MÁXIMA VEROSIMILITUD de θ dada x_1, \dots, x_n .

Ejemplos

$$(1) \text{ Ber}(p) \quad \blacktriangleright 0 < \bar{x} < 1$$

$$\text{VERO}(p) = p^{n\bar{x}} (1-p)^{n(1-\bar{x})}$$

$$\left. \begin{array}{l} \text{VERO}(0) = 0 \\ \text{VERO}(1) = 0 \\ \text{VERO} \geq 0 \end{array} \right\} \begin{array}{l} \text{hay máximo global. Vamos a comprobar que hay} \\ \text{un único punto crítico.} \end{array}$$

continua y derivable

Simplificación habitual:


$$\log \text{VERO}(p) = \ln \text{VERO}(p) \quad \text{puntos críticos de } \log \text{VERO}$$

$$\longrightarrow n\bar{x} \ln p + n(1-\bar{x}) \ln(1-p)$$

$$0 = n\bar{x} \frac{1}{p} - \frac{n(1-\bar{x})}{1-p} \Rightarrow \boxed{\hat{p} = \bar{x}} \text{ estimación por MÁXIMA VEROSIMILITUD}$$

$$\blacktriangleright \bar{x} = 1$$

$$\text{VERO}(p) = p^n$$




Alcanza máximo en $p=1$

$$\Rightarrow \boxed{\hat{p} = 1}$$

$$\blacktriangleright \bar{x} = 0$$

$$\text{VERO} = (1-p)^n$$



Alcanza máximo en $p=0$


$$\Rightarrow \boxed{\hat{p} = 0}$$

$$(2) \quad X \sim \text{Exp}(x) \quad x_1, \dots, x_n$$

$$\text{VERO}(\lambda) = \lambda^n e^{-\lambda n \bar{x}}$$


$$\log \text{VERO}(\lambda) = n \log(\lambda) - \lambda n \bar{x}$$

$$\frac{d}{d\lambda} \log \text{VERO}(\lambda) = \frac{n}{\lambda} - n \bar{x} \quad ; \quad \frac{n}{\lambda} - n \bar{x} = 0 \Rightarrow \boxed{\bar{\lambda} = 1/\bar{x}}$$



$$(3) \quad \bar{X} \sim \text{Unif}[0, a] \quad x_1, \dots, x_n > 0$$

$$\Rightarrow \boxed{\hat{a} = \max(x_1, \dots, x_n)}$$



estimación por MÁXIMA VEROSIMILITUD de a dado x_1, \dots, x_n .

REGLA GENERAL: ESTIMADOR MV de a

$$\text{EMV}_a = \max(\underbrace{x_1, \dots, x_n}_{\text{clones de } X}) \leftarrow \text{aquí están todas las posibles estimaciones}$$

↓
variable aleatoria

en $X \sim \text{Unif}[0, a]$

NOTA:

$$\begin{matrix} M_a = 2\bar{X} \\ \uparrow \\ \text{momentos} \end{matrix}$$

$$\text{EMV}_p = \bar{X} = M_p \quad \text{en} \quad X \sim \text{Ber}(p)$$

$$\text{EMV}_\lambda = 1/\bar{X} = M_\lambda \quad \text{en} \quad X \sim \text{Exp}(\lambda)$$

PROPIEDADES Y COMPARACIONES DE ESTIMADORES

$$X \quad f(x; \theta) \quad \theta \in \Theta$$

$$\text{Estimador} \longrightarrow T = h(X_1, \dots, X_n) \quad h: \mathbb{R}^n \longrightarrow \mathbb{R}$$

↑ recoge todas las posibles estimaciones

Decimos que T es ESTIMADOR INSESGADO de θ si se cumple

$$\mathbb{E}_{\theta}(T) = \theta \quad \text{para todo } \theta \in \Theta$$

Un estimador insesgado en media no se equivoca.

Ejemplo

$$(1) \quad X \sim \text{Ber}(p) \quad T = \bar{X}$$

$$\mathbb{E}_p(\bar{X}) = \mathbb{E}_p(X) = p$$

$$\mathbb{E}_p(T) \quad T \text{ es insesgado}$$

(2) Supongamos que el parámetro θ es la esperanza de X

$$\mathbb{E}_{\theta}(X) = \theta$$

$$\text{estimador de } \theta: T = \bar{X}$$

$$\mathbb{E}_{\theta}(T) = \mathbb{E}_{\theta}(\bar{X}) \underset{\substack{\uparrow \\ \text{en general}}}{=} \mathbb{E}_{\theta}(X) = \theta$$

\Rightarrow La media muestral es estimador insesgado de $\theta = \mathbb{E}(X)$.

Si T no es insesgado decimos que es SESGADO.

$$\text{sesgo}(T) = \mathbb{E}_{\theta}(T) - \theta$$

$$(3) X \sim \text{Unif}[0, a]$$

$$T_1 = 2X$$

$$T_2 = \max(x_1, \dots, x_n)$$

$$\mathbb{E}_a(T_1) = \mathbb{E}_a(2\bar{X}) = 2\mathbb{E}_a(\bar{X}) = 2\mathbb{E}_a(X) = 2 \cdot \frac{a}{2} = a$$

$$\mathbb{E}_a(T_2) = \mathbb{E}_a(\max(x_1, \dots, x_n)) \Rightarrow$$

$$F_{T_2}(x) = \left(\frac{x}{a}\right)^n \quad 0 \leq x \leq a$$

$$f_{T_2}(x) = \frac{nx^{n-1}}{a^n} \quad 0 \leq x \leq a$$

$$\Rightarrow \mathbb{E}_a(\max(x_1, \dots, x_n)) = \int_0^a x \frac{nx^{n-1}}{a^n} dx = \frac{n}{n+1} a$$

$$\text{sesgo}(T_2) = \frac{n}{n+1} a - a = -\frac{a}{n+1}$$

T_2 es sesgado, pero asintóticamente insesgado

Observación: $T_3 = \frac{n+1}{n} T_2$ es insesgado. (de hecho, es el mejor estimador)

$$(4) X \sim \text{Exp}(\lambda)$$

$$T = 1/\bar{X} \begin{cases} \text{momentos} \\ \text{max VERO} \end{cases}$$

$$\mathbb{E}_\lambda(T) = \mathbb{E}_\lambda(1/\bar{X}) > \frac{1}{\mathbb{E}(X)} = \lambda$$

NOTA: Z variable aleatoria
 $Z > 0$ no constante

$$1 < \mathbb{E}(Z) \cdot \mathbb{E}(1/Z)$$

T es siempre sesgado (sobreestimación)

demo de nota:

$$1 = \mathbb{E}(1) = \mathbb{E}\left(Z \cdot \frac{1}{Z}\right) = \mathbb{E}\left(\sqrt{Z} \cdot \frac{1}{\sqrt{Z}}\right) \leq \mathbb{E}(Z)^{1/2} \mathbb{E}(1/Z)^{1/2}$$

Igualdad solo si Z constante.

VARIANZA DE UN ESTIMADOR

Eficiencia

- Varianza de estimador $V_{\theta}(T)$
- T es insesgado y apelo a Chebyshev

$$P(|T - \theta| \geq \varepsilon) \leq \frac{V_{\theta}(T)}{\varepsilon^2}$$

Si $V_{\theta}(T)$ pequeño, T en general se equivoca poco.

- T_1, T_2 son estimadores insesgados decimos que T_1 es más EFICIENTE que T_2 si:

$$V_{\theta}(T_1) < V_{\theta}(T_2) \text{ para todo } \theta \in \Theta$$

Ejemplo: $X \sim \text{Unif}[0, a]$ $f(x; a) = \begin{cases} 1/a, & \text{si } x \in [0, a] \\ 0, & \text{si no} \end{cases}$

$$T_1 = 2\bar{X}$$

$$T_2 = \frac{n+1}{n} \hat{T}_2$$

$$\mathbb{E}_a(T_1) = a$$

$$\mathbb{E}_a(T_2) = a$$

Para comparar T_1, T_2
¿ $V_a(T_1), V_a(T_2)$?

$$V_a(T_1) = 4V_a(\bar{X}) = \frac{4V_a(X)}{n} = \frac{4}{n} \cdot \frac{a^2}{12}$$

↖ cuenta integrando la función de densidad

$$V_a(\hat{T}_2); \quad F_{\hat{T}_2}(x) = \left(\frac{x}{a}\right)^n \rightarrow f_{\hat{T}_2}(x) = n \frac{x^{n-1}}{a^n}$$

$$V_a(\hat{T}_2) = \int_0^a x^2 \frac{nx^{n-1}}{a^n} dx - \mathbb{E}(\hat{T}_2)^2 = \text{res}$$

$\underbrace{\int_0^a x^2 \frac{nx^{n-1}}{a^n} dx}_{\mathbb{E}(\hat{T}_2^2)}$

$$V_a(T_2) = \left(\frac{n+1}{n}\right)^2 V_a(\hat{T}_2) = \frac{a^2}{n(n+1)}$$

$\Rightarrow T_2$ es más eficiente que T_1 .

Ejemplo: $X \sim \text{Exp}(\lambda)$

REWERDO:

$$\begin{aligned} E_{\lambda}(X) &= 1/\lambda \\ V_{\lambda}(X) &= 1/\lambda^2 \\ \min(X_1, \dots, X_n) &\sim \text{Exp}(n\lambda) \end{aligned}$$

Estimadores de $1/\lambda$:

$$T_1 = \bar{X} \quad E(T_1) = 1/\lambda$$

$$T_2 = n \min(X_1, \dots, X_n) \quad E(T_2) = 1/\lambda$$

$$V(T_1) = V(\bar{X}) = \frac{V(X)}{n} = \frac{1}{n\lambda^2}$$

$$V(T_2) = n^2 V(\min(X_1, \dots, X_n)) = \frac{n^2}{n^2} \cdot \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

T_1 es más eficiente que T_2 .

ESTIMADORES

$X \quad f(x; \theta) \quad \theta \in \Theta$

X_1, \dots, X_n

- Límites de "calidad" de estimadores
- Lema de Cramer - RAO

VARIABLE DE INFORMACIÓN } (*)
ANTIDAD DE INFORMACIÓN

(H) es un intervalo (a,b)

$$f(x; \theta)$$

$$\frac{\partial}{\partial \theta} f(x; \theta) \xrightarrow{\text{notación}} \partial_{\theta} f(x; \theta)$$

Formamos una transformación de X : $Y :=$ variable de información de X

$$Y = \partial_{\theta} \ln f(X; \theta) = \frac{\partial_{\theta} f(X; \theta)}{f(X; \theta)}$$

Cantidad de información de $X := V_{\theta}(Y)$, y se denota como: $I_X(\theta)$

Ejemplos:

(1) X es $N(\overset{\text{fijo}}{\mu_0}, \sigma^2)$ parámetro $\theta = \sigma^2$
 $(H) = (0, \infty)$

$$f(x; \theta) = \frac{1}{\sqrt{2\pi} \sqrt{\theta}} \cdot \exp\left(-\frac{1}{2} \cdot \frac{(x - \mu_0)^2}{\theta}\right)$$

$$\partial_{\theta} \ln f(x; \theta) = -\frac{1}{2} \cdot \frac{1}{\theta} + \frac{1}{2} \cdot \frac{(x - \mu_0)^2}{\theta^2} = \frac{1}{2} \left(\frac{(x - \mu_0)^2}{\theta^2} - \frac{1}{\theta} \right)$$

$$\Rightarrow Y = \frac{1}{2} \cdot \frac{(X - \mu_0)^2}{\theta^2} - \frac{1}{2\theta}$$

$$\mathbb{E}_{\theta}(Y) = \mathbb{E}_{\theta} \left(\frac{1}{2} \cdot \frac{(X - \mu_0)^2}{\theta^2} - \frac{1}{2\theta} \right) = \frac{1}{2} \mathbb{E}_{\theta} \left(\frac{(X - \mu_0)^2}{\theta^2} - \frac{1}{\theta} \right) = \frac{1}{2\theta^2} \underbrace{\mathbb{E}_{\theta}((X - \mu_0)^2 - \theta)}_{V_{\theta}(X) - \theta} \Rightarrow$$

$$\Rightarrow \mathbb{E}_{\theta}(Y) = 0$$

$$\begin{aligned} I_X(\theta) = V_{\theta}(Y) &= \mathbb{E}_{\theta}(Y^2) - \cancel{\mathbb{E}_{\theta}(Y)^2}^0 = \mathbb{E}_{\theta}(Y^2) = \frac{1}{4} \cdot \frac{1}{\theta^4} \mathbb{E}_{\theta}(((X - \mu_0)^2 - \theta)^2) = \\ &= \frac{1}{4} \cdot \frac{1}{\theta^4} \cdot \mathbb{E}_{\theta} \left(\underbrace{(X - \mu_0)^4}_{-2\theta^2} - 2 \underbrace{(X - \mu_0)^2}_{\theta} \cdot \underbrace{\theta}_{\theta^2} + \theta^2 \right) = \frac{1}{4\theta^4} \cdot \left[\mathbb{E}_{\theta}((X - \mu_0)^4) - 2\theta^2 + \theta^2 \right] = \end{aligned}$$

NOTA: RECORDATORIO
 $Z \sim N(0,1)$

$$\mathbb{E}(Z) = 0 \quad \mathbb{E}(Z^2) = 1 \quad \mathbb{E}(Z^3) = 0 \quad \mathbb{E}(Z^4) = 3$$

Con la nota: $\mathbb{E}_\theta \left(\left(\frac{X - \mu_0}{\sqrt{\theta}} \right)^4 \right) = 3 \Rightarrow \mathbb{E}_\theta((X - \mu_0)^4) = 3\theta^2$

$$\Rightarrow I_X(\theta) = V_\theta(Y) = \frac{1}{4\theta^4} \cdot (3\theta^2 - 2\theta^2 + \theta^2) = \frac{1}{2\theta^2}$$

alternativa: $V_\theta(Y) = \frac{1}{4\theta^4} \cdot V_\theta((X - \mu_0)^2) = \frac{1}{4\theta^2} \cdot V_\theta(\chi_1^2) = \frac{2}{4\theta^2} = \frac{1}{2\theta^2}$

(2) X es $\text{Exp}(\)$ $\theta = 1/\lambda$

$$f(x; \theta) = \frac{1}{\theta} \cdot \exp\left(-\frac{1}{\theta}x\right)$$

$$\partial_\theta \ln f(x; \theta) = \partial_\theta \left(-\ln \theta - \frac{1}{\theta}x \right) = -\frac{1}{\theta} + \frac{x}{\theta^2} \Rightarrow Y = \frac{-1}{\theta} + \frac{X}{\theta^2} \Rightarrow$$

$$\Rightarrow Y = \frac{X - \theta}{\theta^2}$$

NOTA:

$$\mathbb{E}(\text{exp}) = \frac{1}{\lambda}$$

$$V(\text{exp}) = \frac{1}{\lambda^2}$$

$$\mathbb{E}_\theta(X) = \theta \quad ; \quad \mathbb{E}_\theta(Y) = \mathbb{E}\left(\frac{X - \theta}{\theta^2}\right) = 0$$

$$V_\theta(Y) = \frac{1}{\theta^4} \cdot \theta^2 = \frac{1}{\theta^2} = \text{cantidad de informaci3n} = I_X(\theta)$$

(3) X es $\text{Ber}(p)$ $p \in (0,1) = \textcircled{H}$

$$f(x; p) = p^x \cdot (1-p)^{(1-x)} = \begin{cases} p, & x=1 \\ 1-p, & x=0 \end{cases}$$

$$\ln f(x; p) = x \ln p + (1-x) \ln(1-p)$$

$$\partial_p \ln f(x; p) = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x-p}{p(1-p)} \Rightarrow Y = \frac{X-p}{p(1-p)}$$

$$\mathbb{E}_p(Y) = 0$$

$$V_p(X) = p(1-p)$$

$$V_p(Y) = \frac{1}{(p(1-p))^2} V_p(X-p) = \frac{1}{p(1-p)} = I_X(p)$$

NOTA: valores probabilidad

$$Y = \begin{cases} 1/p \rightarrow p \\ -1/(1-p) \rightarrow 1-p \end{cases}$$

$$\Rightarrow \mathbb{E}(Y) = 1/p \cdot p + (1-p) \cdot \frac{-1}{1-p} = 0$$

-EMA (Condiciones especiales) (A)

hipótesis $\left[\begin{array}{l} f(x; \theta) \quad \theta \in \Theta = (a, b) \quad \text{sop}_{\theta} = \{a_1, \dots, a_m\} \\ \downarrow \text{variable finita} \quad \uparrow \\ \theta \longrightarrow f(x; \theta) \text{ derivable} \end{array} \right.$

Entonces:

$$E_{\theta}(Y) = 0 \quad \text{para todo } \theta$$

(por tanto, obtenemos:)

$$I_X(\theta) = E_\theta(Y^2)$$

demonstración

$$\sum_{j=1}^M f(a_j, \theta) = 1 \quad \text{para todo } \theta \in \Theta$$

derivamos respecto de θ

$$\sum_{j=1}^M \partial_{\theta} f(a_j, \theta) = 0 \quad \text{para todo } \theta \in \mathbb{R}$$

$$\sum_{j=1}^M \underbrace{\frac{\partial_\theta f(a_j, \theta)}{f(a_j, \theta)}}_{\text{valores de } Y} \cdot \underbrace{f(a_j, \theta)}_{\text{probab.}} = 0 = \mathbb{E}_\theta(Y) = 0 \quad \text{para todo } \theta \in \Theta$$

VARIABLE DE INFORMACIÓN de (x_1, \dots, x_n)

$$Z_n = \sum \partial_\theta \ln f(x_j; \theta) \quad \left(\begin{array}{l} \text{suma de variables de} \\ \text{información de } x_1, \dots, x_n \end{array} \right)$$

LEMA (B) (Corolario del lema (A))

$$\Theta = (a, b) \quad \text{sop}_{\theta} = \{a_1, \dots, a_m\} \quad \text{para todo } \theta \in \Theta$$

$$\theta \longrightarrow f(x; \theta) \text{ derivable}$$

Para la variable de información de la muestra

$$\mathbb{E}_\theta(Z_n) = 0 \quad \text{y} \quad V_\theta(Z_n) = n I_X(\theta) = n V_\theta(Y) \quad \forall \theta \in \Theta$$

LEMA (C) (Lema de CRAMER-RAO)

$$\Theta = (a, b) \quad \sup_{\theta \in \Theta} = \{a_1, \dots, a_m\} \quad \forall \theta \in \Theta$$

$$\theta \longrightarrow f(a_j; \theta) \text{ es derivable con } 1 \leq j \leq M$$

Sea T un estadístico INSESGADO de \bar{X} , entonces:

$$V_{\theta}(T) \geq \frac{1}{n I_X(\theta)} \quad \forall \theta \in \Theta$$

cota de CRAMER-RAO

demonstración

T insesgado

T insesgado

Para todo $\theta \in \Theta$

$T = h(X_1, \dots, X_n)$

$h: \mathbb{R}^n \rightarrow \mathbb{R}$

valores de T

probabil.

$\theta = \mathbb{E}_\theta(T) = \sum h(x_1, \dots, x_n) \cdot f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta)$

$(x_1, \dots, x_n) \in \text{sop}_\theta^n \rightarrow = \sum_{x_n \in \text{sop}_\theta} \sum_{x_{n-1} \in \text{sop}_\theta} \dots \sum_{x_1 \in \text{sop}_\theta}$

un total de M^n sumandos

derivamos respecto de θ :

$$1 = \sum h(x_1, \dots, x_n) \cdot \left[\frac{\partial f(x_1; \theta) \cdot f(x_2; \theta) \cdot \dots \cdot f(x_n; \theta)}{f(x_1; \theta)} + \dots + \frac{\partial f(x_n; \theta)}{f(x_n; \theta)} \right]$$

$$\Rightarrow 1 = \sum_{\text{valores de } T} \underbrace{h(x_1, \dots, x_n)}_{\text{valores de } Z_n} \underbrace{\left(\sum_{j=1}^n \alpha_j \ln f(x_j; \theta) \right)}_{\text{prob.}} f_1(x_1; \theta) \dots f_n(x_n; \theta) \Rightarrow 1 = \mathbb{E}_\theta(T \cdot Z_n) \quad \forall \theta \in \Theta$$

$$1 = \mathbb{E}_\theta(T Z_n) - \mathbb{E}(T) \cdot \mathbb{E}(Z_n) = \text{cov}_\theta(T, Z_n)$$

Finalmente, $1 = |\text{cov}_\theta(T, Z_n)| \leq \sqrt{V_\theta(T)} \sqrt{V_\theta(Z_n)} \Rightarrow V_\theta(T) \geq \frac{1}{n I_n(\theta)}$

(1) Ber(p)

$$\frac{1}{n I_X(p)} = \frac{p(1-p)}{n} \quad \left. \vphantom{\frac{1}{n I_X(p)}} \right\} \begin{array}{l} \text{Todo estimador de } p \\ \text{tiene varianza} \end{array} \geq \frac{p(1-p)}{n} \quad \begin{array}{l} \nearrow \text{insesgado} \\ \text{de } p \end{array}$$

Ahora $T = \bar{X}$ $E_p(\bar{X}) = E_p(X) = p$ insesgado

$$V_p(\bar{X}) = \frac{1}{n} V_p(X) = \frac{1}{n} (E_p(\underbrace{X^2}_{X^2}) - E_p(X)^2) = \frac{1}{n} (p - p^2) = \frac{1}{n} p(1-p)$$

\bar{X} es un estimador más eficiente. (puede no ser el único)

(2) $X \sim N(\mu_0, \sigma^2)$ $\xrightarrow{\theta = \sigma^2}$
 \uparrow dato conocido

$$I_X(\theta) = \frac{1}{2\theta^2} \quad \Theta = (0, \infty)$$

En general: variable U

$$E(\bar{U}) = E(U) \quad ; \quad V(\bar{U}) = \frac{V(U)}{n}$$

\nearrow insesgados
 $E(S^2) = V(U)$

Tomamos $T = S^2$ $E_\theta(S^2) = \theta = \sigma^2$

¿Es más eficiente? ¿ $V_\theta(S^2)$?

✓ Fisher-Cochran (variables normales)

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2 \quad ; \quad V(\chi_{n-1}^2) = 2(n-1)$$

$$V_\theta(S^2) = \frac{2(n-1)\theta^2}{(n-1)^2} = \frac{2\theta^2}{n-1} > \underbrace{\frac{2\theta^2}{n}}_{\text{cota de Cramer-Rao}} = \frac{1}{n I_X(\theta)}$$

Ejercicio X $f(x; \alpha) = \begin{cases} \alpha x^{\alpha-1} & , \text{ si } x \in (0,1) \\ 0 & , \text{ si no} \end{cases}$ $\alpha \in \mathbb{H} = (0, \infty)$

- 1) Preliminar, calcular $\mathbb{E}_\alpha((\log X)^K)$
- 2) Cantidad de información y cota de Cramer-Rao
- 3) Sea $T = \frac{1}{n} \sum_{i=1}^n \ln x_i$. Comprobar que es más eficiente.

$$1) \mathbb{E}_\alpha((\log X)^K) = \int_0^1 (\ln x)^K \alpha x^{\alpha-1} dx \stackrel{\substack{y = \ln \frac{1}{x} \rightarrow x = e^{-y} \\ \text{cambio variable}}}{=} \alpha \int_0^\infty (-1)^K y^K e^{-y(\alpha-1)} dy =$$

$$= \frac{\alpha (-1)^K}{(\alpha-1)^{K+1}} \underbrace{\int_0^\infty t^K \cdot e^{-t} dt}_{\Gamma(K+1) = K!} = \frac{\alpha (-1)^K}{(\alpha-1)^{K+1}} K!$$

(2) Variable de información

$$Y = \frac{\partial}{\partial \theta} \ln f(X; \alpha) = \frac{\partial}{\partial \theta} [\ln(\alpha x^{\alpha-1})] = \frac{\partial}{\partial \theta} [\ln \alpha + (\alpha-1) \ln x]$$

$$= \frac{1}{\alpha} + \ln x = \frac{\alpha \ln x + 1}{\alpha}$$

Cantidad de información

$$I_X(\alpha) = V_\alpha(Y) = V_\alpha(\ln x) = \mathbb{E}_\alpha((\ln x)^2) - \mathbb{E}_\alpha(\ln x)^2$$

VARIABLE DE INFORMACIÓN PARA X CONTINUA

$\theta \in \Theta = (a, b)$
 $\text{sop} = \text{sop}_\theta \leftarrow \begin{matrix} \text{fijo} \\ \text{(no dep. de } \theta \text{)} \end{matrix}$

Queremos replicar la demostración de $\mathbb{E}_\theta(Y) = 0$

$\theta \rightarrow f(x; \theta)$ derivat

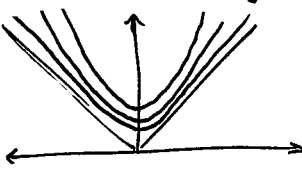
$\int_{\text{sop}} f(x; \theta) dx = 1 \quad \forall \theta \in \Theta$

$\theta \rightarrow \int_{\text{sop}} f(x; \theta) dx$

no depende de θ

En general, $\frac{d}{d\theta} \int \neq \int \frac{\partial}{\partial \theta}$ como por ejemplo:

sucesión de curvas derivables que tienden a una no derivable



Derivadas bajo signo integral (Feynman)

Ejemplo: $\int_0^1 \frac{x^t - 1}{\ln x} dx$

truco: $I(t) = \int_0^1 \frac{x^t - 1}{\ln x} dx$

$x^t = e^{t \ln x}$

$I(0) = 0$; $I'(t) = \int_0^1 \frac{\ln x e^{t \ln x}}{\ln x} dx = \int_0^1 x^t dx = \frac{1}{t+1}$

$\Rightarrow I(t) = \int \frac{1}{t+1} dt = \ln(t+1) + C$ y $C=0$ porque $I(0)=0$

$\Rightarrow I(1) = \frac{1}{12}$


Aproximar por 2ª derivada

$g(t) - g(0) = \int_0^t g'(u) du$

$g'(u) - g'(0) = \int_0^u g''(s) ds$

$g(t) = g(0) + g'(0)t + \int_0^t \left(\int_0^u g''(s) ds \right) du$

$= \int_0^t g''(s) (t-s) ds$



Idea

Si fuera:

$\frac{d}{d\theta} \int_{\text{sop}} f(x; \theta) dx = \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx$

entonces

$0 = \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx =$

$= \int_{\text{sop}} \frac{\partial}{\partial \theta} \ln f(x; \theta) f(x; \theta) dx = \mathbb{E}_\theta(Y)$

sop valores prob.

y ya estaría

LEMA A
para continuas

$$|g(t) - g(0) - g'(0)t| \leq \max_{0 \leq s \leq t} |g''(s)| \cdot \frac{t^2}{2}$$

Más general:

$$|g(\theta + \delta) - g(\theta) - g'(\theta)\delta| \leq \left(\max_{\theta \leq \psi \leq \theta + \delta} |g''(\psi)| \right) \cdot \frac{\delta^2}{2}$$

Aplicamos a $f(x; \theta)$:

$$|f(x; \theta + \delta) - f(x; \theta) - \frac{\partial f}{\partial \theta}(x; \theta) \delta| \leq \overbrace{\left(\max_{\theta \leq \psi \leq \theta + \delta} \left| \frac{\partial^2 f}{\partial \theta^2}(x; \psi) \right| \right)}^{(*)} \cdot \frac{\delta^2}{2}$$

$$x \in \text{sop} \quad [\theta, \theta + \delta] \subset \Theta$$

$$\left| \underbrace{\int_{\text{sop}} f(x; \theta + \delta) dx}_{=0} - \underbrace{\int_{\text{sop}} f(x; \theta) dx}_{=0} - \delta \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx \right| \leq \frac{\delta^2}{2} \cdot \int_{\text{sop}} (*) dx$$

$$\Rightarrow \left| \delta \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx \right| \leq \frac{\delta^2}{2} \int_{\text{sop}} (*) dx \Rightarrow \left| \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx \right| \leq \frac{\delta}{2} \int_{\text{sop}} (*) dx$$

$$\text{haciendo } \delta \rightarrow 0 \Rightarrow \int_{\text{sop}} \frac{\partial}{\partial \theta} f(x; \theta) dx = 0$$

$$\int_{\text{sop}} \frac{\partial}{\partial \theta} \ln f(x; \theta) f(x; \theta) dx = \mathbb{E}_{\theta}(Y)$$

Hipótesis del TEOREMA:

X ; $f(x; \theta)$ continua

$\theta \in \Theta = (a, b)$

$\theta \rightarrow f(x; \theta)$ es C^2

I compacto

$$I \subset \Theta ; \int_{\text{sop}} \max_{\theta \in I} \left| \frac{\partial^2}{\partial \theta^2} f(x; \psi) \right| dx < \infty$$

$$\Rightarrow \mathbb{E}_{\theta}(Y) = 0 \quad \forall \theta \in \Theta$$

$$X \quad f(x; \theta) \quad x_1, \dots, x_n$$

Tenemos una sucesión T_n de estimadores de θ tal que:

$$T_n = h_n(x_1, \dots, x_n)$$

DEFINICIÓN: Decimos que T_n es sucesión consistente de estimadores de θ si: $\lim_{n \rightarrow \infty} P(|T_n - \theta| \geq \varepsilon) = 0 \quad \forall \varepsilon > 0$

• Desigualdad de Chebyshev y consistencia

Si T_n es insesgado, la desigualdad de Chebyshev da

$$P(|T_n - \theta| > \varepsilon) \leq \frac{V_\theta(T_n)}{\varepsilon^2}$$

Por tanto si T_n son insesgados y $\lim_{n \rightarrow \infty} V_\theta(T_n) = 0$, entonces T_n es consistente.

Ejemplo: Supongamos $\theta = E(X)$.

En este caso

$$T_n = \bar{X}_n$$

$$\uparrow$$

$$\frac{x_1 + \dots + x_n}{n}$$

$$E_\theta(\bar{X}_n) = E_\theta(X) = \theta \quad \rightarrow \text{insesgado}$$

$$V_\theta(\bar{X}_n) = \frac{V_\theta(X)}{n}$$

T_n insesgado y $V_\theta(T_n) \xrightarrow{n \rightarrow \infty} 0 \Rightarrow T_n$ consistente

- Distribución EXACTA de $P(|T_n - \theta| > \varepsilon)$

(interesa la velocidad con que esta probabilidad tiende a 0)

Ejemplo: X es $N(\mu, \overset{\text{conocido}}{\sigma_0^2}) \Rightarrow \bar{X}_n$ es $N(\mu, \frac{\sigma_0^2}{n})$

$$T_n = \bar{X}_n \quad \text{Entonces: } P(|T_n - \mu| > \varepsilon) = P(|\bar{X}_n - \mu| > \varepsilon) =$$

$$= P\left(\underbrace{\frac{|\bar{X}_n - \mu|}{\sigma_0/\sqrt{n}}}_{N(0,1)} > \frac{\varepsilon\sqrt{n}}{\sigma_0}\right) = 2\left(1 - \Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma_0}\right)\right)$$


nos da el tamaño de muestra que necesitamos para tener un error menor que ε .

Ejemplo: $X \sim \text{Unif}[0, a]$

$$M_n = \max(X_1, \dots, X_n)$$

$$\text{¿ } P_a(|M_n - a| > \varepsilon) ?$$

$$P_a(|M_n - a| > \varepsilon) = P_a(M_n < a - \varepsilon) =$$



$$= \left[\frac{1}{a}(a - \varepsilon)\right]^n = \underbrace{\left(1 - \frac{\varepsilon}{a}\right)^n}_{< 1}$$

$$\Rightarrow \lim_{n \rightarrow \infty} P(|M_n - a| > \varepsilon) = 0$$

M_n es sucesión consistente

Comentario / "truquillo"

$$P(|M_n - a| > \underbrace{\frac{a\varepsilon}{n}}_{\varepsilon'}) = \left(1 - \underbrace{\left(\frac{a\varepsilon}{n}\right)}_{\varepsilon'} \cdot \frac{1}{a}\right)^n \xrightarrow{n \rightarrow \infty} e^{-\varepsilon}$$

$$P\left(\frac{n}{a} |M_n - a| > \varepsilon\right) \xrightarrow{n \rightarrow \infty} \underbrace{e^{-\varepsilon}}_{\text{exp}(1)}$$

Z es $\text{Exp}(\lambda)$
 $P(Z > \varepsilon) = e^{-\lambda\varepsilon}$

$$\Rightarrow \frac{n}{a} |M_n - a| \xrightarrow{\text{distr.}} \text{exp}(1)$$

COMPORTAMIENTO ASINTÓTICO DE ESTIMADORES POR MOMENTOS

X

X_1, \dots, X_n

$$\mu = \mathbb{E}(X) \quad \sigma^2 = \mathbb{V}(X) \quad X_1, \dots, X_n \text{ clones de } X$$

TCL dice:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{\text{distr.}} N(0, 1)$$

y esto lo escribimos así:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{\text{distr.}} N(0, \sigma^2)$$

Estimador por momentos: $X \sim f(x; \theta)$

$$\bar{X}_n = \mathbb{E}_\theta(X) \leftarrow \text{función de } \theta$$

despejamos θ :

$$\boxed{M_\theta = g(\bar{X}_n)}$$

Ejemplos: $M_\theta = \bar{X}_n$; $M_\theta = \frac{1}{\bar{X}_n}$; $M_\theta = \sqrt{\bar{X}_n^2}$

TEOREMA (método delta): Z_n variables aleatorias con valores en un intervalo (a, b)

Las Z_n cumplen esta condición: $\sqrt{n}(Z_n - \alpha) \xrightarrow[n \rightarrow \infty]{\text{distr.}} N(0, \beta^2)$

$g: (a, b) \rightarrow \mathbb{R}$, g es $C^2(a, b)$, $g'(\alpha) \neq 0$

Entonces: $\sqrt{n}(g(Z_n) - g(\alpha)) \xrightarrow[n \rightarrow \infty]{\text{distr.}} N(0, |g'(\alpha)|^2 \cdot \beta^2)$

Idea demostración

$$g(x) \cong g(\alpha) + g'(\alpha)(x - \alpha) \quad ; \quad Z_n \cong \alpha + \frac{\beta}{\sqrt{n}} Y \quad \xrightarrow{\quad} N(0, 1)$$

para la idea: $g(x) \cong g(\alpha) + g'(\alpha)(x - \alpha)$ y $Z_n \cong \alpha + \frac{\beta}{\sqrt{n}} Y$

$$g(Z_n) = g(\alpha) + g'(\alpha)(Z_n - \alpha) = g(\alpha) + g'(\alpha) \frac{\beta}{\sqrt{n}} Y$$

$$g(Z_n) \text{ es } N\left(g(\alpha), (g'(\alpha))^2 \frac{\beta^2}{n}\right)$$

Aplicación

$$X \quad f(x; \theta) \quad x_1, x_2, \dots$$
$$\sqrt{n}(\bar{X}_n - \underbrace{\mu}_{E(X)}) \longrightarrow N(0, \underbrace{\sigma^2}_{V(X)}) \quad g'(\mu) \neq 0$$

Método delta: $\sqrt{n}(g(\bar{X}_n) - g(\mu)) \longrightarrow N(0, |g'(\mu)|^2 \cdot \sigma^2)$

↓ Muchos estimadores por momentos se escriben $g(\bar{X}_n)$,
y esto nos dice que son asintóticamente normales

Ejemplo: X es $\text{Exp}(\lambda)$ $E(X) = 1/\lambda$ $V(X) = 1/\lambda^2$

Usamos como estimador de λ : $\bar{X} = E(X) = 1/\lambda$
↑
momentos

$M_{\lambda,n} = \frac{1}{\bar{X}_n}$ Método delta con $g(x) = 1/x$

TLC $\Rightarrow \sqrt{n}(\bar{X}_n - \underbrace{\frac{1}{\lambda}}_{E(X)}) \longrightarrow N(0, \underbrace{1/\lambda^2}_{V(X)})$

Por el método delta: $\sqrt{n}(\frac{1}{\bar{X}_n} - \lambda) \longrightarrow N(0, \lambda^4 \cdot \frac{1}{\lambda^2})$

$\Rightarrow \sqrt{n}(M_{\lambda,n} - \lambda) \xrightarrow[n \rightarrow \infty]{\text{distr.}} N(0, \lambda^2)$ \uparrow
 $|g'(1/\lambda)|^2 = \lambda^4$

Esto significa que para $\varepsilon > 0$ fijo, el margen de error:

$P(|M_{\lambda,n} - \lambda| > \varepsilon) = \text{probabilidad de equivocarse al estimar en un error mayor que } \varepsilon.$

$P\left(\frac{|M_{\lambda,n} - \lambda|}{\lambda/\sqrt{n}} \geq \frac{\varepsilon\sqrt{n}}{\lambda}\right) \approx 2(1 - \Phi(\frac{\varepsilon\sqrt{n}}{\lambda}))$

$\lambda^2 \rightarrow \text{var} = \lambda$

Ejemplo: $X \sim \text{Ber}(p)$

odds = $\frac{p}{1-p}$:= parámetro a estimar

$$T_n = \frac{\bar{X}_n}{1 - \bar{X}_n}$$

• TCL $\sqrt{n}(\bar{X}_n - p) \xrightarrow[n \rightarrow \infty]{\text{distr.}} N(0, p(1-p))$

• Método delta, $g(x) = \frac{x}{1-x}$

$$\Rightarrow \sqrt{n} \left(\frac{\bar{X}_n}{1 - \bar{X}_n} - \frac{p}{1-p} \right) \longrightarrow N \left(0, \frac{p}{(1-p)^3} \right)$$

$$\sqrt{n}(T_n - \text{odds}) \longrightarrow N \left(0, \frac{p}{(1-p)^3} \right)$$

MÉTODO DELTA si $g'(\alpha) = 0$

$$\sqrt{n}(Z_n - \alpha) \xrightarrow[n \rightarrow \infty]{} N(0, \beta^2)$$

Idea: $g(x) - g(\alpha) \approx \frac{1}{2} g''(\alpha)(x - \alpha)^2$ (ahora $g''(\alpha) \neq 0$)

$$Z_n \approx \alpha + \frac{\beta}{\sqrt{n}} Y \quad \xrightarrow{\quad} \text{normal}(0, 1)$$

idea $\Rightarrow "="$

$$\Rightarrow g(Z_n) - g(\alpha) = \frac{1}{2} g''(\alpha) (Z_n - \alpha)^2 = \frac{1}{2} g''(\alpha) \frac{\beta^2}{n} Y^2 \xrightarrow{\quad} \chi_1^2$$

Entonces:

$$n(g(Z_n) - g(\alpha)) = \frac{1}{2} g''(\alpha) \beta^2 \chi_1^2$$

$\xrightarrow{\quad}$ si esto es positivo siempre estamos estimando para arriba.
Si es negativo, siempre estimamos para abajo.

hay sesgo, error sistemático

MÉTODO DELTA si $g'(x) = 0$, $g''(x) \neq 0$ y $g \in C^3$

$$n(g(z_n) - g(x)) \cong \frac{1}{2} g''(x) \beta^2 \chi^2_1$$

INTERVALOS DE CONFIANZA

Ejemplo básico:

X es $N(\mu, \sigma_0^2)$
↑
a estimar


conocido

X_1, \dots, X_n
clones

\bar{X} es $N(\mu, \frac{\sigma_0^2}{n})$

$$\frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \sim N(0, 1)$$


Notación percentiles:



α pequeño

$$\Phi(Z_\alpha) = 1 - \alpha \Rightarrow Z_\alpha = \Phi^{-1}(1 - \alpha)$$

$$\Rightarrow P\left(\left|\frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}}\right| > Z_{\alpha/2}\right) = \alpha$$



por el valor absoluto

$$P\left(\mu - Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}} \leq \bar{X} \leq \mu + Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}}\right) = 1 - \alpha \quad \left(\begin{array}{l} \text{PROBABILIDAD 1} \\ \text{ANTES DE} \\ \text{LA MUESTRA,} \end{array}\right)$$

Prob: antes de la muestra

Estad: tenemos una muestra

Estadística: muestra $x_1, \dots, x_n \rightarrow \bar{x}$

Con confianza $1 - \alpha$ se tiene $\mu - Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}} \leq \bar{X} \leq \mu + Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}}$

ponemos a μ en el papel central: $\bar{x} - Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}} \leq \mu \leq \bar{x} + Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}}$

Al intervalo $\left(\bar{x} - Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}}, \bar{x} + Z_{\alpha/2} \cdot \frac{\sigma_0}{\sqrt{n}}\right)$ lo llamamos
INTERVALO DE CONFIANZA μ de $N(\mu, \sigma_0^2)$ con σ_0^2 conocido.

Tamaño del intervalo: $2 Z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}$

Dos grados de libertad $\left\{ \begin{matrix} \alpha \\ n \end{matrix} \right.$

Si aumentamos confianza $(1-\alpha)$ con n fijo

- crece $(1-\alpha)$
- decrece α
- crece Z_α y $Z_{\alpha/2}$
- crece el intervalo

Si aumentamos n con α fijo \rightarrow decrece el intervalo

Tamaño de la muestra (para un error determinado)

Fijamos $\overbrace{Z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}}$ (con α fijado) \rightarrow error

Esto determina un n mínimo.

Ejemplo: error permitido es de 0.01 y $\alpha = 5\%$ ($Z_{\alpha/2} = 1.96$)
 $\sigma_0 = 1$

$$\Rightarrow n \geq \left(Z_{\alpha/2} \frac{\sigma_0}{0.01} \right)^2 \Rightarrow n \geq 38416$$

Ejemplo: $X \sim N(\mu, \sigma^2)$

$$x_1, \dots, x_n \begin{cases} \bar{x} = \frac{x_1 + \dots + x_n}{n} \\ s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases}$$

Intervalo para μ e intervalo para σ^2 ?

Probabilidad

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

$$\bar{x} - Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

con confianza $(1-\alpha)$

Para μ : $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ es t_{n-1} de Student

variables aleatorias

$$\Rightarrow P\left(-t_{n-1, \alpha/2} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1, \alpha/2}\right) = 1-\alpha$$


⊛ \bar{x} estimador insesgado de μ

Dentro del ámbito estadístico (ya tenemos una muestra)

$$\boxed{\bar{x} - \frac{s}{\sqrt{n}} t_{n-1, \alpha/2} \leq \mu \leq \bar{x} + \frac{s}{\sqrt{n}} t_{n-1, \alpha/2}} \quad \text{Intervalo para } \mu \text{ de } N(\mu, \sigma^2) \text{ con confianza } (1-\alpha)$$

► Para σ^2 : S^2 estimador de σ^2 (insesgado)

$$(n-1) \frac{S^2}{\sigma^2} \text{ es } \chi^2_{n-1}$$



$$\Rightarrow P\left(\chi^2_{n-1, 1-\alpha/2} \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{n-1, \alpha/2}\right) = 1-\alpha$$

↳ debido a que χ^2_k no es simétrica

Intervalo para σ^2 de $N(\mu, \sigma^2)$ con confianza $(1-\alpha)$

$$\boxed{\frac{(n-1)}{\chi^2_{n-1, \alpha/2}} \cdot S^2 \leq \sigma^2 \leq \frac{(n-1)}{\chi^2_{n-1, 1-\alpha/2}} \cdot S^2} \quad \text{de la muestra}$$

Ejemplo:

$N(\mu, \sigma^2)$

α	$Z_{\alpha/2}$
5%	1.96
1%	2.58
0.1%	3.29

$n=30$

$\bar{x}=1.3$

$S^2 = 0.36$

Intervalo al 95% de μ y de σ^2

$$\mu = 1.3 \pm \underbrace{t_{29, 2.5\%}}_{2.045 \text{ (excel)}} \cdot \frac{0.06}{\sqrt{30}}$$

2.045 (excel)

$$\frac{29 \cdot 0.36}{45.72} \leq \sigma^2 \leq \frac{29 \cdot 0.36}{16.04}$$

INTERVALOS ASINTÓTICOS DE CONFIANZA

Idea: Tenemos un estadístico H_n (que usa x_1, \dots, x_n)

$$\sqrt{n}(H_n - a) \xrightarrow{\text{distr.}} N(0, b^2)$$

$$P\left(-Z_{\alpha/2} \leq \frac{H_n - a}{b/\sqrt{n}} \leq Z_{\alpha/2}\right) \approx 1 - \alpha \quad \rightarrow \text{un igual a partir de ahora}$$

\Downarrow

$$\text{Intervalo: } a = h_n \pm \frac{b}{\sqrt{n}} Z_{\alpha/2} \quad \left(h_n - \frac{b}{\sqrt{n}} Z_{\alpha/2} \leq a \leq h_n + \frac{b}{\sqrt{n}} Z_{\alpha/2} \right)$$

Confianza $1 - \alpha$

\hookrightarrow muestra de $H_n(x_1, \dots, x_n)$

Ejemplo: X es $\text{Ber}(p)$ x_1, \dots, x_n muestra \bar{x} = proporción de 1's.

$$\sqrt{n}(\bar{X}_n - p) \rightarrow N(0, p(1-p))$$

$$\text{Intervalo de confianza } 1 - \alpha: \bar{x} - \frac{\sqrt{p(1-p)}}{\sqrt{n}} Z_{\alpha/2} \leq p \leq \bar{x} + \frac{\sqrt{p(1-p)}}{\sqrt{n}} Z_{\alpha/2}$$

alternativas: ① $p(1-p) \leq \frac{1}{4} \Rightarrow \sqrt{p(1-p)} \leq \frac{1}{2}$

$\swarrow \searrow$
como depende de p
arreglamos el intervalo

Confianza $1 - \alpha$:

$$\bar{x} - \frac{1/2}{\sqrt{n}} Z_{\alpha/2} \leq p \leq \bar{x} + \frac{1/2}{\sqrt{n}} Z_{\alpha/2}$$

(2) Utilizar \bar{x} como estimador:
 media de la muestra pequeña y barata

$$\underbrace{\bar{x}}_{\substack{\text{media de} \\ \text{la muestra} \\ \text{de verdad (grande)}}} - \frac{\sqrt{\bar{x}(1-\bar{x})}}{\sqrt{n}} Z_{\alpha/2} \leq p \leq \bar{x} + \frac{\sqrt{\bar{x}(1-\bar{x})}}{\sqrt{n}} Z_{\alpha/2}$$

TAMAÑO DE MUESTRA

BERNOULLI:

Margen de error (absoluto), dado en porcentaje

$$\text{error} = \pm 1\% = \pm 0.01$$

$$\alpha = 5\%$$

$$Z_{\alpha/2} = 1.96$$

$$\left| \begin{array}{l} \text{tamaño de la muestra conservador: } \frac{1}{2\sqrt{n}} \cdot 1.96 \leq 0.01 \end{array} \right.$$

Alternativa: muestra previa \rightarrow estimación $\hat{p} = 0.3$

$$\frac{\sqrt{0.3(1-0.3)}}{\sqrt{n}} \cdot 1.96 \leq 0.01$$

Ejemplo: Intervalo $(1-\alpha)$
 X es Poisson (λ)

$$\boxed{\begin{array}{l} \downarrow E_{\lambda}(X) = \lambda \quad V_{\lambda}(X) = \lambda \quad \uparrow \end{array}}$$

$$\sqrt{n}(\bar{X} - \lambda) \rightarrow N(0, \lambda)$$

$$\text{Intervalo: } \bar{x} - \underbrace{\sqrt{\lambda}}_{\rightarrow \sqrt{\bar{x}}} \frac{Z_{\alpha/2}}{\sqrt{n}} \leq \lambda \leq \bar{x} + \sqrt{\lambda} \frac{Z_{\alpha/2}}{\sqrt{n}}$$

$\rightarrow \sqrt{\bar{x}}$ (solución ingenieril)

INTERVALOS DE DOS POBLACIONES

Normales / Bernouillis

Ejemplo básico: $X \sim N(\mu_1, \sigma_1^2)$ X_1, \dots, X_{n_1} n_1 tamaño
 $Y \sim N(\mu_2, \sigma_2^2)$ Y_1, \dots, Y_{n_2} n_2 tamaño

• Intervalo para $\mu_1 - \mu_2$ | σ_1^2, σ_2^2 son conocidas

$$\begin{aligned} \bar{X} - \bar{Y}, \text{ y como son indep. } \bar{X} \text{ e } \bar{Y} & \begin{cases} \bar{X} \sim N(\mu_1, \frac{\sigma_1^2}{n_1}) \\ \bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{n_2}) \end{cases} \\ \bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}) & \end{aligned}$$

Probabilidad:

$$P\left(-Z_{\alpha/2} \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq Z_{\alpha/2}\right) = 1 - \alpha$$

Confianza $1 - \alpha$:

$$-Z_{\alpha/2} \leq \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{\dots}} \leq Z_{\alpha/2} \Rightarrow$$

$$\Rightarrow \bar{x} - \bar{y} - Z_{\alpha/2} \sqrt{\dots} \leq \mu_1 - \mu_2 \leq \bar{x} - \bar{y} + Z_{\alpha/2} \sqrt{\dots}$$

• Intervalo para $\mu_1 - \mu_2$ con σ_1^2, σ_2^2 desconocidas.
pero $\sigma_1 = \sigma_2 = \sigma$ desconocido.

$$(n_1 - 1) S_1^2 = \sigma_1^2 \chi_{n_1 - 1}^2$$

$$+ (n_2 - 1) S_2^2 = \sigma_2^2 \chi_{n_2 - 1}^2$$

independientes

$$(n_1 - 1) S_1^2 + (n_2 - 1) S_2^2 = \sigma^2 \chi_{n_1 - 1 + n_2 - 1}^2 \quad (1)$$

Introducimos un $S_p^2 \xleftarrow{\text{promedio}} \Rightarrow S_p^2 = \frac{(n_1 - 1) S_1^2 + (n_2 - 1) S_2^2}{(n_1 - 1 + n_2 - 1)} \quad (2)$

(1) con (2) : $(n_1 - 1 + n_2 - 1) S_p^2 = \sigma^2 \chi_{n_1 - 1 + n_2 - 1}^2$

Con esto obtenemos:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \text{ es } t_{n_1 - 1 + n_2 - 1}$$

Intervalo:

$$\bar{x} - \bar{y} - \hat{S}_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} t_{n_1 - 1 + n_2 - 1; \alpha/2} \leq \mu_1 - \mu_2 \leq \bar{x} - \bar{y} + \hat{S}_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} t_{n_1 - 1 + n_2 - 1; \alpha/2}$$

COMPARACION DE PROPORCIONES

X es $\text{Ber}(p_1)$

n_1

\bar{x} - proporción de 1's de X

Y es $\text{Ber}(p_2)$

n_2

\bar{y} - proporción de 1's de Y

Intervalo:

$\downarrow \bar{x} \sim N(p_1, \frac{p_1(1-p_1)}{n_1})$

$$p_1 - p_2 = (\bar{x} - \bar{y}) \pm Z_{\alpha/2} \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$$

$$\begin{cases} p_1 \approx \bar{x} \\ p_2 \approx \bar{y} \end{cases}$$

CONTRASTE DE HIPÓTESIS

Ejemplo inicial: Moneda que se supone equilibrada

$n=10 \rightarrow \# \text{caras} = 6 \rightarrow \bar{x} = \text{proporción de caras} = 60\%$

$n=100 \rightarrow \# \text{caras} = 60 \rightarrow \bar{x} = 60\%$

$n=1000 \rightarrow \# \text{caras} = 600 \rightarrow \bar{x} = 60\%$

• Ingredientes del contraste de hipótesis:


$X \sim N(\mu, \sigma^2)$
 ↑ ↑
 desconocido conocido

(1) HIPÓTESIS NULA: $H_0: \mu = \mu_0$ (hipótesis de partida)

Nosotros vamos a hacer un experimento para ver si esta hipótesis se cumple o no.

(2) TEST/CONTRASTE: Damos $\alpha > 0$, próximo a cero

Si H_0 es cierto $\Rightarrow \bar{x} \in \left(\mu_0 - \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma, \mu_0 + \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma \right)$



con probabilidad $1 - \alpha$.

Hacemos experimento: si $\bar{x} \notin \left(\mu_0 - \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma, \mu_0 + \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma \right)$, entonces rechazamos la hipótesis H_0 , en caso contrario aceptamos H_0 .

(3) HIPÓTESIS ALTERNATIVA: $H_1: \mu \neq \mu_0$

(4) REGIÓN DE RECHAZO: R_α

$R_\alpha = \left(-\infty, \mu_0 - \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma \right) \cup \left(\mu_0 + \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma, \infty \right)$

(3) ERRORES:

5.1. ERROR DE TIPO 1: rechazar H_0 si es cierta

5.2. ERROR DE TIPO 2: aceptar H_0 cuando es falsa

En el ejemplo $\rightarrow P(\text{error de tipo 1}) = \alpha$ (pequeño)

Si lo rechazamos, tenemos CONFIANZA de que lo hemos rechazado bien.

Si aceptamos, es porque no nos queda más remedio.

Ejemplo: $N(\mu, 4)$ $n=100$ $\alpha=1\%$ $\alpha=5\%$

$$H_0 \Rightarrow \mu_0 = 1$$

$$R_\alpha: |\bar{x} - 1| > Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \quad \begin{matrix} \leftarrow \sigma \\ 10 \leftarrow \sqrt{100} \end{matrix}$$

Hacemos un experimento y obtenemos $\bar{x} = 1.4$:


para $\alpha=1\% \rightarrow$ Rechazo $|\bar{x} - 1| > 2.58 \cdot (0.2) = 0.52$

para $\alpha=5\% \rightarrow$ Rechazo $|\bar{x} - 1| > 1.96 \cdot (0.2) = 0.39$

α = nivel de significación

Con significación de 1% \Rightarrow aceptamos

Con significación de 5% \Rightarrow rechazamos



EL P-VALOR es el valor de α tal que \bar{x} está en el borde de la región de rechazo.

$$|\bar{x} - \mu_0| = \frac{Z_{\alpha/2}}{\sqrt{n}} \sigma \Rightarrow |\bar{x} - \mu_0| \frac{\sqrt{n}}{\sigma} = Z_{\alpha/2} \Rightarrow$$

$$\Rightarrow \boxed{\alpha = 2 \left(1 - \Phi \left(|\bar{x} - \mu_0| \frac{\sqrt{n}}{\sigma} \right) \right)}$$

cuanto menor sea, más seguro estás de haber rechazado bien
* Cuanto menor es el p-valor, mejor ha sido el experimento esta-

Ejemplo: Ber(p)

\bar{x} = proporción en la muestra

$$H_0: p = p_0$$

α : nivel de significación

n: tamaño de la muestra

Región de rechazo: $R_\alpha = \left\{ |\bar{x} - p_0| > \frac{Z_{\alpha/2}}{\sqrt{n}} \sqrt{p_0(1-p_0)} \right\}$

Retomamos el ejemplo inicial: ejemplo de "mosqueo"

n = 10 #caras = 6

n = 100 #caras = 60

n = 1000 #caras = 600

$\bar{x} = 60\%$ en las tres muestras

$$H_0 \Rightarrow p = p_0 = 0.5$$

p-valor:
$$\frac{0.1}{|\bar{x} - p_0|} = \frac{Z_{\alpha/2}}{\sqrt{n}} \cdot \frac{1}{2} \rightarrow \alpha = 2 \left(1 - \Phi(0.2\sqrt{n}) \right)$$

p-valor para n=10 #caras=6 $\Rightarrow \sim 52\%$

p-valor para n=100 #caras=60 $\Rightarrow \sim 4\%$

p-valor para n=1000 #caras=600 $\Rightarrow \sim 2.1\%$

Hemos visto TEST BILATERALES.

$$\bar{X} \sim N(\mu, \sigma^2)$$

\uparrow conocido

tenemos μ_0 de referencia

$$H_0 \equiv \mu \leq \mu_0$$

$$(H_1 \equiv \mu > \mu_0)$$

Región de rechazo:

$$R_\alpha: \bar{x} > \mu_0 + \frac{\sigma}{\sqrt{n}} Z_\alpha$$

esto de aquí son
TEST UNILATERALES

Diseño de test unilateral

Referencia μ_0

$N(\mu, \sigma^2)$ con σ^2 conocido

\bar{X} más grande que μ_0 .

¿ $H_0: \mu \leq \mu_0$? ó ¿ $H_0: \mu \geq \mu_0$? \rightarrow Planteamos $H_0: \mu \leq \mu_0$ porque el test lo que hace bien es rechazar.

TESTS GENERALES

Ejemplo base: control de calidad

Producción: cajas con 10000 tornillos

Control de calidad: tomamos una caja y una muestra de 10 tornillos.
La caja es buena si la proporción de defectuosos es $\leq 5\%$

Test: Si hay ≥ 2 tornillos defectuosos de los 10 de la muestra declaramos la caja como no válida.

Nos interesa la probabilidad de rechazar cajas buenas.

Notación: p = prop. de defectuosas en la caja

Hipótesis nula: $H_0: p \leq 5\%$

$n=10$

Rechazamos si #defectuosas ≥ 2

Función de potencia del test:

$p \in \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$\rightarrow \beta(p) := \mathbb{P}_p(\text{rechazar})$

test


En este caso: \rightarrow en muestra

$\beta(p) = \mathbb{P}_p(\# \text{defectuosos} \geq 2) =$

$= \mathbb{P}(\text{Bin}(10, p) \geq 2) =$

$= 1 - \mathbb{P}(\text{Bin}(10, p) = 1) - \mathbb{P}(\text{Bin}(10, p) = 0)$

$= 1 - (1-p)^{10} - 10p(1-p)^9$



Probabilidad de error de tipo 1:

$$\underset{\substack{\square \\ \rightarrow \text{cuando } H_0 \\ \text{es bueno}}}{P}(\text{rechazar}) = P_p(\text{rechazar}) \text{ con } p \in \underset{\substack{|| \\ (0,5\%)}}{H_0}$$

En este caso:

$$\text{Significación} = P_{5\%}(\text{rechazar}) = 1 - (95\%)^{10} - 10p(1-p)^9 \approx 8\%$$

Ejemplo: Propongo el siguiente test

$$X \sim N(\mu, \sigma^2) \quad \underset{\substack{\uparrow \\ \text{conocido}}}{\sigma^2}$$

Queremos func. de potencia
y significación.

$$\begin{aligned} H &= R \\ H_0 &= \{\mu \leq \mu_0\} = (-\infty, \mu_0) \\ &\quad \uparrow \\ &\text{hipótesis nula} \end{aligned}$$


n = tamaño de la muestra

$$\text{Rechazamos cuando: } \bar{X} \geq \mu_0 + Z_\alpha \frac{\sigma}{\sqrt{n}}$$

Función de potencia: rechazar

$$\underset{\substack{\uparrow \\ \mu \in R}}{\beta(\mu)} = P_\mu \left(\bar{X} \geq \mu_0 + Z_\alpha \frac{\sigma}{\sqrt{n}} \right) = P_\mu \left(\underbrace{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}_{N(0,1)} \geq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + Z_\alpha \right) =$$

$$= 1 - \Phi \left(\frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + Z_\alpha \right)$$



$$\text{Significación} = \sup_{\mu \in H_0} \beta(\mu)$$

$$\beta(\mu_0) = 1 - \Phi(Z_\alpha) = 1 - (1 - \alpha) = \alpha$$

$$\Rightarrow \text{Significación} = \beta(\mu_0) = \alpha$$

Notación:

Θ = espacio de parámetros

$H_0 = \theta \in \Theta_0 \subset \Theta$

hipótesis nula
Rechazo $\left\{ \begin{array}{l} n = \text{tamaño de la muestra} \\ T \text{ estadístico} \\ \text{Rechazo si } T \in \mathcal{R} \end{array} \right.$

Función de potencia $\beta(\theta) = P_\theta(T \in \mathcal{R})$
 \uparrow región de rechazo

Significación del test: $\sup_{\theta \in \Theta_0} \beta(\theta)$

Ejemplo: $\text{Unif}[0, a]$

$$\Theta = (0, \infty)$$


$$\Theta_0 = (0, A)$$

$$H_0: a \leq A$$

Rechazamos si $\max(x_1, \dots, x_n) > A$

$$\beta(a) = P_a(\max(x_1, \dots, x_n) > A) = \begin{cases} 0 & \text{si } a < A \\ * & \text{si } a > A \end{cases}$$

$$\begin{aligned} * &= P_a(\max(x_1, \dots, x_n) > A) = P_a(A < \max(\dots) < a) = \\ &= 1 - P_a(\max(\dots) < A) = 1 - \left(\frac{A}{a}\right)^n \quad \text{si } a > A \end{aligned}$$



Significación = 0

\hookrightarrow jamás cometeríamos un error de tipo 1

Ejemplo: $\text{Unif}[0, a]$

$$a \in \Theta = (0, \infty)$$

x_1, \dots, x_n muestra

$$n=10$$



$H_0 = a \geq A$
↑ hipótesis nula ↑ dato

Rechazo si $\max(x_1, \dots, x_n) \leq \frac{A}{2}$
↑
región de rechazo

1) Función de potencia

$$a \in \Theta; \beta(a) = P_a(\text{rechazar})$$

$$\beta(a) = \begin{cases} 1 & \text{si } a \leq A/2 \text{ (en este caso } x_1, \dots, x_n \leq a \leq A/2) \\ \left(\frac{A/2}{a}\right)^n & \text{si } a \geq A/2 \end{cases}$$



Nueva región de rechazo porque la significación es muy pequeña:

$$\beta(a) = \begin{cases} 1 & a \leq tA \\ \left(\frac{tA}{a}\right)^n & a \geq tA \end{cases}$$

significación: $\beta(A) = t^n = t^{10} = 5\% \rightarrow$ despejar t
 $a=A$ $\rightarrow t = 74.1\%$

Significación:

$$\begin{aligned} \sup_{a \in \Theta} P_a(\text{rechazar}) &= \\ &= \sup_{a \in \Theta} \beta(a) = \beta(A) \\ &= \left(\frac{1}{2}\right)^n \\ &= \left(\frac{1}{2}\right)^{10} \approx 0.1\% \end{aligned}$$

Otro contraste: $\text{Unif}[0, a]$

$$\Theta_0 = [a \geq A] = (A, \infty)$$

Nos mosqueamos si hay "muchos" "pequeños". x_1, \dots, x_n muestra $n=10$

Rechazo si $\#\{x_j < \frac{A}{5}\} \geq \frac{n}{2}$


1) Función de potencia

2) Significación

$$P_a(\text{rechazar}) = P\left(\text{Bin}\left(\overset{n}{10}, \frac{A/5}{a}\right) \geq \overset{n/2}{5}\right) \quad \text{si } a \geq \frac{A}{5}$$

$$P_a(X < A/5) = \frac{A/5}{a}$$

$$\Rightarrow \beta(a) = \begin{cases} 1 & \text{si } a \leq A/5 \\ P(\text{Bin}(10, \frac{A/5}{a}) \geq 5) & \text{si } a \geq A/5 \end{cases}$$



$$\text{Significación} = \sup_{a \in \Theta_0} \beta(a) = \beta(A) = P(\text{Bin}(10, 1/5) \geq 5) = 3.28\%$$

MÉTODO DE RAZÓN DE VEROSIMILITUDES (TEST DE RAZÓN DE VEROS.)

(Método general para construir contrastes)

$$X \quad f(x; \theta) \quad \theta \in \Theta$$

$$H_0 \equiv \theta \in \Theta_0 \subset \Theta$$

x_1, \dots, x_n muestra de X .

$$\text{VERO}(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

Si $\sup_{\theta \in \Theta_0} \text{VERO}(\dots)$ es pequeña, los $\theta \in \Theta_0$ son poco creíbles.
Son poco consistentes con la muestra.

Se toma $c \in (0, 1)$ donde c se denomina CALIBRE.

$$\text{Rechazo } \Theta_0 \text{ si } \frac{\sup_{\theta \in \Theta_0} \text{VERO}(\dots)}{\sup_{\theta \in \Theta} \text{VERO}(\dots)} \leq c$$

Ejemplos de test de razón de verosimilitudes con calibre c .

① $X \sim N(\mu, \sigma^2)$ ^{conocido}

Para simplificar $\sigma = 1$


n = tamaño de la muestra

x_1, \dots, x_n
calibre $\rightarrow c \in (0, 1)$

$$H_0 \equiv \mu \leq \mu_0$$

1. Función de verosimilitud

$$\begin{aligned} \text{VERO}(\mu; x_1, \dots, x_n) &= \prod_{i=1}^n f(x_i, \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i - \mu)^2} \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2} \end{aligned}$$



Observemos $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 - 2\left(\sum_{i=1}^n x_i\right)\mu + n\mu^2$ \leftarrow mínimo en $\mu = \bar{x}$

3. $H = (-\infty, \infty)$

$H_0 = (-\infty, \mu_0)$

$$\sup_{\mu \in H} \text{VERO}(\mu; x_1, \dots, x_n) = \text{VERO}(\bar{x}; x_1, \dots, x_n)$$

$\sup_{\mu \in H_0} \text{VERO}(\mu; x_1, \dots, x_n)$ ^{dos casos}

$$= \begin{cases} \text{VERO}(\mu_0, x_1, \dots, x_n) & \text{si } \mu_0 < \bar{x} \\ \text{VERO}(\bar{x}; x_1, \dots, x_n) & \text{si } \mu_0 > \bar{x} \end{cases}$$

4. Razón de verosimilitudes = RV

$$RV = \begin{cases} \frac{\text{VERO}(\bar{x})}{\text{VERO}(\mu_0)} = \exp\left(-\frac{1}{2}\left(\sum_{i=1}^n (x_i - \mu_0)^2 - \sum_{i=1}^n (x_i - \bar{x})^2\right)\right) & \text{si } \mu_0 < \bar{x} \\ 1 & \text{si } \mu_0 \geq \bar{x} \end{cases}$$

5. Simplificación

$$\sum_{i=1}^n (x_i - \mu_0)^2 = \cancel{\sum_{i=1}^n x_i^2} - 2 \left(\sum_{i=1}^n x_i \right) \mu_0 + n \mu_0^2 = -2n\bar{x}\mu_0 + n\mu_0^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \cancel{\sum_{i=1}^n x_i^2} - 2 \left(\sum_{i=1}^n x_i \right) \bar{x} + n\bar{x}^2 = -2n\bar{x}\bar{x} + n\bar{x}^2$$

$$\Rightarrow -2n\bar{x}\mu_0 + n\mu_0^2 + 2n\bar{x}\bar{x} - n\mu_0^2 - n\bar{x}^2 =$$

$$= n(-2\bar{x}\mu_0 + \mu_0^2 + 2\bar{x}^2 - \bar{x}^2) = n(-2\bar{x}\mu_0 + \mu_0^2 + \bar{x}^2) =$$

$$= n(\mu_0 - \bar{x})(\mu_0 + \bar{x} - 2\bar{x}) = n(\mu_0 - \bar{x})^2$$

$$\Rightarrow RV = \begin{cases} \exp\left(-\frac{1}{2}n(\mu_0 - \bar{x})^2\right) & \text{si } \mu_0 < \bar{x} \\ 1 & \text{si } \mu_0 \geq \bar{x} \end{cases}$$

6. Región de rechazo: (Test)

Rechazamos cuando $RV \leq C \Rightarrow$

$$\Rightarrow \begin{cases} \exp\left(-\frac{1}{2}n(\mu_0 - \bar{x})^2\right) \leq C \quad \wedge \quad \mu_0 \leq \bar{x} & (*) \\ \text{ó cuando} \\ 1 \leq C \quad \wedge \quad \mu_0 \geq \bar{x} \end{cases}$$

$\xrightarrow{\quad}$ esto no pasa nunca


$$(*) \quad \bar{x} \geq \mu_0 \quad \wedge \quad (\mu_0 - \bar{x})^2 \geq \frac{2}{n} \ln \frac{1}{C} \Leftrightarrow \boxed{\bar{x} > \mu_0 + \sqrt{\frac{2}{n} \ln \frac{1}{C}}}$$

7. Función de potencia y significación

$$\beta(\mu) = P_{\mu}(\text{rechazar}) \quad \mu \in \Theta = (-\infty, \infty)$$

$$\beta(\mu) = P_{\mu} \left(\bar{x} > \mu_0 + \frac{1}{\sqrt{n}} \sqrt{2 \ln \frac{1}{\alpha}} \right) = P_{\mu} \left(\frac{\bar{x} - \mu}{\frac{1}{\sqrt{n}}} > \frac{\mu_0 - \mu}{\frac{1}{\sqrt{n}}} + \sqrt{2 \ln \frac{1}{\alpha}} \right)$$

$$= 1 - \Phi \left(\frac{\mu_0 - \mu}{\frac{1}{\sqrt{n}}} + \sqrt{2 \ln \frac{1}{\alpha}} \right)$$



$$\text{Significación} = \sup_{\mu \in \Theta_0} \beta(\mu) = \beta(\mu_0) = 1 - \Phi \left(\sqrt{2 \ln \frac{1}{\alpha}} \right)$$

