

TEMA { NORMAL MULTIDIMENSIONAL VECTORES NORMALES

A) VARIABLE NORMAL (1-dimensión)

$$\bullet X \sim N(\mu, \sigma^2) \Leftrightarrow f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x \in \mathbb{R}$$

$$\bullet Y \sim N(0,1) \Leftrightarrow f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} \quad y \in \mathbb{R}$$

$$\bullet X \sim N(\mu, \sigma^2) \Leftrightarrow X = \mu + \sigma Y \quad \text{con } Y \sim N(0,1)$$

• X, Z normales independientes

$$X \sim N(\mu_1, \sigma_1^2) \quad Z \sim N(\mu_2, \sigma_2^2)$$

$$\Rightarrow \underbrace{X+Z}_{\text{variable normal}} \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

obs: si sumas dos normales dependientes, su suma no tiene porque ser normal.

→ ejemplo: $X; Z = -X \Rightarrow X+Z \equiv 0$ (no es normal)

B) $\vec{m} \in \mathbb{R}^n$, V es matriz $n \times n$ $V \in M_{n \times n}$
simétrica y def. positiva (no basta semidef. positiva)

$\vec{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \sim N(\vec{m}, V)$ si su función de densidad es:

vector aleatorio

$$f_{\vec{X}}(\vec{x}) = \frac{1}{(\sqrt{2\pi})^n} \cdot \frac{1}{\sqrt{\det(V)}} \cdot \exp\left(-\frac{1}{2}(\vec{x}-\vec{m})^t V^{-1}(\vec{x}-\vec{m})\right)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sqrt{\sigma^2}} \exp\left(-\frac{1}{2}(x-m) \cdot \frac{1}{\sigma^2}(x-m)\right)$$

C) CASO ESPECIAL (e importante): NORMAL ESTANDAR N-MULTIDIMENSIONAL

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \vec{y} \sim N(\vec{0}, I_n) \quad \text{normal estándar}$$

$$f_{\vec{y}}(\vec{y}) = \frac{1}{(\sqrt{2\pi})^n} \cdot \exp\left(-\frac{1}{2} \vec{y}^t \vec{y}\right) = \frac{1}{(\sqrt{2\pi})^n} \cdot \exp\left(-\frac{1}{2} \sum_{i=1}^n y_i^2\right)$$

$$= \left(\frac{1}{\sqrt{2\pi}} \cdot e^{-y_1^2/2}\right) \cdot \dots \cdot \left(\frac{1}{\sqrt{2\pi}} \cdot e^{-y_n^2/2}\right)$$

$\Rightarrow Y_1, Y_2, \dots, Y_n$ son independientes, porque la función de densidad conjunta es el producto de densidades de las variables aleatorias.

Además, $\forall i \ Y_i \sim N(0, 1)$ para $1 \leq i \leq n$.

Y recíprocamente:

$\vec{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \sim N(\vec{0}, I_n)$ si y solo si Y_1, \dots, Y_n son independientes y normales estándar.

D) MATRICES SIMÉTRICAS / FORMAS CUADRÁTICAS. M_n = matrices $n \times n$ reales.

D.1. $O \in M_n$ es ORTOGONAL si $O^t O = I_n$, es decir, $O^{-1} = O^t$

\Leftrightarrow columnas son base ortonormal de $\mathbb{R}^n \Leftrightarrow$

\Leftrightarrow filas son base ortonormal de \mathbb{R}^n

Ejemplo

BASE ORTOGONAL

$$A = \begin{pmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} & \dots & \begin{bmatrix} 1 \\ -1 \end{bmatrix} \end{pmatrix}$$

en general $I_n \neq A^t A$, las columnas/filas tienen que ser ortonormales

$$\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

no es ortonormal

$$\det(O) = \pm 1.$$

D.2. Si A es simétrica, entonces A es orto-diagonalizable.
 Es decir, $\exists O$ ortogonal tal que $A = O D O^t$
 \uparrow matriz diagonal

$$D = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}$$

\hookrightarrow autovalores de A

Las columnas de O son base ortonormal de autovectores.

D.3. A simétrica es definida positiva $\vec{x}^t A \vec{x} > 0$
 si $\vec{x} \neq 0$. Definida positiva $\Leftrightarrow \lambda_1, \dots, \lambda_n > 0$
 autovalores

D.4. Lema: A simétrica y definida positiva \Leftrightarrow
 $\Leftrightarrow \exists R \in M_n$ tal que $A = R^t \cdot R$ y R es no singular.
 R se dice que es RAÍZ CUADRADA de A

$\nearrow \det(R) \neq 0$
 $\nearrow \exists R^{-1}$

Caso particular: A es diagonal $= \begin{pmatrix} a_1 & & 0 \\ & \ddots & \\ 0 & & a_n \end{pmatrix}$

A definida positiva $\Leftrightarrow a_i > 0 \quad i=1, \dots, n$

$$R = \begin{pmatrix} \sqrt{a_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{a_n} \end{pmatrix}$$

$$R^t R = R R = A$$

demonstración lema

$\Rightarrow A = O \cdot D \cdot O^t \quad A \text{ def. positiva} \Rightarrow \lambda_1, \dots, \lambda_n > 0$

$$\begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}$$

$$F = \begin{pmatrix} \sqrt{\lambda_1} & & 0 \\ & \ddots & \\ 0 & & \sqrt{\lambda_n} \end{pmatrix}$$

$$\Rightarrow A = O \cdot D \cdot O^t = O \cdot F \cdot F \cdot O^t = O \cdot F \cdot F^t \cdot O^t =$$

$$= O F (O F)^t \Rightarrow R = (O F)^t$$

$\hookrightarrow \det(R)? \Rightarrow \det(R) = \det(O) \cdot \det(F) \neq 0$

$$\boxed{\Leftarrow} \quad A = R^t R \quad \text{y } R \text{ no singular} \quad A, R \in M_n$$

• ¿A es simétrica? $A^t = R^t (R^t)^t = R^t R = A \rightarrow A \text{ simétrica}$

• ¿A def. positiva?

$$\vec{x}^t A \vec{x} = \vec{x}^t R^t R \vec{x} = (R\vec{x})^t (R\vec{x}) = \|R\vec{x}\|^2 \geq 0$$

$$\text{y } \|R\vec{x}\| = 0 \Leftrightarrow R\vec{x} = \vec{0} \xRightarrow{\substack{\uparrow \\ R \text{ no singular}}} \vec{x} = \vec{0} \quad \square$$

D.5. Inversa

$$A \in M_n \text{ simétrica y definida positiva} \Leftrightarrow$$

$$\Leftrightarrow A^{-1} \text{ es simétrica y def. positiva}$$

demostración

$$A = O \underset{\substack{\parallel \\ \lambda_i > 0}}{D} O^t \quad \Leftrightarrow \quad A^{-1} = (O \underset{\substack{\parallel \\ \lambda_i > 0}}{D} O^t)^{-1} = O \cdot \begin{pmatrix} 1/\lambda_1 & & \\ & \ddots & \\ & & 1/\lambda_n \end{pmatrix}$$

$$\Rightarrow A^{-1} \text{ es simétrica porque } A^{-1} = (A^{-1})^t$$

autovalores de $A^{-1} = \underbrace{\{1/\lambda_1, \dots, 1/\lambda_n\}}_{> 0} \Rightarrow \text{def. positivo}$

observación:

$$A^n = (O D O^t)^n = O D^n O^t$$

E) $\mathbf{X} \sim N(\vec{m}, V)$ V es simétrica y definida positiva $\in M_n$

$$V = U U^t, \quad U \in M_n \quad (U = R^t)$$

no singular

$$V^{-1} = (U^{-1})^t U^{-1}$$

En la exponencial de la normal aparece:

$$\begin{aligned} (\vec{x} - \vec{m})^t \cdot V^{-1} \cdot (\vec{x} - \vec{m}) &= (\vec{x} - \vec{m})^t (U^{-1})^t \cdot U^{-1} (\vec{x} - \vec{m}) = \\ &= \|U^{-1}(\vec{x} - \vec{m})\|^2 \end{aligned}$$

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(\sqrt{2\pi})^n} \cdot \frac{1}{|\det(U)|} \cdot \exp\left(-\frac{1}{2} \|U^{-1}(\vec{x} - \vec{m})\|^2\right)$$

$$\int_{\mathbb{R}^n} f_{\mathbf{X}}(\mathbf{x}) dx_1 \dots dx_n = \boxed{\begin{array}{l} \text{cambio de variables} \\ \vec{y} = U^{-1}(\vec{x} - \vec{m}) \\ \vec{x} = \vec{m} + U\vec{y} \end{array}} =$$

$$= \frac{1}{(\sqrt{2\pi})^n} \int_{\mathbb{R}^n} \overbrace{\frac{|\det(U)|}{|\det(U)|}}^{|\mathbf{J}|} \cdot \exp\left(-\frac{1}{2} \|\mathbf{y}\|^2\right) =$$

$$= \int_{\mathbb{R}^n} \left(\frac{1}{\sqrt{2\pi}} e^{-y_1^2/2} \right) \dots \left(\frac{1}{\sqrt{2\pi}} e^{-y_n^2/2} \right) = 1$$

F) Si $X \sim N(\vec{m}, V)$

Definimos $Y = U^{-1}(X - \vec{m}) \sim N(\vec{0}, I_n)$

Mismo argumento que en el apartado E)

Por tanto: $X = \vec{m} + U \underset{\substack{\uparrow \\ \text{normal estándar}}}{Y}$

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

G) TEOREMA: Si $X \sim N(\vec{m}, V)$, entonces $E(X) = \begin{pmatrix} E(x_1) \\ \vdots \\ E(x_n) \end{pmatrix} = \vec{m}$,
 $\text{cov}(X) = V$. Además para $1 \leq j \leq n$, la coordenada $X_j \sim N(m_j, V_{jj})$
 $\xrightarrow{\text{elemento } V_{jj} \text{ de } V}$

demostración

• ¿ $\vec{m} = E(X)$?

Usamos que si $X \sim N(\vec{m}, V) \rightarrow X = \vec{m} + U \underset{\substack{\uparrow \\ \text{normal estándar}}}{Y}$

$$Y \sim N(\vec{0}, I_n) \quad E(Y) = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$I_n = \text{cov}(Y) = E(YY^t) = E((y_i, y_j))$$

$$\left. \begin{array}{l} \text{si } i=j: E((y_i)^2) = \underset{1}{V}(y_i) + \underset{0^2}{E(y_i)^2} = 1 \\ \text{si } i \neq j: E((y_i, y_j)) = \underset{0}{E(y_i)} \cdot \underset{0}{E(y_j)} = 0 \end{array} \right\} \Rightarrow E(YY^t) = \underset{\substack{\text{matriz que en} \\ (i,j) \text{ tiene } (y_i, y_j)}}{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}$$

$$X = \vec{m} + UY$$

$$E(X) = \vec{m} + E(UY) = \vec{m} + U \underset{\substack{\uparrow \\ \vec{0}}}{E(Y)} = \vec{m}$$

$$\underset{U}{\begin{pmatrix} a & b \\ c & d \end{pmatrix}} \underset{Y}{\begin{pmatrix} y_1 \\ y_2 \end{pmatrix}} = \begin{pmatrix} ay_1 + by_2 \\ cy_1 + dy_2 \end{pmatrix}$$

$$\underset{U}{\begin{pmatrix} a & b \\ c & d \end{pmatrix}} \underset{E(Y)}{\begin{pmatrix} E(y_1) \\ E(y_2) \end{pmatrix}} = \begin{pmatrix} aE(y_1) + bE(y_2) \\ cE(y_1) + dE(y_2) \end{pmatrix}$$

• ¿ $\text{cov}(X) = V$?

$$\text{cov}(X) = (\text{cov}(X_i, X_j)) = (E(X_i - m_i)(X_j - m_j)) = E((X - \vec{m})(X - \vec{m})^t) =$$

$$\xrightarrow{\substack{\uparrow \\ = \vec{m} + UY}} E(UY(UY)^t) = E(UY \underset{\substack{\uparrow \\ \text{cov}(Y) = I_n}}{Y^t} U^t) = U \underset{\substack{\uparrow \\ \text{cov}(Y) = I_n}}{E(YY^t)} U^t = UU^t = V$$

\hookrightarrow normal estándar

• ¿ $X_j \sim N(m_j, V_{jj})$?

De $X = \vec{m} + UY$ sacamos que $X_j = m_j +$ combinación lineal de Y_1, \dots, Y_n

Recordar que $\begin{cases} Z_1, Z_2 \text{ son normales independientes} \\ a_1 Z_1 + a_2 Z_2 \text{ es normal } a_1, a_2 \in \mathbb{R} \end{cases}$

$\Rightarrow X_j = m_j +$ combinación lineal de Y_1, \dots, Y_n es una variable normal

$$\vec{m} = E(X) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_n) \end{pmatrix} \Rightarrow m_j = E(X_j)$$

$$\text{cov}(X) = V$$

$$\begin{pmatrix} V(X_1) & \dots & \text{cov}(X_i, X_j) \\ \vdots & \ddots & \vdots \\ V(X_n) \end{pmatrix} \Rightarrow V(X_j) = V_{jj}$$

$$V = UU^t$$

$$X = \vec{m} + UY$$

$$\vec{z} = \vec{r} + B(\vec{m} + UY) = \vec{r} + B\vec{m} + BU Y$$

H) Sea $X \sim N(\vec{m}, V)$. Además $\vec{h} \in \mathbb{R}^n$ y $B \in M_n$ no singular

Entonces $Z = \vec{h} + BX$. ¿qué distribución tiene Z ?

$$\hookrightarrow Z \sim N(_, _)$$

$$Z = \vec{h} + B(\vec{m} + UY) = (\vec{h} + B\vec{m}) + BU Y \Rightarrow Z \sim N(\vec{h} + B\vec{m}, (BU)(BU)^t)$$

$$\Rightarrow Z \sim N(\vec{h} + B\vec{m}, BUU^t B^t) \Rightarrow Z \sim N(\vec{h} + B\vec{m}, BV B^t)$$

$$I) \Psi \text{ es } N(\vec{0}, I_n) \quad \left\{ \begin{array}{l} O\Psi \\ \vec{m} = \vec{0} \\ \vec{r} = \vec{0} \end{array} \right. \quad \begin{array}{l} V = I_n \\ B = 0 \end{array}$$

O es matriz ortogonal $n \times n$

$$\Rightarrow O\Psi \sim N(\vec{0}, I_n)$$

$$\underbrace{O \underbrace{V}_{I_n} O^t}_{I_n} = I_n \text{ porque } O \text{ ortogonal}$$

Conclusión, si O matriz ortogonal y Ψ normal estándar \Rightarrow
 $\Rightarrow O\Psi$ normal estándar

$$J) X \sim N(\vec{m}, V) \quad , \quad \vec{a} \in \mathbb{R}^n \text{ y } \vec{a} \neq \vec{0}$$

$\sum_{i=1}^n a_i x_i$, esto ya no es un vector aleatorio, es una variable aleatoria

$$\sum_{i=1}^n a_i x_i \sim N(,)$$

Lo siguiente: $\left[\begin{array}{l} X_1, \dots, X_n \text{ son variables normales } X_j \sim N(m_j, \sigma_j^2) \\ \text{entonces } \sum a_i x_j \text{ es normal} \end{array} \right]$

es FALSO. Sólo sería verdadero si $X_j \forall j$ son variables INDEPENDIENTES

$$\sum_{i=1}^n a_i x_i = \vec{a}^t X = \vec{a}^t (\vec{m} + V\Psi) = \underbrace{\vec{a}^t \vec{m}}_{\mathbb{R}} + \underbrace{(\vec{a}^t V)}_{\text{vector fila} = \vec{b}^t} \Psi =$$

$$= \vec{a}^t \vec{m} + \sum_{j=1}^n b_j \Psi_j$$

$$\Rightarrow \sum_{i=1}^n a_i x_i = \vec{a}^t X \sim N\left(\underbrace{\vec{a}^t \vec{m}}_{\mathbb{R}}, \underbrace{\vec{a}^t V \vec{a}}_{\mathbb{R}^+}\right)$$

DISTRIBUCIONES ASOCIADAS A VECTORES NORMALES

(A) χ_n^2 chi-cuadrado con n grados de libertad.

(B) $F_{n,m}$ distribución F con n, m grados

(C) t_n distribución t de Student con n grados.

A) Partimos de $\mathbf{X} \sim N(\vec{0}, I_n)$, y sea $Z = \|\mathbf{X}\|^2 = \sum_{i=1}^n x_i^2$
 $\xrightarrow{\text{vector de independientes}}$
Decimos que $Z = \chi_n^2 \xrightarrow{\text{grados de libertad}}$

$$1. E(Z) = \sum_{i=1}^n E(x_i^2) = n$$

$$2. V(Z) = \sum_{i=1}^n V(x_i^2) = 2n$$

\uparrow
independientes

otra manera de calcular $V(Z)$

$$V(Z) = E(Z^2) - E(Z)^2$$

\uparrow
 χ_n^2

$$Z = x_1^2 + \dots + x_n^2$$

$$Z^2 = \sum_{j=1}^n x_j^4 + \sum_{i \neq j} x_i^2 x_j^2$$

$$E(Z^2) = \sum_{j=1}^n E(x_j^4) + \sum_{i \neq j} E(x_i^2 x_j^2) =$$

$$= 3n + \sum_{i \neq j} \underbrace{E(x_i^2) E(x_j^2)}_{\text{independientes}} = 3n + n(n-1) = n^2 + 2n$$

$$\Rightarrow V(Z) = E(Z^2) - E(Z)^2 = n^2 + 2n - n^2 = 2n$$

RECUERDO

$$X \sim N(0, 1)$$

$$E(X) = 0 \quad E(X^2) = 1$$

$$1 = V(X) = E(X^2) - E(X)^2$$

OBSERVACIÓN

$$X \sim N(0, 1)$$

$$E(X) = 0 \quad V(X) = E(X^2)$$

$$V(X^2) = E(X^4) - E(X^2)^2$$

$$E(X^4) = \int_{\mathbb{R}} \underbrace{x^4}_{\text{valores}} \cdot \underbrace{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}_{\text{prob}} dx =$$

por partes
 \downarrow

$$= \int x^3 \left(\frac{x}{\sqrt{2\pi}} e^{-x^2/2} \right) dx = 3$$

$$\Rightarrow V(X^2) = \underbrace{E(X^4)}_3 - \underbrace{E(X^2)^2}_1 = 2$$

Caso $n=1$: función de densidad

$$Z = X^2$$

$$X \sim N(0,1)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

$Z = h(X)$ con $h(x) = x^2$ pero esta NO ES BIYECTIVA

Cuidado, h no es biyectiva

Sacamos la función de distribución:

$$P(Z \leq z) = P(X^2 \leq z) = P(-\sqrt{z} \leq X \leq \sqrt{z}) =$$

$$= P(X \leq \sqrt{z}) - P(X \leq -\sqrt{z})$$

$$f_Z(z) = \frac{d}{dz} P(Z \leq z) = \frac{d}{dz} P(X \leq \sqrt{z}) - \frac{d}{dz} P(X \leq -\sqrt{z}) =$$

$$= \frac{1}{2\sqrt{z}} \cdot \frac{1}{\sqrt{2\pi}} e^{-z/2} + \frac{1}{2\sqrt{z}} \cdot \frac{1}{\sqrt{2\pi}} e^{-z/2} = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sqrt{z}} e^{-z/2} =$$

$$= \frac{1}{\sqrt{2\pi}} \cdot z^{1/2-1} \cdot e^{-z/2} = \text{Gamma}\left(\frac{1}{2}, \frac{1}{2}\right) \quad \text{para } z > 0$$

$$P(Z \leq z) = 0 \quad \text{para } z < 0 \quad (\text{porque } P(Z \leq z) = P(X^2 \leq z) \geq 0)$$

LEMA: $Z = X^2$ con $X \sim N(0,1) \Rightarrow Z \sim \text{Gamma}\left(\frac{1}{2}, \frac{1}{2}\right)$

Recordatorio

$U \sim \text{Gamma}(\lambda, t)$ significa

$$f_U(x) = \frac{1}{\Gamma(t)} \cdot (\lambda x)^t \cdot e^{-\lambda x} \cdot \frac{1}{x}$$

$$U \sim \text{Gamma}(\lambda, t)$$

$$V \sim \text{Gamma}(\lambda, s)$$

U, V independ. $\Rightarrow U + V \sim \text{Gamma}(\lambda, s+t)$

RECUERDO

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$$

$$Z = \|\mathbf{X}\|^2 = X_1^2 + \dots + X_n^2 \quad \text{decimos que es } \chi_n^2$$

$$\left\{ \begin{array}{l} \mathbb{E}(Z) = n \\ \text{Var}(Z) = 2n \end{array} \right.$$

$N(\vec{0}, I_n)$, que es lo mismo que decir que $X_1, \dots, X_n \sim N(0, 1)$

(1) $n=1$ Z es χ_1^2 entonces: Z es $\text{Gamma}(\frac{1}{2}, \frac{1}{2})$

(2) Recordar adem s que si $\left\{ \begin{array}{l} U \text{ es } \text{Gamma}(\lambda, t) \\ V \text{ es } \text{Gamma}(\lambda, s) \end{array} \right. \Rightarrow U+V \text{ es } \text{Gamma}(\lambda, t+s)$
| independientes!

Usando (1) y (2):

Si Z es χ_n^2 entonces $Z = X_1^2 + \dots + X_n^2$ es $\text{Gamma}(\frac{1}{2}, \frac{n}{2})$
 $\uparrow \quad \uparrow \quad \uparrow$
 $\text{Gamma}(\frac{1}{2}, \frac{1}{2}) \quad \text{independientes} \quad \text{Gamma}(\frac{1}{2}, \frac{1}{2})$

Recordar que W es $\text{Gamma}(\lambda, t) \Rightarrow f_W(x) = \frac{1}{\Gamma(t)} (\lambda x)^t e^{-\lambda x} \cdot \frac{1}{x}$

donde $\Gamma(s) = \int_0^\infty y^{s-1} e^{-y} dy \quad \underline{s > 0} \quad \Gamma(s+1) = s \Gamma(s) \quad \underline{s > 0}$

LEMA: Z es χ_n^2 y $\alpha \in \mathbb{R}$ tal que $\left| \frac{n}{2} + \alpha > 0 \right|$,
 entonces $\mathbb{E}(Z^\alpha) = 2^\alpha \frac{\Gamma(\frac{n}{2} + \alpha)}{\Gamma(\frac{n}{2})}$

$$\mathbb{E}(Z^\alpha) = \int_0^\infty \underbrace{x^\alpha}_{\text{valores}} \cdot \underbrace{f_Z(x)}_{\text{prob.}} dx = \frac{1}{\Gamma(\frac{n}{2})} \int_0^\infty x^\alpha \cdot \left(\frac{1}{2}\right)^{n/2} x^{n/2} \cdot e^{-x/2} \cdot \frac{1}{x} dx =$$

suma de cuadrados $(-\infty, 0) = 0$

$$= \left(\frac{1}{2}\right)^{n/2} \frac{1}{\Gamma(\frac{n}{2})} \int_0^\infty x^{\alpha+n/2} e^{-x/2} \cdot \frac{1}{x} dx$$

cambio de variable

$$= \frac{2^{n/2+\alpha}}{2^{n/2} \Gamma(\frac{n}{2})} \int_0^\infty y^{\alpha+n/2} e^{-y} \frac{dy}{y} =$$

$$= 2^\alpha \frac{\Gamma(\frac{n}{2} + \alpha)}{\Gamma(\frac{n}{2})}$$

CASOS PARTICULARES.

- $\alpha = 0 \rightarrow \mathbb{E}(Z^0) = 1$

- $\alpha = 1 \rightarrow n = \mathbb{E}(Z) = 2 \frac{\Gamma(\frac{n}{2} + 1)}{\Gamma(\frac{n}{2})} = 2 \frac{\frac{n}{2} \Gamma(\frac{n}{2})}{\Gamma(\frac{n}{2})} = n$

- $\alpha = -1 \rightarrow \mathbb{E}\left(\frac{1}{Z}\right) = \frac{1}{2} \cdot \frac{\Gamma(\frac{n}{2} - 1)}{\Gamma(\frac{n}{2})} = \frac{1}{2} \cdot \frac{\Gamma(\frac{n}{2} - 1)}{(\frac{n}{2} - 1) \Gamma(\frac{n}{2} - 1)} = \frac{1}{n - 2}$

- $\alpha = \frac{1}{2} \rightarrow \mathbb{E}(\sqrt{Z}) = \sqrt{2} \frac{\Gamma(\frac{n}{2} + \frac{1}{2})}{\Gamma(\frac{n}{2})}$

↳ caso particular de $\alpha = \frac{1}{2}$

$n = 2 \rightarrow \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$

$\sqrt{Z} = \sqrt{X_1^2 + X_2^2} = \text{distancia al origen}$

Z es χ^2_2

$\mathbb{E}(\text{distancia al origen}) = \mathbb{E}(\sqrt{Z}) =$

$= \sqrt{2} \frac{\Gamma(3/2)}{\Gamma(1)} = \frac{\sqrt{2} \cdot \frac{1}{2} \Gamma(1/2)}{1} = \frac{\sqrt{2} \cdot \frac{1}{2} \cdot \sqrt{\pi}}{1} = \sqrt{\frac{\pi}{2}}$

B) Z es $F_{n,m}$ si $Z = \frac{U/n}{V/m}$ U es χ^2_n independientes
 $\uparrow \uparrow$
 grados de libertad V es χ^2_m

$\mathbb{E}(Z) = \mathbb{E}\left(\frac{U}{n}\right) \cdot \underbrace{\mathbb{E}\left(\frac{m}{V}\right)}_{\mathbb{E}\left(\frac{1}{\frac{V}{m}}\right)} = 1 \cdot \frac{m}{m-2} = \frac{m}{m-2}$

$V(Z) = \mathbb{E}(Z^2) - \overbrace{\mathbb{E}(Z)^2}^{\text{conocido}}$

$\mathbb{E}(Z^2) = \mathbb{E}\left(\frac{U^2}{n^2}\right) \cdot \mathbb{E}\left(\frac{m^2}{V^2}\right) =$

$V(U) = 2n$

$\mathbb{E}(U^2) = \mathbb{E}(U)^2 + \underbrace{V(U)}_{= 2n}$

↳ Lema anterior con $\alpha = -2$

$\Rightarrow V(Z) = \frac{2(m+n-2)m^2}{n(m-4)(m-2)^2}$

C) $t_n \rightarrow t$ de Student con n -grados de libertad

Z es t_n significa $Z = \frac{Y}{\sqrt{U_n/n}} \xrightarrow{\substack{Y \rightarrow N(0,1) \\ U_n/n \rightarrow \chi_n^2 \text{ independientes}}} (n \geq 2)$

$E(Z) = 0$ porque $E(Y) = 0$

$$E(Z) = \underbrace{E(Y)}_0 \cdot E\left(\frac{1}{\sqrt{U_n/n}}\right) = 0$$

$$V(Z) = E(Z^2) - \underbrace{E(Z)^2}_0$$

$$E(Z^2) = \underbrace{E(Y^2)}_1 \cdot \underbrace{E\left(\frac{n}{U_n}\right)}_{\frac{n}{n-2}} = \frac{n}{n-2}$$

$$\Rightarrow V(Z) = \frac{n}{n-2}$$

NOTA: Cuando $n \rightarrow \infty$, $t_n \rightarrow N(0,1)$

$$\text{Idea: } \frac{U_n}{n} ; E\left(\frac{U_n}{n}\right) = 1 ; V\left(\frac{U_n}{n}\right) = \frac{2n}{n^2} = \frac{2}{n}$$

Esto dice que $\frac{U_n}{n}$ (para n enorme) muy próximo a 1.

MODELO TEÓRICO DE MUESTREO ALEATORIO

X es variable aleatoria

$\underbrace{X_1, \dots, X_n}_{\text{independientes}} \longrightarrow \text{clones de } X \quad (X_j \stackrel{d}{=} X \quad 1 \leq j \leq n)$

Modelo de muestreo aleatorio de X .

Estadístico $H: \mathbb{R}^n \longrightarrow \mathbb{R}$ (determinista)

$$T = H(X_1, \dots, X_n)$$

T es estadístico asociado a H .

T es variable aleatoria

Cada T es un resumen de la muestra (X_1, \dots, X_n)

Ejemplos de estadísticos

1) $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$ media muestral

2) $S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$ cuasivarianza muestral

3) $\begin{cases} \max(X_1, \dots, X_n) \\ \min(X_1, \dots, X_n) \end{cases}$

4) Estadístico de orden

\hookrightarrow de orden r : se ordena la muestra y se coge el valor de la posición r .

Ejemplo

$n=3$

$$X \sim \text{Ber}(p)$$

$$0 < p < 1$$

valores	probabilidades
0/3	$(1-p)^3$
1/3	$3p(1-p)^2$
2/3	$3p^2(1-p)$
3/3	p^3

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

• ¿ \bar{x} ?

$$\bar{x} = \frac{x_1 + x_2 + x_3}{3}$$

↓
variable aleatoria

$$\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \rightarrow (1-p)^3$$

$$\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \rightarrow p(1-p)^2$$

• ¿ $\max(x_1, x_2, x_3)$?

$$\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \rightarrow p^3$$

$\max(x_1, x_2, x_3)$

valores	probabilidades
0	$(1-p)^3$
1	$1 - (1-p)^3$

• ¿ $\min(x_1, x_2, x_3)$?

$\min(x_1, x_2, x_3)$

valores	probabilidades
0	$1 - p^3$
1	p^3

• ¿ S^2 ?

distribución de S^2

$$\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \rightarrow \bar{x} = 0 \quad y \quad S^2 = 0$$

$$\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \rightarrow \bar{x} = 1/3 \quad y \quad S^2 = \frac{1}{2} \left((1-1/3)^2 + (0-1/3)^2 + (0-1/3)^2 \right) = 1/3$$

$$= \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \rightarrow \bar{x} = 2/3 \quad y \quad S^2 = \frac{1}{2} \left((1-2/3)^2 + (1-2/3)^2 + (0-2/3)^2 \right) = 1/3$$

$$\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \rightarrow \bar{x} = 1 \quad y \quad S^2 = 0$$

valores	probabilidades
0	$p^3 + (1-p)^3$
1/3	$1 - p^3 - (1-p)^3$

• ¿ $E(S^2)$?

$L_D =$

= valores · probabilidad :

$$= \frac{1}{3} (1 - p^3 - (1-p)^3) + 0$$

• ESTUDIO DE \bar{X}

X variable aleatoria

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}$$

X_1, \dots, X_n clones independientes

Proposición: $\mathbb{E}(\bar{X})$

$$\mathbb{E}(\bar{X}) = \mathbb{E}(X) \quad \text{para cualquier } X.$$

demostración

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \mathbb{E}(X_1 + \dots + X_n) = \frac{1}{n} (n \mathbb{E}(X)) = \mathbb{E}(X)$$

← clones de X (misma distribución)

Proposición: $V(\bar{X})$

$$V(\bar{X}) = \frac{1}{n} V(X) \quad \text{para cualquier } X.$$

demostración

$$\begin{aligned} V(\bar{X}) &= V\left(\frac{1}{n}(X_1 + \dots + X_n)\right) = \frac{1}{n^2} V(X_1 + \dots + X_n) = \\ &= \frac{1}{n^2} (V(X_1) + \dots + V(X_n)) = \frac{1}{n^2} (n V(X)) = \frac{1}{n} V(X) \end{aligned}$$

← independientes

DISTRIBUCIÓN EXACTA DE \bar{X}

A veces (raramente) podemos escribir la distribución de probabilidad de \bar{X} .

Ejemplo: $X \sim \text{Ber}(p)$ X_1, \dots, X_n son $\text{Ber}(p)$

$$n\bar{X} = X_1 + \dots + X_n \sim \text{Bin}(n, p)$$

$n\bar{X}$ toma valores $0, \dots, n$.

$$P\left(\bar{X} = \frac{k}{n}\right) = P(n\bar{X} = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad 0 \leq k \leq n$$

Ejemplo: $X \sim \text{Poisson}(\lambda)$

$$P(X=k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!} \quad k \text{ entero } \geq 0.$$

↓ X, Y son indep.

$$X \sim \text{Poisson}(\lambda)$$

$$Y \sim \text{Poisson}(\mu)$$

$$\Rightarrow X+Y \sim \text{Poisson}(\lambda+\mu)$$

$$X_1, \dots, X_n \sim \text{Poisson}(\lambda)$$

$$n\bar{X} = X_1 + \dots + X_n \sim \text{Poisson}(n\lambda)$$

$n\bar{X}$ toma valores $0, 1, 2, \dots$

\bar{X} toma valores $\frac{0}{n}, \frac{1}{n}, \frac{2}{n}, \dots$

$$P(\bar{X} = \frac{k}{n}) = P(n\bar{X} = k) = e^{-n\lambda} \cdot \frac{(n\lambda)^k}{k!} \quad 0 \leq k \text{ entero}$$

Ejemplo: $X \sim N(\mu, \sigma^2)$

X_1, \dots, X_n clones independientes

$$X_1 + \dots + X_n \text{ es } N(n\mu, n\sigma^2)$$

$$\frac{X_1 + \dots + X_n}{n} \text{ es } N\left(\underset{\text{E}(X)}{\mu}, \underset{\frac{V(X)}{n}}{\frac{\sigma^2}{n}}\right)$$

$$\sqrt{X \sim N(\mu, \sigma^2)}$$

$$Y \sim N(\delta, \eta^2) \text{ independ.}$$

$$\Rightarrow X+Y \sim$$

$$\sim N(\mu+\delta, \sigma^2+\eta^2)$$

DISTRIBUCIÓN APROXIMADA

1) CHEBYSHEV para \bar{X} :

Variable aleatoria Y
Desigualdad de Chebyshev:

$$\mathbb{P}(|Y - \mathbb{E}(Y)| \geq \lambda) \leq \frac{\mathbb{V}(Y)}{\lambda^2}$$

Aplicado a $\bar{X} = \frac{1}{n}(x_1 + \dots + x_n)$ donde x_1, \dots, x_n son clones de X

$$\mathbb{P}(|\bar{X} - \mathbb{E}(\bar{X})| \geq \lambda) \leq \frac{\mathbb{V}(\bar{X})}{\lambda^2}$$

es decir,

$$\mathbb{P}(|\bar{X} - \mathbb{E}(X)| \geq \lambda) \leq \frac{\mathbb{V}(X)}{n\lambda^2}$$

Si $\mathbb{V}(X) = 1000$ y
 $\lambda = 0.01$ (error que quieres)

$$\Rightarrow \frac{\mathbb{V}(X)}{\lambda^2} = 10^6$$

2) TEOREMA CENTRAL DEL LÍMITE

X clones de X independientes

$$X_1 + \dots + X_n \xrightarrow[n \rightarrow \infty]{d} N(n\mathbb{E}(X), n\mathbb{V}(X))$$

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \xrightarrow[n \rightarrow \infty]{d} N\left(\mathbb{E}(X), \frac{\mathbb{V}(X)}{n}\right)$$

$$\bar{X} - \mathbb{E}(X) \xrightarrow[n \rightarrow \infty]{d} N\left(0, \frac{\mathbb{V}(X)}{n}\right)$$

Lo escribimos como: (reescritura TCL)

$$\sqrt{n}(\bar{X} - \mathbb{E}(X)) \xrightarrow[n \rightarrow \infty]{d} N(0, \mathbb{V}(X))$$

Única hipótesis para esto:

$\mathbb{E}(X^2) < +\infty$
(que exista la media y la varianza)

• ESTUDIO DE S^2

X x_1, \dots, x_n clones de X independientes

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Expresiones alternativas de S^2 : $(E(x^2) - E(x)^2)$

$$\frac{S^2(n-1)}{n} = \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$$

$$\bar{x} = \frac{1}{n} (x_1 + \dots + x_n)$$

$$\bar{x}^2 = \frac{1}{n^2} \left(\underbrace{\sum_{j=1}^n x_j^2}_n + \underbrace{\sum_{i \neq j}^n x_i x_j}_{n(n-1)} \right)$$

$$\Rightarrow (n-1)S^2 = \sum x_j^2 - n \left(\frac{1}{n^2} \sum x_j^2 + \frac{1}{n^2} \sum_{i \neq j} x_i x_j \right) \Rightarrow$$

$$\Rightarrow \boxed{n(n-1)S^2 = (n-1) \sum_{j=1}^n x_j^2 - \sum_{i \neq j} x_i x_j}$$

PROPOSICIÓN: $E(S^2)$

$E(S^2) = V(X)$ para cualquier X .

demostración

$$n(n-1)E(S^2) = (n-1)nE(x^2) - \sum_{i \neq j} \overbrace{E(x_i x_j)}^{E(x_i)E(x_j) \text{ por independencia e } i \neq j} =$$

$$= (n-1)nE(x^2) - n(n-1)E(x)^2 \Rightarrow E(S^2) = E(x^2) - E(x)^2 \Rightarrow$$

$$\Rightarrow E(S^2) = V(X)$$

$$V(S^2) = \underbrace{E((S^2)^2)} - [E(S^2)]^2 = V(X)$$

TRUQUE: hacer primero el caso tipificado

Suponemos primero $E(X) = 0$ y $V(X) = 1$
Luego hacemos el caso general con un cambio lineal de variable.

PROPOSICIÓN: Si X es tipificada:

$$V(S^2) = \frac{1}{n} E(X^4) - \frac{n-3}{n(n-1)}$$

Cálculo de $E((S^2)^2)$ con X tipificada:

$$E((S^2)^2)$$

$$n^2(n-1)^2 E((S^2)^2) = E\left(\left(\underbrace{(n-1) \sum_{j=1}^n X_j^2}_A - \underbrace{\sum_{i \neq j} X_i X_j}_B\right)^2\right)$$

A: n sumandos B: n(n-1) sumandos

$$AA = \underbrace{\sum_{j=1}^n X_j^4}_{n E(X^4)} + \underbrace{\sum_{i \neq j} X_i^2 X_j^2}_{n(n-1)} = n E(X^4) + n(n-1)$$

= $E(X^2)E(X^2) = 1 \cdot 1$ sumado $n(n-1)$ veces

$$AB \rightarrow \text{términos } \underbrace{X_k^3 X_j}_{E(X^3)E(X)} \quad k \neq j \quad \text{o} \quad \underbrace{X_k^2 X_i X_j}_{E(X^2)E(X)E(X)} \quad \text{con } k \neq i \neq j$$

$$AB = 0$$

$$BB \rightarrow \text{términos } \begin{cases} X_i X_j X_k X_l & \text{si } i \neq j \neq k \neq l = 0 \\ X_i X_j X_k X_l & \text{si } i \neq j, k \neq l, \text{ dos iguales} = 0 \\ X_i X_j X_i X_j & i \neq j = E(X_i X_j X_i X_j) = E(X_i^2)E(X_j^2) = 1 \end{cases}$$

se suma $2n(n-1)$ veces

$$BB = 2n(n-1)$$

$$\Rightarrow E\left((n-1) \sum_{j=1}^n X_j^2 - \sum_{i \neq j} X_i X_j\right)^2 = (n-1)^2 \left(n E(X^4) + n(n-1)\right) + 2n(n-1)$$

Ahora destipificamos:

X variable aleatoria X_1, \dots, X_n clones independientes
 \sqrt{n} v.a.
 $Y = \frac{\bar{X} - \mathbb{E}(X)}{\sqrt{V(X)}} \leftarrow n^2$ transformación lineal

$$\mathbb{E}(Y) = 0 \quad V(Y) = 1$$

$$\bar{Y} = \frac{\bar{X} - \mathbb{E}(X)}{\sqrt{V(X)}}$$

$$S_Y^2 = \frac{1}{n-1} \sum (Y_i - \bar{Y})^2 = \frac{1}{n-1} \sum \frac{(X_i - \bar{X})^2}{V(X)} = \frac{1}{V(X)} S_X^2$$

Sabemos: $V(S_Y^2) = \frac{1}{n} \mathbb{E}(Y^4) - \frac{n-3}{n(n-1)}$

$$\Rightarrow V(S_Y^2) = V\left(\frac{1}{V(X)} \cdot S_X^2\right) = \frac{V(S_X^2)}{V(X)^2}$$

$$\Rightarrow \frac{1}{n} \mathbb{E}(Y^4) - \frac{n-3}{n(n-1)} = \frac{1}{n} \mathbb{E}\left(\frac{(X - \mathbb{E}(X))^4}{V(X)^2}\right) - \frac{n-3}{n(n-1)} =$$

$$= \frac{1}{n} \cdot \frac{\mathbb{E}((X - \mathbb{E}(X))^4)}{V(X)^2} - \frac{n-3}{n(n-1)}$$

$$\Rightarrow V(S_X^2) = \frac{1}{n} \mathbb{E}((X - \mathbb{E}(X))^4) - \frac{n-3}{n(n-1)} V(X)^2$$

Chebyshev para S^2

Estimación de dispersión de S^2

$$\sqrt{\mathbb{P}(|Z - \mathbb{E}(Z)| > \lambda)} \leq \frac{\sqrt{V(Z)}}{\lambda^2} \uparrow$$

$$\mathbb{P}(|S^2 - V(X)| > \lambda) \leq \frac{V(S^2)}{\lambda^2} \leq \frac{1}{\lambda^2} \cdot \frac{1}{n} \mathbb{E}((X - \mathbb{E}(X))^4)$$

\bar{X}, S^2 para variables normales, solo NORMALES

TEOREMA (Fisher-Cochran)

$X \sim N(0,1)$ X_1, \dots, X_n clones independientes

Calculamos los estadísticos \bar{X}, S^2 .

1) $\bar{X} \sim N(0, \frac{1}{n})$

2) $(n-1)S^2 \sim \chi^2_{\frac{n-1}{1} \rightarrow \text{grados de libertad}}$

3) \bar{X} y S^2 son independientes

Analizamos caso $n=2$:

$$\bar{X} = \frac{1}{2}(X_1 + X_2)$$

$$S^2 = \frac{1}{2-1} \left(\underbrace{(X_1 - \bar{X})^2}_{\rightarrow X_1 - \bar{X} = X_1 - \frac{1}{2}(X_1 + X_2) = \frac{1}{2}(X_1 - X_2)} + \underbrace{(X_2 - \bar{X})^2}_{\rightarrow X_2 - \bar{X} = X_2 - \frac{1}{2}(X_1 + X_2) = \frac{1}{2}(X_2 - X_1)} \right) = \frac{1}{2}(X_1 - X_2)^2$$

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N(\vec{0}, I_2)$$

$$\begin{pmatrix} X_1 + X_2 \\ X_1 - X_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

$$\downarrow N(\vec{0}, I_2)$$

$$\uparrow \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \begin{pmatrix} \frac{X_1 + X_2}{\sqrt{2}} \\ \frac{X_1 - X_2}{\sqrt{2}} \end{pmatrix}$$

Recordar que si X es $N(\vec{0}, I_n)$ y O es matriz ortogonal $\Rightarrow OX$ es $N(\vec{0}, I_n)$. Además, debemos recordar que si

X es $N(\vec{0}, I_n) \iff X_1, \dots, X_n$ es $N(0,1)$ independientes

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix} \Rightarrow (X_1 + X_2) \text{ y } (X_1 - X_2) \text{ son independientes}$$

demostración

Consideremos una matriz $A = \begin{pmatrix} \frac{x_1}{\sqrt{n}} & \dots & \frac{x_n}{\sqrt{n}} \end{pmatrix}$ y A ortogonal.

Rellenamos el resto de las filas de la matriz con el método de Gram-Schmidt.

$$\begin{matrix} Z \\ \parallel \\ \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix} \end{matrix} = A \begin{matrix} X \\ \parallel \\ \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \end{matrix}$$

a) $z_1 = \sqrt{n} \bar{x}$ \swarrow A es ortogonal

b) $\|z\|^2 \equiv \|X\|^2 = \sum_{j=1}^n x_j^2$

$$\left. \begin{aligned} \sum_{j=1}^n z_j^2 &= n\bar{x}^2 + \sum_{j=2}^n z_j^2 \\ &\quad \uparrow \text{por (a)} \end{aligned} \right\} \Rightarrow$$

$$\Rightarrow \sum_{j=1}^n x_j^2 - n\bar{x}^2 = \sum_{j=2}^n z_j^2$$

1) z_1 es $N(0,1) \Rightarrow \bar{x}$ es $N(0, \frac{1}{n})$

2) $\sum_{j=2}^n z_j^2$ es χ_{n-1}^2

recordar apuntes anteriores

$$\sum_{j=1}^n x_j^2 - n\bar{x}^2 = (n-1)S^2 ; (n-1)S^2 \text{ es } \chi_{n-1}^2$$

3) \bar{x} viene de z_1 ($\bar{x} \leftarrow z_1$)
 S^2 viene de z_2, \dots, z_n ($S^2 \leftarrow z_2, \dots, z_n$)

$$\left. \begin{aligned} &\bar{x} \text{ y } S^2 \text{ son} \\ &\text{independientes} \end{aligned} \right\} \Rightarrow$$

COROLARIO: $X \sim N(0,1)$

X_1, \dots, X_n son clones independientes

$\frac{\bar{X}}{(\sqrt{S^2}/\sqrt{n})}$ es t_{n-1} (t de Student con n-1 grados)

demonstración

$$\frac{\bar{X}}{(\sqrt{S^2}/\sqrt{n})} = \frac{\sqrt{n} \bar{X}}{\sqrt{\frac{(n-1)S^2}{n-1}}} \begin{matrix} \nearrow \sim N(0,1) \\ \downarrow \text{independientes} \\ \rightarrow \chi_{n-1}^2 \end{matrix}$$

COROLARIO: $X \sim N(\mu, \sigma^2)$

X_1, \dots, X_n son clones independientes

$$Y = \frac{X - \mu}{\sigma}$$

$$\bar{Y} = \frac{\bar{X} - \mu}{\sigma} \Rightarrow \bar{X} = \mu + \sigma \bar{Y}$$

$$S_Y^2 = \frac{1}{\sigma^2} S_X^2 \Rightarrow S_X^2 = \sigma^2 S_Y^2$$

\bar{Y} es $N(0, 1/n) \Rightarrow \bar{X}$ es $N(\mu, \frac{\sigma^2}{n})$ $\swarrow \searrow$ independientes

$(n-1)S_Y^2$ es $\chi_{n-1}^2 \Rightarrow (n-1)\frac{S_X^2}{\sigma^2}$ es χ_{n-1}^2

1) \bar{X} es $N(\mu, \frac{\sigma^2}{n})$

2) $(n-1)\frac{S_X^2}{\sigma^2}$ es χ_{n-1}^2

3) \bar{X} y S_X^2 son independientes


Ejemplo/ejercicio: (x_1, \dots, x_{100}) muestra aleatoria de normal con $\mu=3$ y $\sigma^2=4$. Calcular $P(|\bar{x}-\mu|>1/2, S^2<4'2)$

$$P(|\bar{x}-\mu|>1/2, S^2<4'2) \overset{\substack{\uparrow \\ \bar{x} \text{ y } S^2 \text{ indep.}}}{=} P(|\bar{x}-\mu|>1/2) \cdot P(S^2<4'2)$$

Ahora tenemos que expresarlo en términos de funciones de distribución, en este caso, de la normal.

$$P(|\bar{x}-\mu|>1/2) \overset{\substack{\uparrow \\ \text{tipificamos}}}{=} P\left(|\frac{\bar{x}-\mu}{0'2}|>\frac{0'5}{0'2}\right) = P(|N(0,1)|>2'5)$$

$$\begin{aligned} &\text{desviación típica de } \bar{x} \\ &= \frac{\sigma}{\sqrt{n}} = \frac{2}{\sqrt{100}} = 0'2 \end{aligned}$$



por simetría

$$= 2 \left(1 - P(N(0,1) < 2'5) \right) = 2(1 - \Phi(2'5)) = 1'24\%$$

NOTACIÓN

$$F_{\chi_n^2} := \text{función de distribución de } \chi_n^2$$

$$P(S^2 < 4'2) = P\left(\underbrace{\frac{99}{4}}_{\sigma^2} \overbrace{S^2}^{(n-1)} < \frac{99 \cdot 4'2}{4}\right) = P(\chi_{99}^2 < 103) =$$

$$= F_{\chi_{99}^2}(103) \cong 65\%$$

$$\Rightarrow P(|\bar{x}-\mu|>1/2, S^2<4'2) = 0'0124 \cdot 0'65 = 0'00806 = 0'8\%$$

ESTADÍSTICOS: MÁXIMOS Y MÍNIMOS

X variable aleatoria

X_1, \dots, X_n clones de X

$$M_n = \max(X_1, \dots, X_n)$$

$$m_n = \min(X_1, \dots, X_n)$$

1) Funciones de distribución

$$\begin{aligned} F_{M_n}(t) &= P(M_n \leq t) = P(\max(X_1, \dots, X_n) \leq t) = P(X_1 \leq t, \dots, X_n \leq t) \stackrel{\text{independen}}{=} \\ &= P(X_1 \leq t) \cdot \dots \cdot P(X_n \leq t) \stackrel{\text{clones de } X}{=} P(X \leq t)^n = \boxed{F_X(t)^n} \end{aligned}$$

nota: Si X es continua y f_X es función de densidad:

$$f_{M_n}(t) = F'_{M_n}(t) = n f_X(t) \cdot F_X(t)^{n-1}$$

$$\begin{aligned} F_{m_n}(t) &= P(m_n \leq t) = 1 - P(m_n > t) = 1 - P(X_1 > t, \dots, X_n > t) = \\ &\stackrel{\text{independencia}}{=} 1 - P(X > t)^n = \boxed{1 - (1 - F_X(t))^n} \end{aligned}$$


clones de X

nota: Si X es continua y f_X es función de densidad:

$$f_{m_n}(t) = F'_{m_n}(t) = n \cdot f_X(t) \cdot (1 - F_X(t))^{n-1}$$

2) Concentración

Supongamos que β es el MÁXIMO ESENCIAL de X , es decir,



Ejemplos

Uniforme $[0, 1]$ $\beta = 1$

Bin(n, p) $\beta = n$

Normal

Poisson

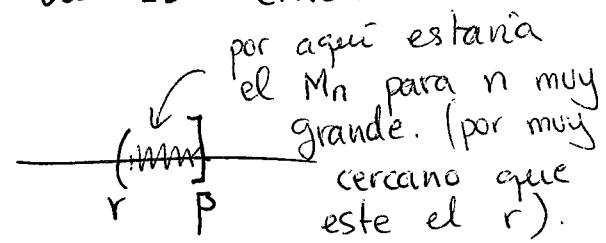
Geométrica

Exp

} $\rightarrow \beta = \infty$

Proposición: Si β es el máximo esencial de X entonces
 si $r < \beta$.

$$\lim_{n \rightarrow \infty} P(r \leq M_n \leq \beta) = 1$$



demostración

$$P(M_n \leq r) = F_X(r)^n, \text{ pero } F_X(r) < 1 \Rightarrow F_X(r)^n \xrightarrow{n \rightarrow \infty} 0$$

$$P(M_n > \beta) = 0 \quad (\text{porque } P(X > \beta) = 0)$$

