

PROBABILIDAD II

Grado en Matemáticas

Tema 3 Variables y vectores aleatorios

Javier Cárcamo

**Departamento de Matemáticas
Universidad Autónoma de Madrid**
javier.carcamo@uam.es

Tema 3: Variables y vectores aleatorios

1. Variables y vectores aleatorios
2. Ley imagen y distribución de probabilidad
3. Función de distribución
4. Distribuciones discretas
5. Distribuciones absolutamente continuas
6. Independencia de variables aleatorias
7. Esperanza matemática
8. El teorema de cambio de variable y sus consecuencias

Una **variable** es cualquier aspecto relativo a un experimento. Si (Ω, \mathcal{F}, P) es un espacio de probabilidad, podemos pensar en una aplicación:

$$X : \Omega \longrightarrow E$$

$$\omega \longmapsto X(\omega).$$

Las variables pueden ser cuantitativas o cualitativas. Nos centraremos en las **variables cuantitativas** ($E \subseteq \mathbb{R}$). Se denomina variable *aleatoria* ya que a priori no conocemos el resultado del experimento, luego no sabemos el valor que va a tomar X .

Como sabemos calcular probabilidades en (Ω, \mathcal{F}) vía P , la aplicación $X : \Omega \longrightarrow E \subseteq \mathbb{R}$ inducirá una medida de probabilidad en $(E, \mathcal{B}(E))$.

Nos podemos preguntar por $P(X \leq 2)$ o $P(2 < X < 7)$. Para poder calcular estas probabilidades tendremos que pedir que $\{\omega \in \Omega : X(\omega) \leq 2\} \in \mathcal{F}$ y $\{\omega \in \Omega : 2 < X(\omega) < 7\} \in \mathcal{F}$.

Definición de variable aleatoria

Sea (Ω, \mathcal{F}, P) un espacio de probabilidad. Se llama **variable aleatoria** a toda aplicación

$$X : \Omega \longrightarrow \mathbb{R} \quad (\text{o } \overline{\mathbb{R}})$$

$$\omega \longmapsto X(\omega)$$

verificando que para todo $B \in \mathcal{B}$, se tiene que $X^{-1}(B) \in \mathcal{F}$.

Recordamos que $X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}$, es la **anti-imagen** de B por X .

Notación: $X : \Omega \longrightarrow \mathbb{R}$ función.

$$\{X \in B\} = X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

$$\{X = a\} = X^{-1}(\{a\}) = \{\omega \in \Omega : X(\omega) = a\}.$$

$$\{a < X < b\} = X^{-1}((a, b)) = \{\omega \in \Omega : a < X(\omega) < b\}.$$

Función medible: Sean (Ω, \mathcal{F}) , (Ω', \mathcal{F}') dos espacios medibles. Se dice que una función $f : (\Omega, \mathcal{F}) \rightarrow (\Omega', \mathcal{F}')$ es \mathcal{F}/\mathcal{F}' -medible si para todo $A \in \mathcal{F}'$, se tiene que $f^{-1}(A) \in \mathcal{F}$.

Observación: Una variable aleatoria sobre (Ω, \mathcal{F}) es una función \mathcal{F}/\mathcal{B} -medible (**medible Borel**).

Ejercicio: Si $f : (\Omega, \mathcal{F}) \rightarrow (\Omega', \mathcal{F}')$ es \mathcal{F}/\mathcal{F}' -medible y $g : (\Omega', \mathcal{F}') \rightarrow (\Omega'', \mathcal{F}'')$ es $\mathcal{F}'/\mathcal{F}''$ -medible, entonces $g \circ f$ es $\mathcal{F}/\mathcal{F}''$ -medible.

Ejercicio: $f : (\Omega, \mathcal{F}) \rightarrow (\Omega', \mathcal{F}')$. Si $\mathcal{F}' = \sigma(\mathcal{C}')$, entonces f es \mathcal{F}/\mathcal{F}' -medible si y solo si para todo $C \in \mathcal{C}'$, $f^{-1}(C) \in \mathcal{F}$.

Aplicación: $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B})$ es v.a. si y sólo si $\{X \leq a\} \in \mathcal{F}$, para todo $a \in \mathbb{Q}$.

Proposición: Sea $f : (\Omega, \tau) \rightarrow (\Omega', \tau')$, donde τ y τ' son dos topologías. Sean \mathcal{B}_τ y $\mathcal{B}_{\tau'}$ las σ -álgebras Borelianas asociadas. Si f es τ/τ' continua, entonces f es $\mathcal{B}_\tau/\mathcal{B}_{\tau'}$ -medible.

Aplicación: Si $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ es v.a., entonces X^n , $|X|^\alpha$ ($\alpha > 0$), e^X , $5X + 1$, $\frac{X-3}{X^2+1}, \dots$, son v.a.

Proposición: Sean $f, g : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B})$ \mathcal{F}/\mathcal{B} -medibles y $\phi : \mathbb{R}^2 \rightarrow \mathbb{R}$ continua. La función $\phi(f, g) : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B})$ es \mathcal{F}/\mathcal{B} -medible.

Aplicación: Si $X, Y : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ son v.a., entonces $X + Y$, XY , $X^2 + Y^2$, \dots , son v.a.

Proposición: Sean $X_k : (\Omega, \mathcal{F}) \rightarrow \overline{\mathbb{R}}$, $k \geq 1$ v.a. Las siguientes funciones son v.a.

- (a) $\sup_k X_k$.
- (b) $\inf_k X_k$.
- (c) $\limsup_k X_k$
- (d) $\liminf_k X_k$
- (e) Si existe $\lim_k X_k$, entonces es v.a.


- (1) **Constantes:** Toda $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ constante es v.a.
- (2) **Indicadores:** Si $A \subset \Omega$, se llama **indicador de A** a la función $1_A : \Omega \rightarrow \mathbb{R}$ tal que $1_A(\omega) = 1$ si $\omega \in A$ y $1_A(\omega) = 0$ si $\omega \notin A$. ¿Cuándo 1_A es una v.a.?
- (3) **Funciones simples:** Una v.a. $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ se dice **simple** si $X(\Omega)$ es finito.
- Propiedad:** $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ con $X(\Omega) = \{a_1, \dots, a_k\}$. X es v.a. simple si y solo si $\{X = a_i\} \in \mathcal{F}$, $i = 1, \dots, k$.
- Nota:** Si $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ es simple y $X(\Omega) = \{a_1, \dots, a_k\}$, entonces $X = \sum_{i=1}^k a_i 1_{\{X=a_i\}}$.
- (4) **Variables discretas:** Una v.a. X es **discreta** si $X(\Omega)$ es contable.
- Ejercicio:** $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ con $X(\Omega) = \{a_1, a_2, \dots\}$. X v.a. discreta si y sólo si $\{X = a_i\} \in \mathcal{F}$, $i = 1, 2, \dots$.

Definición de vector aleatorio

Se llama **vector aleatorio k -dimensional** a toda aplicación medible $\mathbf{X} : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}^k$. Es decir, $\{\mathbf{X} \in B\} \in \mathcal{F}$, $B \in \mathcal{B}(\mathbb{R}^k)$.

Dado $\mathbf{x} = (x_1, \dots, x_k) \in \mathbb{R}^k$, la **región suroeste generada por \mathbf{x}** :

$$S_{\mathbf{x}} = (-\infty, x_1] \times \dots \times (-\infty, x_k].$$



Observación: $\mathcal{C} = \{S_{\mathbf{x}} : \mathbf{x} \in \mathbb{R}^k\}$ genera a $\mathcal{B}(\mathbb{R}^k)$. Por tanto, $\mathbf{X} : \Omega \rightarrow \mathbb{R}^k$ es v.a. si y solo si $\{\mathbf{X} \in S_{\mathbf{x}}\} \in \mathcal{F}$ para todo $\mathbf{x} \in \mathbb{R}^k$.

Proposición: $\mathbf{X} = (X_1, \dots, X_k) : \Omega \longrightarrow \mathbb{R}^k$ aplicación.

\mathbf{X} vector aleatorio si y solo si X_1, \dots, X_k variables aleatorias.

Corolario: Sean X_1, \dots, X_k v.a. sobre (Ω, \mathcal{F}) con valores en \mathbb{R} y $g : \mathbb{R}^k \longrightarrow \mathbb{R}$ medible (en particular continua). Se tiene que $X = g(X_1, \dots, X_k)$ es v.a.

Aplicación: X_1, \dots, X_k v.a., entonces $\sum X_i, \prod X_i, \sum X_i^2, e^{X_1 + \dots + X_k}, \dots$ son v.a.

σ -álgebras generadas por variables aleatorias

Sea $X : \Omega \longrightarrow \mathbb{R}$ (o $\overline{\mathbb{R}}$) aplicación. La colección

$$\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}\} \quad \text{es una } \sigma\text{-álgebra}$$

denominada **σ -álgebra asociada o generada por X** .

Observación: $X : (\Omega, \mathcal{F}) \longrightarrow \mathbb{R}$ es una v.a. si y solo si $\sigma(X) \subset \mathcal{F}$.
 $\sigma(X)$ es la mínima σ -álgebra sobre Ω que hace medible a X .

Los conjuntos de la forma $X^{-1}(B)$, $B \in \mathcal{B}$ se llaman **sucesos asociados a X** .

Sea $\{X_i : i \in I\}$ con $X_i : (\Omega, \mathcal{F}) \longrightarrow \mathbb{R}$.

$$\sigma(X_i : i \in I) = \sigma \left(\bigcup_{i \in I} \sigma(X_i) \right)$$

es la mínima σ -álgebra sobre Ω que hace medibles a todas las X_i simultáneamente.

Teorema fundamental de aproximación

Sea $X : (\Omega, \mathcal{F}) \longrightarrow [0, \infty]$. Existe una sucesión de funciones simples $\{X_n\}_{n=1}^{\infty}$ verificando:

- (a) Las X_n son $\sigma(X)$ -medibles.
- (b) $0 \leq X_n \leq X_{n+1}$, para todo n .
- (c) $\lim_{n \rightarrow \infty} X_n = X$.

Existe $\{X_n\}$ sucesión de v.a. simples $\sigma(X)$ -medibles con $0 \leq X_n \uparrow X$.

Idea de la prueba: Para todo n y $\omega \in \Omega$, definimos

$$X_n(\omega) = \begin{cases} \frac{q-1}{2^n}, & \text{si } \frac{q-1}{2^n} \leq X(\omega) < \frac{q}{2^n}, \quad q = 1, \dots, n2^n, \\ n, & \text{si } X(\omega) \geq n. \end{cases}$$

Es decir,

$$X_n = \sum_{q=1}^{n2^n} \frac{q-1}{2^n} 1_{\{\frac{q-1}{2^n} \leq X < \frac{q}{2^n}\}} + n 1_{\{X \geq n\}}, \quad \sigma(X)\text{-medible.}$$

Ley imagen

(Ω, \mathcal{F}, P) espacio de probabilidad.

$f : (\Omega, \mathcal{F}, P) \longrightarrow (\Omega', \mathcal{F}')$ función \mathcal{F}/\mathcal{F}' -medible.

Es decir, para todo $B \in \mathcal{F}'$, tenemos que $f^{-1}(B) \in \mathcal{F}$. Por tanto podemos calcular $P(f^{-1}(B))$.

$$\begin{aligned} P_f : \mathcal{F}' &\longrightarrow [0, 1] \\ B &\longmapsto P_f(B) = P(f^{-1}(B)). \end{aligned}$$

Teorema


P_f es una medida de probabilidad sobre (Ω', \mathcal{F}') que se llama **ley imagen** de P bajo f .

$X : (\Omega, \mathcal{F}, P) \longrightarrow (\mathbb{R}, \mathcal{B})$ variable aleatoria ($\Omega' = \mathbb{R}$ o $\overline{\mathbb{R}}$ y $\mathcal{F}' = \mathcal{B}$).

$$P_X : \mathcal{B} \longrightarrow [0, 1]$$

$$B \longmapsto P_X(B) = P(X \in B).$$

P_X se llama **distribución de probabilidad de X** y es una medida de probabilidad en $(\mathbb{R}, \mathcal{B})$ o $(\overline{\mathbb{R}}, \overline{\mathcal{B}})$.



Definición: $X : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}$ e $Y : (\Omega^*, \mathcal{F}^*, P^*) \longrightarrow \mathbb{R}$ variables aleatorias. Se dice que X e Y están **idénticamente distribuidas** y lo denotamos $X =_d Y$ si $P_X = P_Y^*$.

Es decir, si para todo $B \in \mathcal{B}$, se tiene $P_X(B) = P_Y^*(B)$, o lo que es lo mismo, para todo $B \in \mathcal{B}$, $P(X \in B) = P^*(Y \in B)$.

Teorema: Sea $g : \mathbb{R} \longrightarrow \mathbb{R}$ medible. Si $X =_d Y$, entonces $g(X) =_d g(Y)$.

Aplicaciones: Si $X =_d Y$, entonces $X^2 =_d Y^2$, $e^X =_d e^Y$, $\sin X =_d \sin Y, \dots$

Definición: $X, Y : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}$ variables aleatorias. Se dice que X e Y son **casi seguramente iguales** y lo denotamos $X =_{cs} Y$ si $P(X = Y) = 1$ (o $P(X \neq Y) = 0$).

Proposición: Si $X =_{cs} Y$, entonces $X =_d Y$.

Observación: Si $X =_d Y$, X e Y ni siquiera tienen que estar definidas en un mismo espacio de probabilidad. Aun suponiendo que $X, Y : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ y $X =_d Y$, esto *no* implica que $X =_{cs} Y$.

Ejemplo: (Ω, \mathcal{F}, P) espacio de probabilidad donde existe $A \in \mathcal{F}$ con $P(A) = 1/2$. Tomemos $X = 1_A$ e $Y = 1_{A^c}$.


Distribución de probabilidad

$\mathbf{X} = (X_1, \dots, X_k) : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ vector aleatorio.

$$P_{\mathbf{X}} : \mathcal{B}(\mathbb{R}^k) \rightarrow [0, 1]$$

$$B \mapsto P_{\mathbf{X}}(B) = P(\mathbf{X} \in B).$$

$P_{\mathbf{X}}$ o $P_{(X_1, \dots, X_k)}$ se llama **distribución de probabilidad de \mathbf{X}** o **distribución conjunta de las variables X_1, \dots, X_k** y es una medida de probabilidad en $(\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k))$ o $(\overline{\mathbb{R}}^k, \mathcal{B}(\overline{\mathbb{R}}^k))$.




A las distribuciones de las variables aleatorias X_1, \dots, X_k , P_{X_1}, \dots, P_{X_k} , se las llama **distribuciones marginales de \mathbf{X}** .

Observación: $A \in \mathcal{B}$, $\{X_1 \in A\} = \{\mathbf{X} \in A \times \mathbb{R} \times \cdots \times \mathbb{R}\}$.

Luego, $P(X_1 \in A) = P(\mathbf{X} \in A \times \mathbb{R} \times \cdots \times \mathbb{R})$.

Idea física: $n = 2$, $P(X \in A) = P((X, Y) \in A \times \mathbb{R})$



La masa que la variable aleatoria X concentra en A es la masa que el vector aleatorio (X, Y) concentra en $A \times \mathbb{R}$.

Función de distribución

Definición: Sea $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ variable aleatoria. Se llama **función de distribución de X** a la función

$$F_X : \mathbb{R} \rightarrow \mathbb{R}$$

$$x \mapsto F_X(x) = P(X \leq x) = P_X((-\infty, x]).$$



Proposición: X e Y variables aleatorias (no necesariamente definidas sobre el mismo espacio de probabilidad). Se tiene $X =_d Y$ si y solo si $F_X = F_Y$.

Demostración: P_X es la medida de Borel-Stieltjes asociada a la función F_X .

Teorema: Propiedades básicas de la función de distribución

Sea X variable aleatoria y F su función de distribución.

- ① F es no decreciente ($x \leq y$, entonces $F(x) \leq F(y)$).
- ② F es continua por la derecha ($x_n \downarrow x$, entonces $F(x_n) \downarrow F(x)$).
- ③ $\lim_{x \rightarrow -\infty} F(x) = 0$; $\lim_{x \rightarrow +\infty} F(x) = 1$.

Teorema

Sea $F : \mathbb{R} \rightarrow \mathbb{R}$ verificando ①, ② y ③ de arriba, entonces, existe $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ variable aleatoria tal que $F = F_X$.

Demostración: Se basa en el Teorema de extensión de medidas de Caratheodory.

Cálculo de probabilidades con F

- ① $P(X \leq x) = F(x)$.
- ② $P(X > x) = 1 - F(x)$.
- ③ $P(X < x) = F(x^-)$.
- ④ $P(X \geq x) = 1 - F(x^-)$.
- ⑤ $P(x < X \leq y) = F(y) - F(x)$.
- ⑥ $P(x \leq X \leq y) = F(y) - F(x^-)$.
- ⑦ $P(x \leq X < y) = F(y^-) - F(x^-)$.
- ⑧ $P(x < X < y) = F(y^-) - F(x)$.
- ⑨ $P(X = x) = F(x) - F(x^-)$.

Corolario: F continua $\iff F$ continua por la izquierda $\iff F(x^-) = F(x)$, $x \in \mathbb{R} \iff P(X = x) = 0$, $x \in \mathbb{R}$.

Observación: $f : \mathbb{R} \rightarrow \mathbb{R}$ monótona, entonces $\{x : f \text{ discontinua en } x\}$ es contable. En particular $C_f = \{x : f \text{ continua en } x\}$ es denso.

Definición: Sea $\mathbf{X} = (X_1, \dots, X_k) : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ vector aleatorio. Se llama **función de distribución de \mathbf{X}** o **función de distribución conjunta de las X_i -s** a la función $F_{\mathbf{X}} : \mathbb{R}^k \rightarrow \mathbb{R}$ tal que

$$F_{\mathbf{X}}(\mathbf{x}) = P(\mathbf{X} \in S_{\mathbf{x}}) = P(X_1 \leq x_1, \dots, X_k \leq x_k).$$

Teorema: Propiedades básicas de la función de distribución

Sea \mathbf{X} vector aleatorio y F su función de distribución.

- ① F es no decreciente (en \mathbb{R}^k).
- ② F es continua por la derecha en cada variable.
- ③ $\lim_{x_i \rightarrow -\infty} F(x_1, \dots, x_k) = 0$ ($i = 1, \dots, k$);
 $\lim_{x_1, \dots, x_k \rightarrow +\infty} F(x_1, \dots, x_k) = 1$.

Pregunta: ¿Qué significa que una función sea monótona (no decreciente) en \mathbb{R}^k ?

Funciones monótonas (no decrecientes) en \mathbb{R}^k


Notación: Si $G : \mathbb{R}^k \rightarrow \mathbb{R}$ y $u \leq v$,

$$\Delta_i(u, v) = G(x_1, \dots, x_{i-1}, v, x_{i+1}, \dots, x_k) - G(x_1, \dots, x_{i-1}, u, x_{i+1}, \dots, x_k).$$

En $k = 1$, para $a \leq b$, $\Delta(a, b)F(x) = F(b) - F(a) \geq 0$.

En $k = 2$, para $a_1 \leq b_1$ y $a_2 \leq b_2$, se pide que

$$\Delta_1(a_1, b_1)\Delta_2(a_2, b_2)F(x, y) = \Delta_1(a_1, b_1)(F(x, b_2) - F(x, a_2)) = F(b_1, b_2) - F(b_1, a_2) - F(a_1, b_2) + F(a_1, a_2) \geq 0.$$



En general, se pide que, para $a_i \leq b_i$ ($i = 1, \dots, k$)

$$\Delta_1(a_1, b_1)\Delta_2(a_2, b_2) \cdots \Delta_k(a_k, b_k)F(x_1, \dots, x_k) \geq 0.$$

Teorema

Sea $F : \mathbb{R}^k \rightarrow \mathbb{R}$ verificando ①, ② y ③ de antes, entonces, existe $\mathbf{X} : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ vector aleatorio tal que $F = F_{\mathbf{X}}$.

Proposición: \mathbf{X} e \mathbf{Y} vectores aleatorios (no necesariamente definidas sobre el mismo espacio de probabilidad). Se tiene, $\mathbf{X} =_d \mathbf{Y}$ si y solo si $F_{\mathbf{X}} = F_{\mathbf{Y}}$.

Nota: (Relación entre $F_{\mathbf{X}}$ y F_{X_1}, \dots, F_{X_k})

$\mathbf{X} = (X_1, \dots, X_k) : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ vector aleatorio.

$F_{\mathbf{X}}(x_1, \dots, x_k) = P(X_1 \leq x_1, \dots, X_k \leq x_k)$; $F_{X_i}(x_i) = P(X_i \leq x_i)$

$$F_{X_1}(x_1) = \lim_{x_2, \dots, x_k \rightarrow \infty} F_{\mathbf{X}}(x_1, \dots, x_k).$$

Distribuciones discretas

Los tres tipos puros de distribuciones

- ① Discretas
- ② Absolutamente continuas
- ③ Continuas singulares

Distribuciones discretas

Definición: Un vector aleatorio $\mathbf{X} : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ se dice que tiene **distribución discreta** si existe un conjunto $S \subset \mathbb{R}^k$ contable tal que $P(\mathbf{X} \in S) = 1$ ($P(\mathbf{X} \in S^c) = 0$). Es decir, \mathbf{X} concentra su masa en S . S se llama **soporte de la distribución** (de \mathbf{X}).

Nota: \mathbf{X} vector discreto con soporte $S \subset \mathbb{R}^k$, entonces

$$P(\mathbf{X} \in B) = \sum_{s \in S \cap B} P(\mathbf{X} = s), \quad B \in \mathcal{B}^k.$$

Teorema: $\mathbf{X} = (X_1, \dots, X_k) : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ vector aleatorio. \mathbf{X} vector discreto $\iff X_1, \dots, X_k$ variables discretas.

Definición: Un vector aleatorio

$\mathbf{X} = (X_1, \dots, X_k) : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}^k$ se dice que es **absolutamente continuo** si existe una función medible borel $f : \mathbb{R}^k \longrightarrow [0, \infty]$ tal que

$$P(\mathbf{X} \in B) = \int_B f = \int_{\mathbb{R}^k} f 1_B, \quad B \in \mathcal{B}^k.$$

La función f se llama **densidad de probabilidad del vector \mathbf{X}** o **densidad conjunta de las variables X_1, \dots, X_k** .

En particular, la función de distribución de \mathbf{X}

$$F_{\mathbf{X}}(\mathbf{x}) = \int_{S_{\mathbf{x}}} f = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_k} f(t_1, \dots, t_k) dt_1 \cdots dt_k.$$

Se puede demostrar que la densidad

$$f(x_1, \dots, x_k) = \frac{\partial^k F_{\mathbf{X}}(x_1, \dots, x_k)}{\partial x_1 \cdots \partial x_k} \quad \text{c.s. (medida de Lebesgue).}$$

Distribuciones absolutamente continuas

Teorema: Si $\mathbf{X} = (X_1, \dots, X_k)$ vector aleatorio con densidad f , entonces X_i ($i = 1, \dots, k$) tiene densidad

$$f_i(x_i) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, \dots, x_k) dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_k.$$

Ejemplo: Si $\mathbf{X} = (X_1, X_2)$ vector aleatorio con densidad $f(x, y)$. Las densidades de X_1 y X_2 son:

$$f_1(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad f_2(y) = \int_{-\infty}^{\infty} f(x, y) dx.$$

Observación: Puede ocurrir que X_1, \dots, X_k variables aleatorias con densidad (es decir, cada una de ellas es absolutamente continua) y que el vector $\mathbf{X} = (X_1, \dots, X_k)$ *no* tenga densidad.

Ejemplo:

Definición: Un vector aleatorio $\mathbf{X} : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ se dice que tiene distribución **continua singular** si $F_{\mathbf{X}}(x_1, \dots, x_k)$ es continua y existe $B \in \mathcal{B}^k$ con $m_k(B) = 0$ (medida de Lebesgue en \mathbb{R}^k) y $P(\mathbf{X} \in B) = 1$. **No las manejaremos en la práctica.**

Teorema de descomposición

Sea $\mathbf{X} : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}^k$ un vector aleatorio. La medida de probabilidad $P_{\mathbf{X}}$ se descompone **de manera única** como:

$$P_{\mathbf{X}} = aP_d + bP_{ac} + cP_{cs},$$

donde $a, b, c \geq 0$ y $a + b + c = 1$ con

- P_d es una medida de probabilidad discreta sobre $(\mathbb{R}^k, \mathcal{B}^k)$.
- P_{ac} es una medida de probabilidad absolutamente continua sobre $(\mathbb{R}^k, \mathcal{B}^k)$.
- P_{cs} es una medida de probabilidad continua singular sobre $(\mathbb{R}^k, \mathcal{B}^k)$.

Demostración: Teorema de descomposición de Lebesgue.

Independencia de variables aleatorias

Definición: Sea $\{X_i : i \in I\}$ una familia de v.a. Se dice que las v.a. X_i son **(mutuamente) independientes** si las σ -álgebras generadas por ellas $\sigma(X_i)$ son independientes.

$$\sigma(X_i) = \{X_i^{-1}(B) : B \in \mathcal{B}\} = \{\{X_i \in B\} : B \in \mathcal{B}\}.$$

Observaciones:

$$\textcircled{1} \{X_i : i \in I\} \text{ ind.} \iff \forall \{i_1, \dots, i_k\} \subset I, X_{i_1}, \dots, X_{i_k} \text{ ind.}$$

$$\textcircled{2} X_1, \dots, X_k \text{ ind.} \iff \forall A_1 \in \sigma(X_1), \dots, \forall A_k \in \sigma(X_k), \\ P(A_1 \cdots A_k) = P(A_1) \cdots P(A_k).$$

$$\textcircled{3} X_1, \dots, X_k \text{ ind.} \iff \forall B_1, \dots, B_k \in \mathcal{B},$$

$$P(X_1 \in B_1, \dots, X_k \in B_k) = P(X_1 \in B_1) \cdots P(X_k \in B_k).$$

$$\textcircled{4} X_1, \dots, X_k \text{ ind.} \iff \forall B_1, \dots, B_k \in \mathcal{B},$$

$$P_{(X_1, \dots, X_k)}(B_1 \times \cdots \times B_k) = P_{X_1}(B_1) \cdots P_{X_k}(B_k).$$

$$X_1, \dots, X_k \text{ ind.} \iff \forall B_1, \dots, B_k \in \mathcal{B}, \\ P_{(X_1, \dots, X_k)}(B_1 \times \dots \times B_k) = P_{X_1}(B_1) \cdots P_{X_k}(B_k).$$

Nota (Teoría de la medida): Medida producto

$P_{(X_1, \dots, X_k)}$ medida de probabilidad en $(\mathbb{R}^k, \mathcal{B}^k)$.

P_{X_1}, \dots, P_{X_k} medidas de probabilidad en $(\mathbb{R}, \mathcal{B})$.

$X_1, \dots, X_k \text{ ind.} \iff P_{(X_1, \dots, X_k)}$ medida producto de P_{X_1}, \dots, P_{X_k} .

$$P_{(X_1, \dots, X_k)} = P_{X_1} \otimes \dots \otimes P_{X_k}.$$

⑤ X_1, \dots, X_k v.a. y $f_i : \mathbb{R} \rightarrow \mathbb{R}$ medible Borel ($i = 1, \dots, k$).

$$X_1, \dots, X_k \text{ ind.} \implies f_1(X_1), \dots, f_k(X_k) \text{ ind.}$$

⑥ $X_1, \dots, X_n, X_{n+1}, \dots, X_{n+m}$ v.a. $f_1 : \mathbb{R}^n \rightarrow \mathbb{R}$, $f_2 : \mathbb{R}^m \rightarrow \mathbb{R}$ medibles.

$$X_1, \dots, X_{n+m} \text{ ind.} \implies f_1(X_1, \dots, X_n), f_2(X_{n+1}, \dots, X_{n+m}) \text{ ind.}$$

Independencia de variables aleatorias

Teorema: Caracterización mediante funciones de distribución

X_1, \dots, X_k v.a. con f.d. conjunta F y f.d. marginales F_1, \dots, F_k .

$$X_1, \dots, X_k \text{ ind.} \iff F(x_1, \dots, x_k) = F_1(x_1) \cdots F_k(x_k).$$

Teorema: Independencia variables aleatorias discretas

X_i v.a. con soporte S_i contable $i = 1, \dots, k$. Son equivalentes:

- X_1, \dots, X_k ind.
- Para todo $s_i \in S_i$ ($i = 1, \dots, k$), se tiene

$$P(X_1 = s_1, \dots, X_k = s_k) = P(X_1 = s_1) \cdots P(X_k = s_k).$$

Teorema: Independencia variables aleatorias continuas

X_i v.a. absolutamente continua con densidad $f_i(x_i)$, $i = 1, \dots, k$.

- Si (X_1, \dots, X_k) tiene densidad $f(x_1, \dots, x_k) = f_1(x_1) \cdots f_k(x_k)$ (c.s. Lebesgue), entonces X_1, \dots, X_k independientes.
- Si X_1, \dots, X_k independientes, entonces (X_1, \dots, X_k) tiene densidad $f(x_1, \dots, x_k) = f_1(x_1) \cdots f_k(x_k)$.

Idea intuitiva: Sea Ω una población con:

n_1 personas de edad e_1 .

n_2 personas de edad e_2 .

\vdots \vdots \vdots

n_k personas de edad e_k .

$n_1 + \cdots + n_k = n \equiv$ número total de individuos.

$$\text{Edad media} = \frac{n_1 e_1 + \cdots + n_k e_k}{n} = e_1 \frac{n_1}{n} + \cdots + e_k \frac{n_k}{n}$$

ϵ : se elige un individuo al azar. Variable: $X \equiv$ edad del individuo.

X toma los valores e_1, \dots, e_k con probabilidades $P(X = e_i) = \frac{n_i}{n}$.

$$\sum_{i=1}^k e_i P(X = e_i) \equiv \text{Valor medio o esperanza matemática de } X.$$

Nos da una idea de entorno a qué punto se distribuye la v.a.

Esperanza matemática (definición en Probabilidad I)

Caso discreto: Sea X una v.a. discreta, **la esperanza (matemática) o media de X** se define por:

$$EX := \sum_x x P(X = x),$$

siempre que la suma o serie sea convergente, es decir,

$$\sum_x |x| P(X = x) < \infty \quad (\text{Absolutamente convergente}).$$

Caso continuo: Sea X una v.a. continua con función de densidad f , **la esperanza (matemática) o media de X** se define por:

$$EX := \int_{-\infty}^{+\infty} x f(x) dx,$$

siempre que la integral sea convergente, es decir,

$$\int_{-\infty}^{+\infty} |x| f(x) dx < \infty \quad (\text{Absolutamente convergente}).$$

Sea $X : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}$ variable aleatoria (\mathcal{F} -medible), se define la **esperanza (matemática)** de X como

$$EX = \int_{\Omega} X dP.$$

Observación: La EX es la integral (sobre Ω) de la función (medible) X respecto de la medida (de probabilidad) positiva P tal y como se estudia en el curso de Teoría de la medida y la integración.

Observación: La definición de la esperanza como integral (respecto de la medida de probabilidad subyacente) es consistente con la definición que se muestra en los cursos elementales.

Construcción de la esperanza matemática:

- ① Caso de v.a. simples.
- ② Extensión a v.a. no negativas.
- ③ Caso general.

Esperanza matemática (construcción para v.a. simples)

- ① **Caso de v.a. simples:** Sea X una v.a. simple sobre (Ω, \mathcal{F}, P) que toma los valores x_1, \dots, x_m . Es decir,

$$X = \sum_{i=1}^m x_i 1_{\{X=x_i\}}.$$

Se define la **media** o **esperanza matemática** de X

$$EX \equiv \int_{\Omega} X dP := \sum_{i=1}^m x_i P(X = x_i).$$

Esperanza matemática (construcción para v.a. no negativas)

- ② **Caso de v.a. no negativas:** $X : (\Omega, \mathcal{F}, P) \longrightarrow [0, \infty]$ v.a.
Existe una sucesión de v.a. simples $\{X_n\}$ tal que $0 \leq X_n \uparrow X$.
La **esperanza matemática** de X se define mediante

$$EX \equiv \int_{\Omega} X dP := \lim_{n \rightarrow \infty} EX_n.$$

Alternativamente, se puede comprobar que

$$EX \equiv \int_{\Omega} X dP = \sup_{0 \leq s \leq X, s \text{ simple}} \int_{\Omega} s dP.$$

Ejercicio: Dado (Ω, \mathcal{F}, P) e.p. y $A \in \mathcal{F}$. Definimos la función

$$Y(\omega) = \begin{cases} +\infty & \text{si } \omega \in A, \\ 0 & \text{si } \omega \notin A. \end{cases}$$

Mostrar que Y es una v.a. y calcular EY .

Esperanza matemática (propiedades para v.a. positivas)

Sean $X, Y \geq 0$ v.a. Se tienen las siguientes propiedades:

- ① EX siempre existe y $EX \in [0, \infty]$.
- ② **Linealidad:** $E(X + Y) = EX + EY$, $E(cX) = cEX$, para todo $c \geq 0$.
- ③ **Monotonicidad:** Si $X \leq Y$, entonces $EX \leq EY$.
- ④ **Teorema de convergencia monótona:** Si X_n, X v.a. no negativas tales que $X_n \uparrow X$, entonces $EX = \lim_{n \rightarrow \infty} EX_n$.
- ⑤ Si $EX < \infty$, entonces $P(X = \infty) = 0$.
- ⑥ $EX = 0$ si y sólo si $P(X \neq 0) = 0$, es decir $X = 0$ c.s.

- ③ **Caso general:** $X : (\Omega, \mathcal{F}, P) \longrightarrow \overline{\mathbb{R}}$ v.a. Podemos escribir $X = X^+ - X^-$, donde $X^+ = \max\{X, 0\}$ y $X^- = \max\{-X, 0\}$ son v.a. no negativas. La v.a. X se dice que **tiene esperanza** si $EX^+ < \infty$ ó $EX^- < \infty$.

Si X tiene esperanza, la **esperanza matemática** de X se define mediante

$$EX = EX^+ - EX^-.$$

En particular, si $EX^+, EX^- < \infty$, se dice que X es **integrable** y se denota $X \in \mathcal{L}_1(P)$ (o \mathcal{L}_1).

Esperanza matemática (propiedades)

- ① Si X tiene esperanza, entonces $EX \in \overline{\mathbb{R}}$.
- ② X integrable si y solo si $EX \in \mathbb{R}$ ($X \in \mathcal{L}_1(P)$).
- ③ Si $X + Y$ está bien definida ($EX^+ < \infty$ y $EY^+ < \infty$ ó $EX^- < \infty$ y $EY^- < \infty$), entonces $X + Y$ tiene esperanza y $E(X + Y) = EX + EY$.
- ④ Si X tiene esperanza, entonces para todo $c \in \mathbb{R}$ cX tiene esperanza y $E(cX) = cEX$.
- ⑤ **Linealidad:** Si X, Y son integrables ($X, Y \in \mathcal{L}_1(P)$), entonces $aX + bY \in \mathcal{L}_1(P)$ y $E(aX + bY) = aEX + bEY$.
- ⑥ **Monotonicidad:** X, Y tienen esperanza y $X \leq Y$, entonces $EX \leq EY$. En particular, $|EX| \leq E|X|$.
- ⑦ **Teorema de convergencia monótona**
- ⑧ **Lema de Fatou-Lebesgue**
- ⑨ **Teorema de la convergencia dominada**

Esperanza matemática (propiedades)

Teorema de la convergencia monótona

Hacia arriba: Si $X_n \uparrow X$ y existe k tal que $EX_k^- < \infty$, entonces X_k, X_{k+1}, \dots, X tienen esperanza y $EX = \lim_{n \rightarrow \infty} EX_n$.

Hacia abajo: Si $X_n \downarrow X$ y existe k tal que $EX_k^+ < \infty$, entonces X_k, X_{k+1}, \dots, X tienen esperanza y $EX = \lim_{n \rightarrow \infty} EX_n$.

Lema de Fatou-Lebesgue

(a) Si $X_n \leq Y$ para todo n y $EY^+ < \infty$, entonces $X_n, \limsup_{n \rightarrow \infty} X_n$ tienen esperanza para todo n y

$$E\left(\limsup_{n \rightarrow \infty} X_n\right) \geq \limsup_{n \rightarrow \infty} EX_n.$$

(b) Si $X_n \geq Z$ para todo n y $EZ^- < \infty$, entonces $X_n, \liminf_{n \rightarrow \infty} X_n$ tienen esperanza para todo n y

$$E\left(\liminf_{n \rightarrow \infty} X_n\right) \leq \liminf_{n \rightarrow \infty} EX_n.$$

Esperanza matemática (propiedades)

Teorema de la convergencia dominada

Si $X_n \rightarrow X$ y existe U variable aleatoria integrable tal que $|X_n| \leq U$ para todo n , entonces $X_1, \dots, X_n, \dots, X$ son integrables y

$$EX = \lim_{n \rightarrow \infty} EX_n.$$

Integral indefinida: Sea X una v.a. positiva o integrable sobre (Ω, \mathcal{F}, P) y $A \in \mathcal{F}$, se define

$$\int_A X dP = E(X1_A) = \int_{\Omega} X \cdot 1_A dP.$$

Una desigualdad de mucha aplicación

Sea X una variable aleatoria y $a, b \in \mathbb{R}$. Se tiene:

$$aP(a \leq X \leq b) \leq \int_{\{a \leq X \leq b\}} X dP \leq bP(a \leq X \leq b).$$

El Teorema fundamental de aproximación y la construcción de la esperanza es la base de un método de demostración que llamaremos el **método de la cadena ascendente** (MCA):
Supongamos que queremos mostrar que la v.a. X verifica cierta propiedad \mathcal{P} , relacionada con esperanzas.

- ① **Indicadores:** Se prueba que si $X = 1_A$, con $A \in \mathcal{F}$, entonces X verifica \mathcal{P} .
- ② **V.a. simples:** Se prueba que si $X = \sum_{i=1}^n a_i 1_{A_i}$ v.a. simple, entonces X verifica \mathcal{P} .
- ③ **V.a. positivas:** Se usa el teorema fundamental de aproximación para mostrar que toda v.a. positiva X verifica \mathcal{P} . En este punto en ocasiones también se apela al Teorema de convergencia monótona.
- ④ **Caso general:** Se escribe $X = X^+ - X^-$ y se usa el punto anterior para mostrar que X verifica \mathcal{P} .

Esperanza matemática (independencia)

Teorema: Esperanza de un producto de v.a. ind.

$X, Y : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}$ v.a. independientes e integrables. Se tiene:
La v.a. XY es integrable y $E(XY) = EXEY$.


Corolario: $X_1, \dots, X_n : (\Omega, \mathcal{F}, P) \longrightarrow \mathbb{R}$ v.a. independientes e integrables. Se tiene:

La v.a. $X_1 \cdots X_n$ es integrable y $E(X_1 \cdots X_n) = EX_1 \cdots EX_n$.

Observación: Puede ocurrir que $E(XY) = EXEY$, pero X e Y no independientes.

Ejemplos:

Teorema: Cálculo de esperanzas cuando hay densidad



Supongamos que \mathbf{X} y g son medibles y \mathbf{X} tiene densidad f . Se tiene:

$$Eg(\mathbf{X}) = \int_{\Omega} g(\mathbf{X}) dP \quad \text{existe si y sólo si} \quad \int_{\mathbb{R}^k} g f dm_k \text{ existe,}$$

donde m_k es la medida de Lebesgue en \mathbb{R}^k , $dm_k = dx_1 \cdots dx_k$.

En tal caso coinciden. Es decir,

$$\int_{\Omega} g(\mathbf{X}) dP = \int_{\mathbb{R}^k} g f dm_k.$$

El teorema de cambio de variable. Consecuencias

Ejemplos: Expresa en función de las densidades las siguientes esperanzas.

Sea X v.a. con densidad $f(x)$.

$$EX^3 =$$

$$Ee^{tX} =$$

Sea (X, Y) v.a. con densidad $f(x, y)$.

$$E\left(\frac{X^2}{X^4 + Y^4}\right) =$$

Sea X, Y v.a. independientes con densidades $f_1(x)$ y $f_2(y)$.

$$Ee^{X+Y} =$$

$$E\sin(X + Y) =$$