

1. La normal multidimensional

Estadística II, 20-21

Pablo Fernández Gallardo

Vectores aleatorios

Vector aleatorio n dimensional:

$$\mathbb{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}.$$

Su distribución (en el caso continuo) viene dada por una **función de densidad conjunta** $f_{\mathbb{X}}(x_1, \dots, x_n)$ tal que

$$f_{\mathbb{X}}(\mathbf{x}) \geq 0 \quad \text{y} \quad \int_{\mathbb{R}^n} f_{\mathbb{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

(La **independencia** de las coordenadas significa que la función de densidad se factoriza: $f_{\mathbb{X}}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n)$ para todo $(x_1, \dots, x_n) \in \mathbb{R}^n$).

Vector de medias

Notación: si $\mathbb{M} = (X_{i,j})_{i,j}$ es una *matriz* de dimensiones $n \times m$ cuyas componentes son variables aleatorias, escribiremos $\mathbf{E}(\mathbb{M})$ para referirnos la matriz $(\mathbf{E}(X_{i,j}))_{i,j}$ de medias de esas variables.

El **vector de medias** asociado a \mathbb{X} es

$$\mathbf{E}(\mathbb{X}) = \begin{pmatrix} \mathbf{E}(X_1) \\ \vdots \\ \mathbf{E}(X_n) \end{pmatrix}.$$

Si A, B son matrices $n \times n$, \mathbb{X}, \mathbb{Y} vectores aleatorios de dimensión n , y $\mathbf{b} \in \mathbb{R}^n$,

$$\mathbf{E}(A\mathbb{X} + \mathbf{b}) = A\mathbf{E}(\mathbb{X}) + \mathbf{b} \quad \text{y} \quad \mathbf{E}(A\mathbb{X}\mathbb{Y}^T B) = A\mathbf{E}(\mathbb{X}\mathbb{Y}^T) B.$$

(Atención: $\mathbf{E}(\mathbb{X}^T A \mathbb{X}) \neq \mathbf{E}(\mathbb{X}^T) A \mathbf{E}(\mathbb{X})$).

Matriz de varianzas/covarianzas

La **matriz de covarianzas** de \mathbb{X} es

$$\mathbf{cov}(\mathbb{X}) = \begin{pmatrix} \mathbf{V}(X_1) & \text{cov}(X_1, X_2) & \cdots & \text{cov}(X_1, X_n) \\ \text{cov}(X_2, X_1) & \mathbf{V}(X_2) & \cdots & \text{cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \text{cov}(X_n, X_2) & \cdots & \mathbf{V}(X_n) \end{pmatrix}$$

Recuérdese que

$$\begin{aligned} \mathbf{V}(X) &= \mathbf{E}((X - \mathbf{E}(X))^2) = \mathbf{E}(X^2) - \mathbf{E}(X)^2, \\ \text{cov}(X, Y) &= \mathbf{E}[(X - \mathbf{E}(X)) \cdot (Y - \mathbf{E}(Y))] = \mathbf{E}(XY) - \mathbf{E}(X) \mathbf{E}(Y). \end{aligned}$$

1) Se tiene que

$$\mathbf{cov}(\mathbb{X}) = \mathbf{E}((\mathbb{X} - \mathbf{E}(\mathbb{X})) \cdot (\mathbb{X} - \mathbf{E}(\mathbb{X}))^T)$$

(Atención: $(\mathbb{X} - \mathbf{E}(\mathbb{X})) \cdot (\mathbb{X} - \mathbf{E}(\mathbb{X}))^T$ es una matriz $n \times n$; mientras que $(\mathbb{X} - \mathbf{E}(\mathbb{X}))^T \cdot (\mathbb{X} - \mathbf{E}(\mathbb{X}))$ es una variable aleatoria).

2) Bajo cambios lineales,

$$\mathbf{cov}(A\mathbb{X} + \mathbf{b}) = A \cdot \mathbf{cov}(\mathbb{X}) \cdot A^T.$$

3) Una matriz de covarianzas es simétrica y (semi)definida positiva.

Prueba: calcula $\mathbf{V}(\mathbf{a}^T \mathbb{X})$.

Matriz de correlaciones

La matriz de correlaciones de \mathbb{X} es

$$\rho(\mathbb{X}) = \begin{pmatrix} 1 & \rho(X_1, X_2) & \cdots & \rho(X_1, X_n) \\ \rho(X_2, X_1) & 1 & \cdots & \rho(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(X_n, X_1) & \rho(X_n, X_2) & \cdots & 1 \end{pmatrix}$$

Recuérdese que

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\mathbf{V}(X)\mathbf{V}(Y)}} \in [-1, 1].$$

- Se tiene que $\text{cov}(\mathbb{X}) = \sqrt{D(\mathbb{X})} \rho(\mathbb{X}) \sqrt{D(\mathbb{X})}$, donde $\sqrt{D(\mathbb{X})}$ es la matriz diagonal con las desviaciones típicas.
- ¿Cómo cambia $\rho(\mathbb{X})$ bajo transformaciones lineales?

La normal multidimensional

Dados

- un vector $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^\top$;
- y una matriz $V = (v_{ij})$ de dimensiones $n \times n$ simétrica y definida positiva,

decimos que \mathbb{X} sigue una distribución **normal multidimensional** (de dimensión n) con parámetros $\boldsymbol{\mu}$ y V , lo que denotaremos por

$$\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V),$$

si, para todo $\mathbf{x} \in \mathbb{R}^n$, su función de densidad viene dada por

$$f_{\mathbb{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2}} \frac{1}{\sqrt{\det(V)}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top V^{-1}(\mathbf{x}-\boldsymbol{\mu})}.$$

En esta expresión, \mathbf{x} es un vector columna.

Como V es simétrica y definida positiva, la podremos escribir como

$$V = UU^T,$$

para cierta matriz U no singular. Obsérvese que $\det(V) = \det(U)^2$.

Como

$$V^{-1} = (U^{-1})^T U^{-1},$$

U^{-1} es una raíz cuadrada de V^{-1} .

Podemos reescribir la densidad $f_{\mathbb{X}}$ como

$$f_{\mathbb{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2}} \frac{1}{|\det(U)|} e^{-\frac{1}{2} \|U^{-1}(\mathbf{x}-\mathbf{m})\|^2}.$$

Por ejemplo, si orto-diagonalizamos V ,

$$V = O\Lambda O^T = \underbrace{O\Lambda^{1/2}O^T}_{=U} \underbrace{O\Lambda^{1/2}O^T}_{=U^T}$$

y U^{-1} sería

$$U^{-1} = O\Lambda^{-1/2}O^T.$$

Algunas observaciones:

- El caso $\mathcal{N}(\mathbf{0}, I)$ es la normal estándar.
- Si $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$, entonces
 - ▶ $\mathbf{E}(\mathbb{X}) = \boldsymbol{\mu}$ y $\mathbf{cov}(\mathbb{X}) = V$,
 - ▶ y cada X_i es una normal de media μ_i y varianza v_{ii} .
- Las coordenadas X_1, \dots, X_n son independientes si y solo si V es diagonal.
- Tipificación:

$$\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V) \quad \Longleftrightarrow \quad \mathbb{X} = \boldsymbol{\mu} + U\mathbb{Y}, \quad \text{con } \mathbb{Y} \sim \mathcal{N}(\mathbf{0}, I).$$

Es decir,

$$U^{-1}(\mathbb{X} - \boldsymbol{\mu}) \sim \mathcal{N}(\mathbf{0}, I).$$

Si $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$, la variable aleatoria

$$(\mathbb{X} - \boldsymbol{\mu})^\top V^{-1}(\mathbb{X} - \boldsymbol{\mu})$$

se distribuye como una χ^2 con n grados de libertad.

Recuérdese que una χ^2 con n grados de libertad es una suma de n cuadrados de normales estándar. Basta observar que $(\mathbb{X} - \boldsymbol{\mu})^\top V^{-1}(\mathbb{X} - \boldsymbol{\mu}) = \mathbb{Y}^\top \mathbb{Y}$, con $\mathbb{Y} \sim \mathcal{N}(\mathbf{0}, I)$.

Combinaciones lineales de coordenadas

Sea $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$ una normal de dimensión n .

- Para un vector \mathbf{a} , la variable aleatoria

$$\mathbf{a}^\top \mathbb{X} = \sum_{j=1}^n a_j X_j$$

se distribuye como una $\mathcal{N}(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top V \mathbf{a})$.

- Para una matriz A y un vector \mathbf{b} , el vector aleatorio

$$A\mathbb{X} + \mathbf{b}$$

se distribuye como una $\mathcal{N}(A\boldsymbol{\mu}, AVA^\top)$.

Reducción de dimensión

Sea $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$ una normal de dimensión n .

Seleccionamos k índices, $J = \{j_1, \dots, j_k\}$ y definimos \mathbb{X}_J , $\boldsymbol{\mu}_J$ y V_J quedándonos con las entradas correspondientes de \mathbb{X} , $\boldsymbol{\mu}$ y V .

Entonces $\mathbb{X}_J \sim \mathcal{N}(\boldsymbol{\mu}_J, V_J)$.

Condicionando

Sea $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$ una normal de dimensión n .

Digamos que partimos en

$$\mathbb{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \\ X_{p+1} \\ \vdots \\ X_n \end{pmatrix} = \begin{pmatrix} \mathbb{X}_1 \\ \mathbb{X}_2 \end{pmatrix}$$

Partimos, análogamente,

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad y \quad V = \left(\begin{array}{c|c} V_{1,1} & V_{1,2} \\ \hline V_{2,1} & V_{2,2} \end{array} \right)$$

Entonces

- Los vectores \mathbb{X}_1 y \mathbb{X}_2 son **independientes** si $V_{1,2} = V_{2,1}^T$ tiene todas sus entradas nulas.
- El vector \mathbb{X}_1 , **condicionado** a que $\mathbb{X}_2 = \mathbf{a}$, se distribuye como una normal (de dimensión p) con parámetros

$$\tilde{\boldsymbol{\mu}} = \boldsymbol{\mu}_1 + V_{1,2} V_{2,2}^{-1}(\mathbf{a} - \boldsymbol{\mu}_2)$$

$$\tilde{V} = V_{1,1} - V_{1,2} V_{2,2}^{-1} V_{2,1}.$$

Formas lineales y cuadráticas, y normalidad

Sea $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$.

Para ciertos cálculos del curso, interesará conocer la distribución de combinaciones **lineales y cuadráticas** de las coordenadas de \mathbb{X} :

vectores aleatorios del tipo $A\mathbb{X}$,
o variables aleatorias del tipo $\mathbb{X}^T A \mathbb{X}$,

y sus posibles relaciones de dependencia.

Recordamos que una variable Z se distribuye como una χ^2 con n grados de libertad si

$$Z = Z_1^2 + \cdots + Z_n^2,$$

donde Z_1, \dots, Z_n son normales estándar independientes. Se tiene que $\mathbf{E}(Z) = n$ y $\mathbf{V}(Z) = 2n$.

Caso lineal (ya visto):

- Si $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$ es una normal de dimensión n , y A es una matriz $n \times n$, entonces

$$A\mathbb{X} \sim \mathcal{N}(A\boldsymbol{\mu}, AVA^T).$$

(En realidad, A podría ser de dimensiones $p \times n$, con $p < n$).

En el caso de las formas cuadráticas, tenemos que

- Si $\mathbb{X} \sim \mathcal{N}(\mathbf{0}, I)$ es una normal de dimensión n , entonces

$$\mathbb{X}^T \mathbb{X} \sim \chi_n^2.$$

También hemos visto que

- si $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, V)$ es una normal de dimensión n , entonces

$$(\mathbb{X} - \boldsymbol{\mu})^T V^{-1}(\mathbb{X} - \boldsymbol{\mu}) \sim \chi_n^2.$$

Teorema 1

Si $\mathbb{X} \sim \mathcal{N}(\mathbf{0}, I)$ es una normal de dimensión n , y B es una matriz $n \times n$ simétrica e idempotente, entonces

$$\mathbb{X}^T B \mathbb{X} \sim \chi_{\text{traza}(B)}^2.$$

Corolario 2

Si $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 I)$ es una normal de dimensión n , y B es una matriz $n \times n$ simétrica e idempotente, y se tiene que $\boldsymbol{\mu}^T B \boldsymbol{\mu} = 0$, entonces

$$\frac{1}{\sigma^2} \mathbb{X}^T B \mathbb{X} \sim \chi_{\text{traza}(B)}^2.$$

Teorema 3

Sea $\mathbb{X} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 I)$ una normal de dimensión n . Sean

- A una matriz $p \times n$, con $p \leq n$;
- B y C matrices $n \times n$ simétricas e idempotentes.

Entonces,

- si $AB = \mathbf{0}$, entonces $A\mathbb{X}$ y $\mathbb{X}^T B\mathbb{X}$ son independientes;
- si $BC = \mathbf{0}$, entonces $\mathbb{X}^T B\mathbb{X}$ y $\mathbb{X}^T C\mathbb{X}$ son independientes.