



1. $\diamond \equiv 0$ 

$$x_2 = x_1 \rightarrow z_1 = \theta(x_2 - x_1)$$

$$x_2 = x_1 - 2 \rightarrow z_2 = \theta(x_2 - x_1 + 2)$$



$$z_2 = z_1 + 0.5$$

$$y = \theta(z_2 - z_1 - 0.5)$$

Comprobamos
que la predicción
de clase es
la correcta

$$z_1 = 1, z_2 = 1 \Rightarrow y = \theta(-0.5) = 0 \checkmark$$

$$z_1 = 0, z_2 = 0 \Rightarrow y = \theta(-0.5) = 0 \checkmark$$

$$z_1 = 0, z_2 = 1 \Rightarrow y = \theta(0.5) = 1 \checkmark$$

Por tanto:

$$V_{01} = 0$$

$$W_0 = -0.5$$

$$V_{02} = 2$$

$$W_1 = -1$$

$$V_{11} = -1$$

$$W_2 = 1$$

$$V_{12} = -1$$

$$V_{21} = 1$$

$$V_{22} = 1$$

Hemos sacado los coef.
de las fórmulas de
 z_1, z_2 e y :

$$z_1 = \theta(x_2 - x_1)$$

$$z_2 = \theta(x_2 - x_1 + 2)$$

$$y = \theta(z_2 - z_1 - 0.5)$$

2.1

$$Z_1 = \theta(0.5 - 0.5X_1 - \frac{\sqrt{3}}{2}X_2)$$

$$X_2 = 0 \Rightarrow X_1 = 1$$

$$X_1 = 0 \Rightarrow X_2 = \frac{-0.5}{-\sqrt{3}/2} \approx 0.577$$

\Rightarrow pendiente: $m \approx -0.577$

$$\Rightarrow \boxed{X_2 = -0.577X_1 + 0.577} \quad (r_1)$$

$$Z_2 = \theta(1 + X_1) \quad \begin{matrix} X_2 \text{ libre} \\ X_1 = -1 \end{matrix}$$

$$\Rightarrow \boxed{X_1 = -1} \quad (r_2)$$


$$Z_3 = \theta(0.5 - 0.5X_1 + \frac{\sqrt{3}}{2}X_2)$$

$$X_2 = 0 \Rightarrow X_1 = 1$$

$$X_1 = 0 \Rightarrow X_2 = \frac{-0.5}{\sqrt{3}/2} \approx -0.577$$

\Rightarrow pendiente: $m \approx 0.577$

$$\Rightarrow \boxed{X_2 = 0.577X_1 + 0.577} \quad (r_3)$$



punto (0,0): $\begin{cases} Z_1 = 1 \\ Z_2 = 1 \\ Z_3 = 1 \end{cases} \Rightarrow y = \theta(0.5) = 1 \quad (\text{clase 1})$

pto. (0,2): $\begin{cases} Z_1 = 0 \\ Z_2 = 1 \\ Z_3 = 1 \end{cases} \Rightarrow y = \theta(1.5) = 1 \quad (\text{clase 1})$

pto. (2,0): $\begin{cases} Z_1 = 0 \\ Z_2 = 1 \\ Z_3 = 1 \end{cases} \Rightarrow y = \theta(0.5) = 1 \quad (\text{clase 1})$


Si la función fuese la sigmoideal para z_1, z_2 cambiando la frontera de decisión. De forma aproximada, la nueva frontera de decisión sería:

caso $z_1 = \sigma(0.5 - 0.5x_1 - \frac{\sqrt{3}}{2}x_2)$

buscamos (aprox.): $0.5 - 0.5x_1 - \frac{\sqrt{3}}{2}x_2 = 0.5$


$$\boxed{\frac{\sqrt{3}}{2}x_2 = -0.5x_1}$$

$$\Rightarrow \boxed{x_2 \approx -0.577x_1} \quad (r_1)$$



caso $z_2 = \sigma(1 + x_1)$

buscamos (aprox.): $1 + x_1 = 0.5 \Rightarrow \boxed{x_1 = -0.5}$



3. $\left. \begin{array}{l} Y \text{ entrada} \\ X \text{ oculta} \\ 1 \text{ salida} \end{array} \right\} \text{ tarda } t$

Coste clasificación NN: (teoría) : $O(XY) \Rightarrow$

$$\Rightarrow O(XY) = t \Rightarrow O\left(\frac{X}{2}Y\right) = \frac{1}{2} O(XY) = \frac{1}{2} t$$

\Rightarrow tardaría aproximadamente la mitad del tiempo

4. Lista $[1, -2, 8, -3, 10, -5]$

Ind.	Números	Fitness	Esquema
1 0 0 1 1 0	1, -3, 10	$1/8 = 0'125$	H_1
1 1 0 1 0 0	1, -2, -3	$1/4 = 0'25$	H_1, H_2
0 1 0 1 1 0	-2, -3, 10	$1/5 = 0'2$	
0 1 1 0 0 1	-2, 8, -5	$1 = 1$	H_2

Fitness medio población: $\frac{0'125 + 0'25 + 0'2 + 1}{4} = 0'394 := \bar{f}(t)$

Fitness medio H_1 : $\bar{f}_{H_1}(t) = \frac{0'125 + 0'25}{2} = \underline{0'188}$

Fitness medio H_2 : $\bar{f}_{H_2}(t) = \frac{0'25 + 1}{2} = \underline{0'625}$

$E_s[\bar{n}_{H_1}(t)] = n_{H_1}(t) \cdot \frac{\bar{f}_{H_1}(t)}{\bar{f}(t)} = 2 \cdot \frac{0'188}{0'394} = \underline{0'954}$

$E_s[\bar{n}_{H_2}(t)] = n_{H_2}(t) \cdot \frac{\bar{f}_{H_2}(t)}{\bar{f}(t)} = 2 \cdot \frac{0'625}{0'394} = \underline{3'173}$

4.2

Los pesos de una red neuronal son V y W

V es una matriz $(D+1) \times J$, donde D es el número de atributos y J el número de neuronas de la capa oculta

W es un vector $(J+1) \times 1$.

En total tenemos $(D+1)J + (J+1)$ pesos (lo denotaremos por n -pesos)

Los pesos de una red neuronal pueden ser cualquier número real, por lo tanto podemos representar un individuo (cadena de pesos) como un vector real n-pesos-dimens es decir, una lista de números reales de tamaño n-pesos

La inicialización puede ser una muestra de tamaño n-pesos de una distribución uniforme $[-0.5, 0.5]$, así será idéntica a la inicialización del algoritmo vis en teoría.


El fitness será en función del error final en la neurona de salida, es decir:

$$\hat{y} := \text{valor predicho red neuronal}$$
$$y := \text{valor real}$$


Entonces
$$f(v, w | \vec{x}) = \frac{1}{|\hat{y} - y| + 1}$$

Hemos escogido esta fórmula para maximizar el fitness a la vez que minimizamos el error.

Añadimos un '+1' en el denominador para evitar división por cero.



Podemos observar (detenidamente) que todos los ejemplos están bien clasificados gracias al voto por mayoría. \Rightarrow Número de errores = cero.



$$P_L = \frac{7}{10} = 0.7$$

$$i(t_L) = 2 \cdot \frac{4}{7} \cdot \frac{3}{7} = 0.49$$

$$P_R = \frac{3}{10} = 0.3$$

$$i(t_R) = 2 \cdot 0 \cdot 1 = 0$$

$$i(t) = 2 \cdot \frac{4}{10} \cdot \frac{6}{10} = 0.48$$

$$\Delta i(s, t) = 0.48 - 0.7 \cdot 0.49 - 0.3 \cdot 0 = \underline{0.137}$$