

# RESUMEN PARCIAL 3

## COSTES

### ► ENTRENAMIENTO

- KNN :  $O(D \cdot N)$  si normalizamos (si no, nada)
- NB :  $O(DN)$
- NN :  $O(\text{nepocas} \cdot N \cdot D \cdot J)$
- RegLog :  $O(\text{nepocas} \cdot N \cdot D)$

### ► CLASIFICACIÓN / PREDICCIÓN

- KNN :  $O(DN)$
- NB :  $O(DK)$
- RegLog :  $O(D)$
- NN :  $O(DJ)$

## MODELOS LINEALES

► Si  $P(C_1) = P(C_2)$  y  $\Sigma_1 = \Sigma_2 = I$  entonces:

- Si  $(\bar{x} - \mu_2)^2 > (\bar{x} - \mu_1)^2 \Rightarrow C_1$

- Si  $(\bar{x} - \mu_2)^2 \leq (\bar{x} - \mu_1)^2 \Rightarrow C_2$

$\bar{x}$  se clasifica  $C_1$  si está más cerca de la media  $\mu_1$ .

► Ahora  $P(C_1)$  puede ser diferente de  $P(C_2)$

- Frontera de decisión:  $P(C_1 | \bar{x}) = 0.5 \Rightarrow \sigma(a) = 0.5 \Rightarrow a = 0$

$$a = \frac{(\bar{x} - \mu_2)^2}{2} - \frac{(\bar{x} - \mu_1)^2}{2} + \ln\left(\frac{P(C_1)}{P(C_2)}\right) = 0$$

$$\Rightarrow \underbrace{(\mu_1 - \mu_2)}_{\omega} \bar{x} + \underbrace{\frac{\mu_2^2 - \mu_1^2}{2} + \ln\left(\frac{P(C_1)}{P(C_2)}\right)}_{\omega_0 = b} = 0 \quad \text{Ecuación HIPERPLANO}$$

- Si  $P(C_1) = P(C_2) \Rightarrow$  la frontera es la mediatriz de  $\mu_1$  y  $\mu_2$ .
- Si  $P(C_1) > P(C_2) \Rightarrow$  la frontera se aleja de  $\mu_1$  hacia  $\mu_2$ .

►  $P(\bar{x}|C_1) = N(\mu_1, \Sigma)$  y  $P(\bar{x}|C_2) = N(\mu_2, \Sigma)$

llegamos a  $w = \Sigma^{-1}(\mu_1 - \mu_2)$

$b = \frac{1}{2}\mu_1 \Sigma^{-1}\mu_1 + \frac{1}{2}\mu_2 \Sigma^{-1}\mu_2 + \ln\left(\frac{P(C_1)}{P(C_2)}\right)$

→ muchos parámetros a estimar:  $\mu_1, \mu_2, \Sigma, P(C_1), P(C_2)$

Sólo necesitamos  $w$  y  $b$ :  $\boxed{D+1}$   
 $\bar{w} = [w_0, w]$

$\begin{matrix} \uparrow & \uparrow & \uparrow & \uparrow \\ D & D & \frac{D(D+1)}{2} & 1 \end{matrix}$

$P(C_1|\bar{x}) = \sigma(\bar{x}\bar{w})$

Obs: Si  $P(C_1|\bar{x}) = \sigma(\bar{x}\bar{w}) \Rightarrow$   
 $\Rightarrow P(C_2|\bar{x}) = 1 - \sigma(\bar{x}\bar{w})$

• Frontera:  $\sigma(\bar{x}\bar{w}) = 0.5 \Rightarrow \boxed{\bar{x}\bar{w} = 0}$

## REGRESIÓN LOGÍSTICA

$t_j = 1$  si  $\bar{x}_j$  es  $C_1$ ,  $t_j = 0$  si  $\bar{x}_j$  es  $C_2$

[...]

Para mejorar la verosimilitud del ejemplo  $\bar{x}_j$  hay que mover la recta en sentido opuesto al gradiente  $(\sigma_j - t_j)\bar{x}_j$  y proporcional a la constante de aprendizaje:  $\bar{w} = \bar{w} - \eta(\sigma_j - t_j)\bar{x}_j$

► Algoritmo RL MV:

reg-log-mv( $\eta$ , nepocas):

generar  $\bar{w} \in [-0.5, 0.5]^{D+1}$ :

for ep in range(nepocas):

for j in range(1, N):

$\sigma = \sigma(\bar{w}\bar{x}_j)$

$\bar{w} = \bar{w} - \eta(\sigma - t_j)\bar{x}_j$

return  $\bar{w}$

► Algoritmo RL MAP:

reg-log-map( $\eta$ , nepocas,  $\sigma^2$ ):

generar  $\bar{w} \in [-0.5, 0.5]^{D+1}$

for ep in range(nepocas):

for j in range(1, N):

$\sigma = \sigma(\bar{w}\bar{x}_j)$

$\bar{w} = \bar{w} - \eta(\sigma - t_j)\bar{x}_j -$

⊗ En MAP suponemos que el módulo  $|\bar{w}|$  viene dado por una gaussiana de media 0.

► Obs → RL solo trabaja con atributos numéricos  
 → Se recomienda normalizar