

Tema 1: Introducción: de la inspiración biológica a la computación neuronal artificial

- Tema 1.1 Introducción al procesamiento de información neuronal
- Tema 1.2: Modelos de computación del sistema nervioso
- Tema 1.3: De la computación neuronal biológica a las redes neuronales artificiales



Tema 1.1 Introducción al procesamiento de Información Neuronal

- **TERMINOLOGÍA:**
 - **Computación natural:** computación artificial basada en el procesamiento de información observado en la naturaleza.
 - **Neurociencia computacional:** estudio del procesamiento de información en el sistema nervioso.
 - **Computación neuronal artificial:** paradigmas de inteligencia artificial bio-inspirados en el procesamiento de información neuronal (redes neuronales artificiales).
 - **Neurocomputación** = Computación neuronal artificial

Neurociencia Computacional

- La neurociencia Computacional estudia el sistema nervioso desde la perspectiva del procesamiento de información.
- Se trata de un campo multidisciplinar que hace uso de biología, biofísica, bioquímica, computación, ingeniería, medicina, psicología...
- ¿Para qué sirve?
 - Para comprender el funcionamiento del cerebro
 - Para estudiar algunos tipos de enfermedades y diseñar dispositivos prostéticos e interfaces cerebro-máquina.
 - Para diseñar paradigmas de computación artificial bioinspirados y de robótica.

El cerebro y las máquinas de procesar información

Procesador de información	Elementos de procesamiento	Tamaño de cada elemento	Consumo de energía	Velocidad de procesamiento	Tipo de computación	Tolerante a fallos	Capaz de aprender	Inteligente, consciente
	10 ¹⁴ sinapsis	10 ⁻⁶ m	30 W	100 Hz	Paralela, distribuida	SI	SI	A menudo
	10 ⁸ transistores	10 ⁻⁶ m	30W (CPU)	10 ⁹ Hz	En serie, centralizada	NO	Un poco	No (todavía)



La naturaleza y los ingenieros tienen estrategias de computación distintas (I)

- **La naturaleza** emplea estrategias de ingeniería diferentes a las utilizadas por los ingenieros para diseñar sistemas de computación.
- **La ingeniería humana clásica** se basa en el control (de dinámicas, de ruido, de calidad, etc.) y está orientada fundamentalmente a la consecución de un objetivo concreto.
 - Su capacidad está limitada por la imaginación del que establece los objetivos. El ruido o la complejidad de combinar elementos diversos interfieren con esta imaginación y por tanto se consideran como no deseables.

Estrategias de computación distintas (II)

- **La ingeniería de la naturaleza**, al contrario, se basa en la explotación de fenómenos (oscilaciones, ruido, diversidad de componentes, de la oportunidad de combinar procesos, etc). A medida de la ingeniería natural configura fenómenos más complejos, el espacio de posibilidades se expande, haciendo posible fenómenos nuevos.
 - Por tanto la ingeniería de la naturaleza es abierta y cosas como el ruido, la diversidad y la riqueza de la combinatoria se tratan como ventajas y no como problemas.
- La ingeniería humana y la de la naturaleza tienen distintos propósitos. Sin embargo, pueden combinarse.


Principios básicos de neurocomputación: niveles de procesamiento de información en el sistema nervioso




- Subcelular
- Celular
- Red
- Sistema
- Cerebro




Complejidad informacional



Neurona: unidad de procesamiento de información en el sistema nervioso




Mecanismos de generación de información en el nivel celular





La excitabilidad de las neuronas se debe a las propiedades eléctricas de sus membranas.

La membrana mantiene una concentración de iones en el interior celular distinta a la del exterior celular

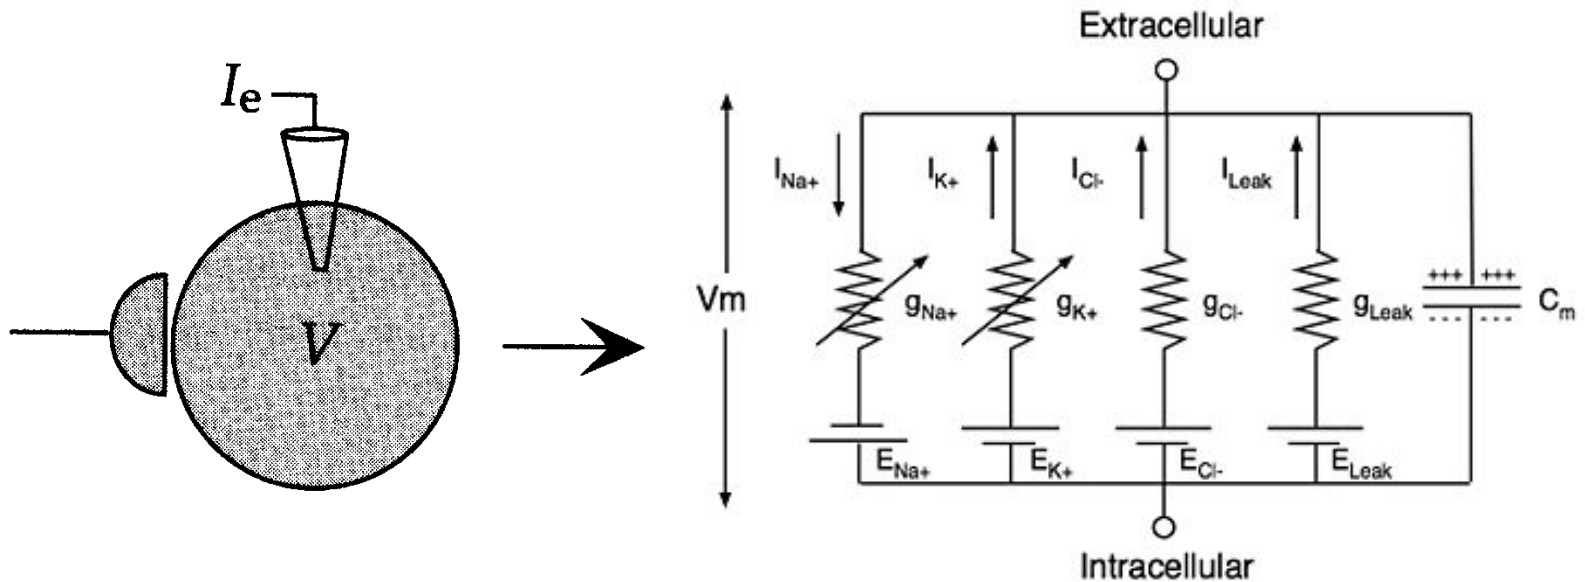


Esto crea una diferencia de potencial entre el interior y el exterior y una concentración de cargas en la superficie.




Las membranas no sólo tienen propiedades electrotónicas pasivas, sino también activas.

Por tanto, además de los componentes electrotónicos de un circuito (independientes del voltaje), tenemos también conductancias dependientes del voltaje o de la concentración de determinadas especies iónicas.



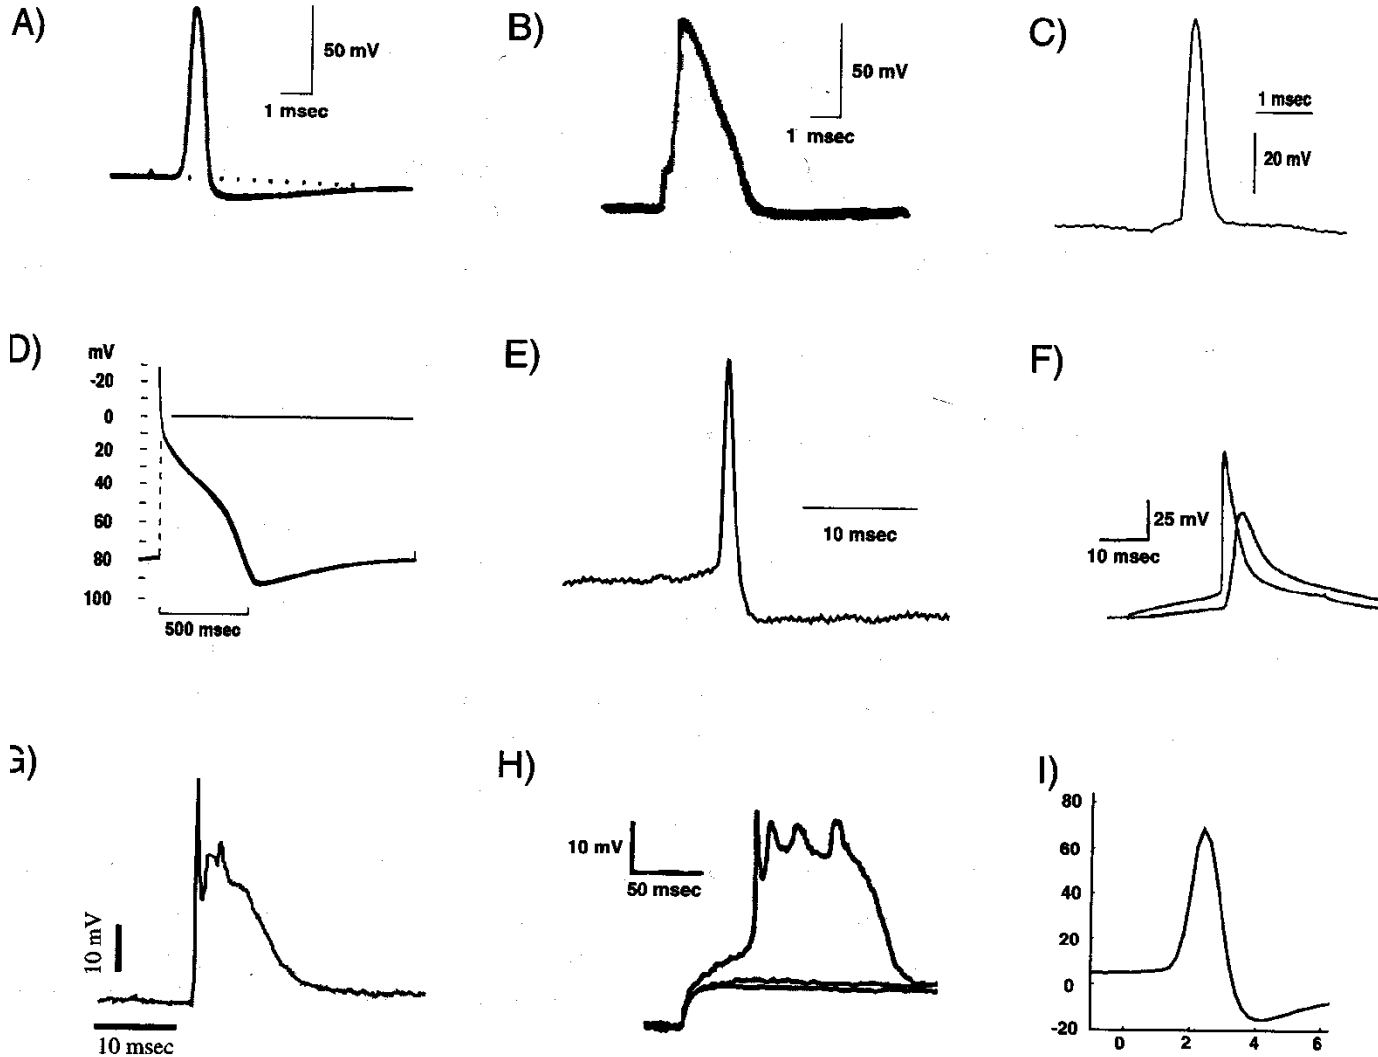
hay una combinación de dinámicas lentas y rápidas

Variedad neuronal



Las neuronas son las células que presentan más variabilidad morfológica.

Variedad de disparos




Los potenciales de acción también presentan mucha variabilidad dependiendo de los tipos neuronales.

La neurociencia computacional utiliza modelos de neuronas

para abordar el estudio de los mecanismos de:

- codificación de información
- transmisión de información
- procesamiento de información y memoria
- creación y coordinación de información
- ejecución de información



Escalas de modelado neuronal

modelos
top-down

modelos
bottom-up

- Modelos abstractos
- Modelos de integración y disparo.
- Modelos dinámicos simplificados.
- Modelos de conductancia tipo Hodgkin-Huxley

-


realismo

+

Terminología



- **Neurona:** principal célula del sistema nervioso (considerada a menudo como la unidad de procesamiento de información)
- **Sinapsis:** conexión entre neuronas
- **Dendritas:** extensiones de la neurona donde tradicionalmente se considera que se recibe la información.
- **Soma:** cuerpo celular de la neurona
- **Axón:** extensión de la neurona donde tradicionalmente se considera que se emite la información

¿Cómo se genera electricidad en las neuronas?




Terminología


- Potencial de acción:
es una onda de descarga eléctrica que viaja a lo largo de la membrana celular. Se considera a menudo como la unidad de transmisión de información del sistema nervioso.




Tema 2.1: Modelos de computación en el sistema nervioso




Modelos realistas de membrana: el Modelo HODGKIN-HUXLEY (H-H):




<http://es.youtube.com/watch?v=k48jXzFGMc8>



Modelos realistas de membrana: el Modelo HODGKIN-HUXLEY (H-H):



Las conductancias dependientes del potencial de membrana se describen a través de una sencilla EDO



$$C_m \frac{dV}{dt} = I_{ext} - g_L(V - V_L) - g_{Na} h m^3 (V - V_{Na}) - g_K n^4 (V - V_K)$$

$$\tau_h(V) \frac{dh}{dt} = \bar{h}(V) - h$$

$$\tau_m(V) \frac{dm}{dt} = \bar{m}(V) - m$$

$$\tau_n(V) \frac{dn}{dt} = \bar{n}(V) - n$$



τ_x = constante de tiempo

$\bar{x} \equiv x_\infty$ = valor en el estado estacionario

$x = (h, m, n)$


MODELO HODGKIN-HUXLEY:

Los valores estacionarios y las constantes de tiempo dependen del potencial de membrana




Evolución conjunta de las conductancias de los canales

MODELO H-H



MODELO H-H



Evolución conjunta del

potencial de membrana,

la corriente transmembrana,

la variable de activación de la conductancia del canal de Na,

la variable de inactivación de la conductancia del canal de Na,

la variable de activación del canal de K

Las ecuaciones H-H se pueden reescribir en función de la tasa de apertura y cierre de los canales

$$x_{\infty} = \alpha_x(V) / (\alpha_x(V) + \beta_x(V)) \quad \text{y} \quad \tau_x = 1 / (\alpha_x(V) + \beta_x(V))$$

$$dn/dt = \alpha_n(V)(1-n) - \beta_n(V)n \quad \alpha_n(V) = \text{tasa de apertura} \quad \beta_n(V) = \text{tasa de cierre}$$

$$dm/dt = \alpha_m(V)(1-m) - \beta_m(V)m \quad \alpha_m(V) = \text{tasa de apertura} \quad \beta_m(V) = \text{tasa de cierre}$$

$$dh/dt = \alpha_h(V)(1-h) - \beta_h(V)h \quad \alpha_h(V) = \text{tasa de apertura} \quad \beta_h(V) = \text{tasa de cierre}$$


La dependencia de α_x y β_x del voltaje se obtiene experimentalmente:

$$\alpha_n = (0.01(V+55)) / (1 - \exp(-0.1(V+55))) \quad \beta_n = 0.125 \exp(-0.0125(V+65))$$


$$\alpha_m = (0.1(V+40)) / (1 - \exp(-0.1(V+40))) \quad \beta_m = 4.00 \exp(-0.0556(V+65))$$

$$\alpha_h = 0.07 \exp(-0.05(V+65)) \quad \beta_h = 1.0 / (1 + \exp(-0.1(V+35)))$$

La actividad eléctrica es distinta en cada localización de la membrana




La generación, propagación y procesamiento de la actividad eléctrica puede modelarse mediante la compartimentación de la membrana





Cada compartimento se puede describir con un circuito equivalente de la actividad de la membrana


Cada compartimento puede tener propiedades activas para el procesamiento complejo de información



Los modelos más realistas tienen en cuenta este procesamiento distribuido dentro de cada célula




Ejemplo: simulación realista de la morfología y fisiología de una neurona de CA1 del hipocampo



265 compartimentos

Reproduce la morfología en 3-D



Ejemplo: simulación realista de la morfología y fisiología de una neurona de CA1 del hipocampo

- Cada compartimento tiene su propia distribución de canales:
- Además de canales de Na y K tiene otro que dependen de [Ca]

Ca channel:

$$I_{Ca} = g_{Ca} s^2 r (V_m - E_{Ca})$$

$$E_{Ca} = -13.3 \ln([Ca, 1]_{in} / 1200)$$

$$\alpha_s = -0.16 (V_m + 26.0) / \{\exp[(V_m + 26) / -4.5] - 1\}$$

$$\beta_s = 0.04 (V_m + 12) / \exp[(V_m + 12) / 10] - 1\}$$

$$\alpha_r = 2 / \exp[(V_m + 94) / 10]$$

$$\beta_r = 8 / \{\exp[(V_m - 68) / -27] + 1\}$$

K_AHP channel:

$$I_{AHP} = g_{AHP} q (V_m - E_K)$$

$$E_K = -85 \text{ mV}$$


$$\alpha_q = 0.0048 / \exp[(10 \log([Ca, 2]_{in} - 35) / -2]$$

$$\beta_q = 0.012 / \exp[(10 \log([Ca, 2]_{in} + 100) / 5]$$

$$\tau_q = 48 \text{ ms}$$

$$\frac{d[Ca, i]_m}{dt} = \frac{[Ca, i]_m}{\tau_i} - \frac{f_i I_{Ca}}{wZFA}$$

Ejemplo: simulación realista de la morfología y fisiología de una neurona de CA1 del hipocampo



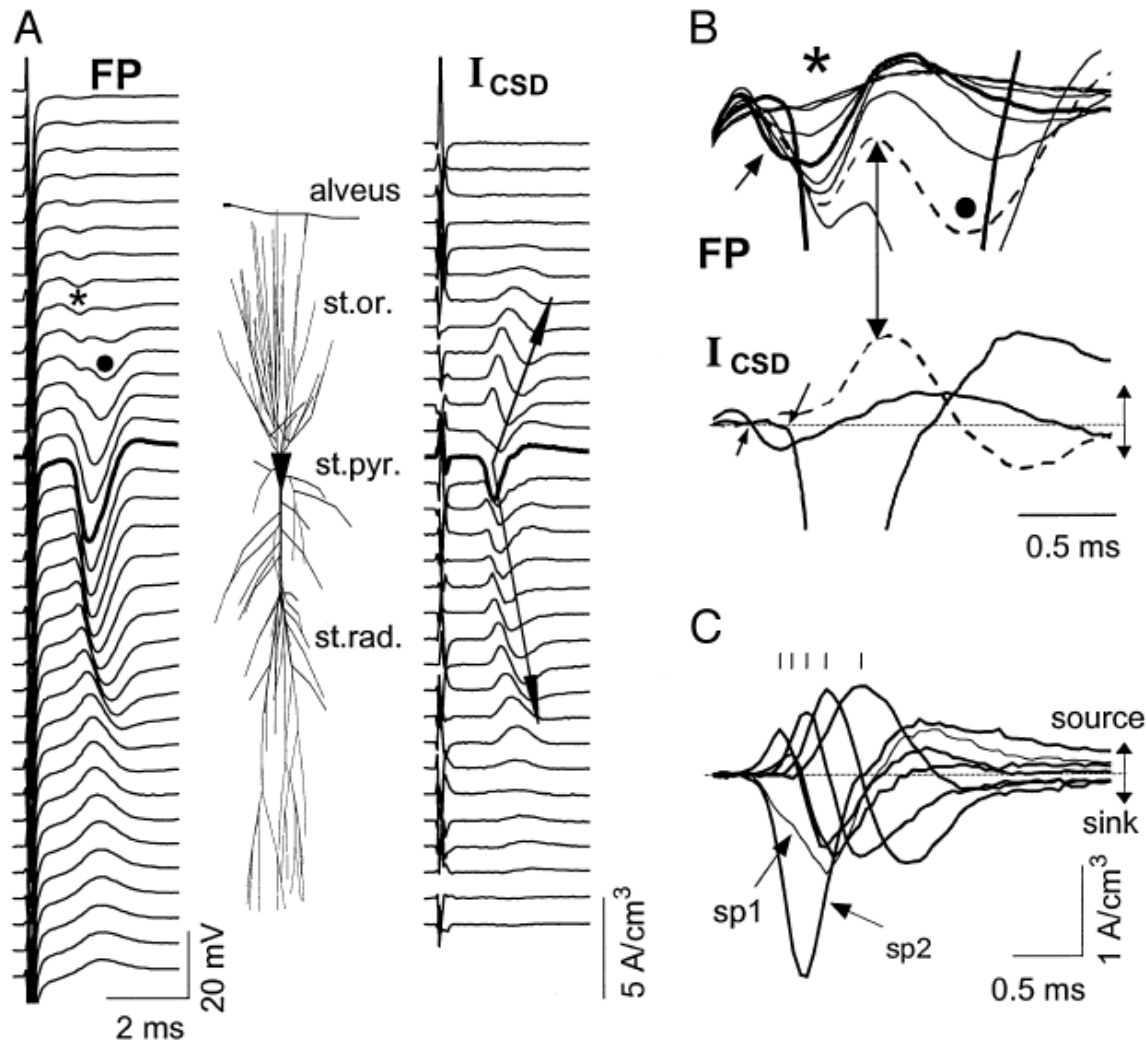
La región del hipocampo permite mediante la técnica de análisis de fuentes de corriente (CSD) averiguar la distribución de corrientes a lo largo de la morfología

$$\Phi(t) = \frac{1}{4\pi\sigma} \sum_{i=1}^{cells} \sum_{j=1}^{comps} \frac{I_{m_{ij}}(t)}{r_{ij}}$$

$$I_{CSD} = -\vec{\nabla} \cdot \vec{\partial \nabla} \Phi$$


$$I_{CSD} = -\sigma \frac{d^2 \Phi}{dz^2}$$

Técnica experimental de CSD

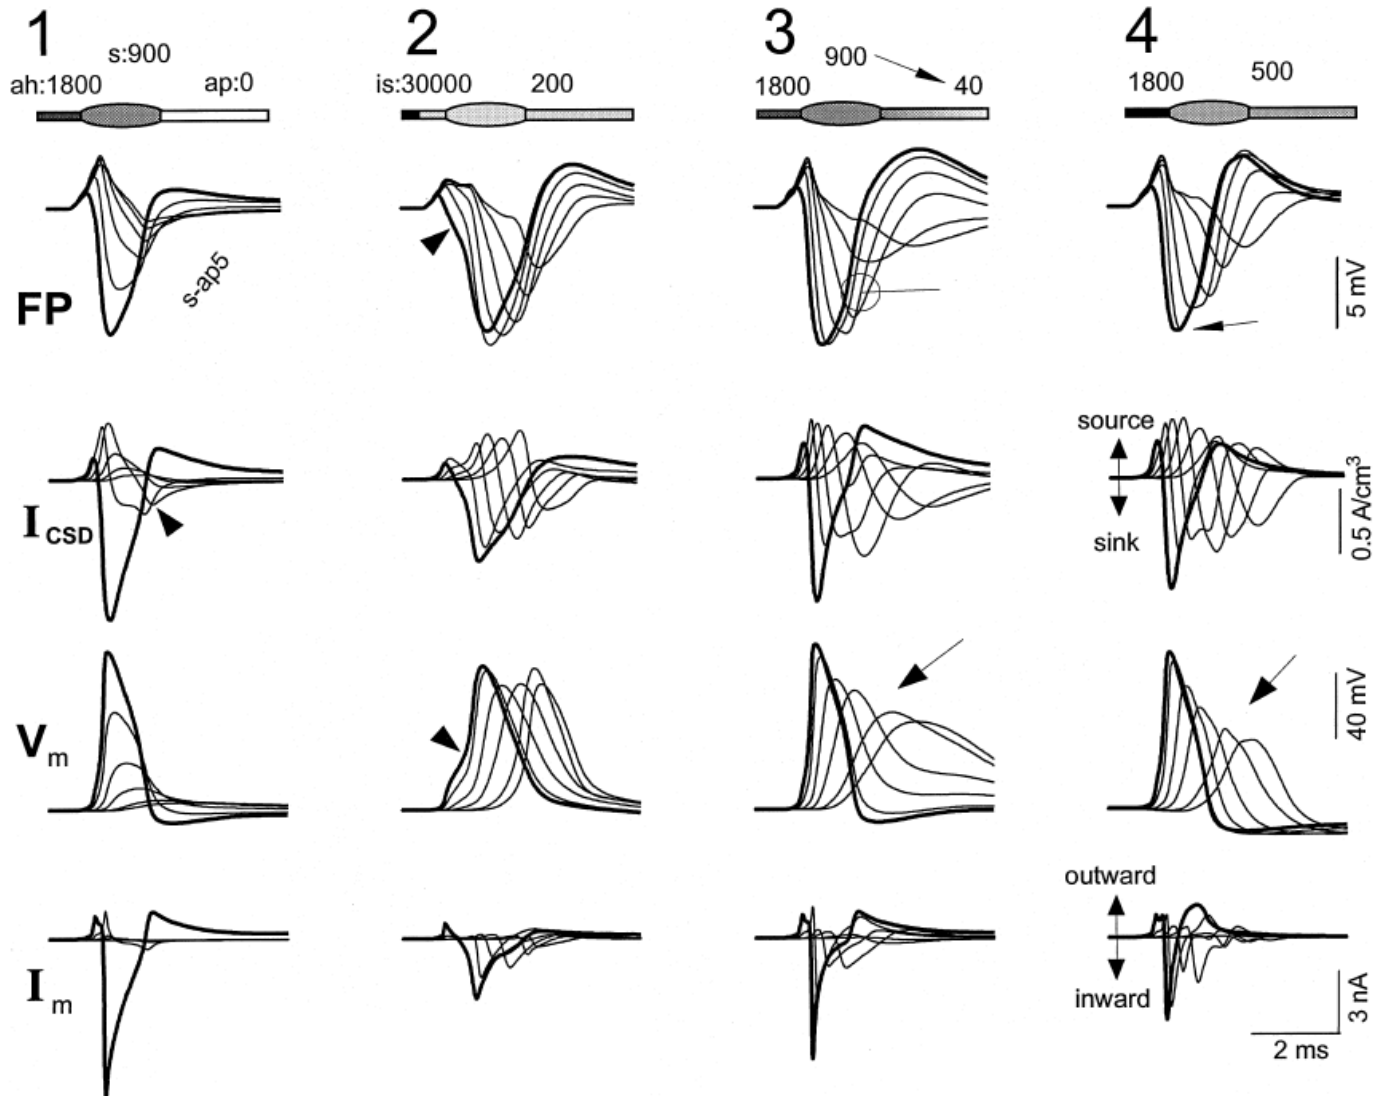


$$I_{CSD} = -\sigma \frac{d^2 \Phi}{dz^2}$$

El modelo permite la correcta interpretación de la técnica experimental y el acceso a nuevos datos





Distintas distribuciones de los canales en las dendritas dan lugar a distintas propagaciones y procesamiento



Modelos dinámicos simplificados

- Describen la evolución dinámica del estado de las neuronas con ecuaciones diferenciales, pero con un grado de no-linealidad suavizado respecto a los modelos más realistas.
- A menudo convierten las no-linealidades exponenciales de los modelos realistas en no-linealidades polinómicas.
- Reducen el número de variables.



Modelos dinámicos simplificados:



- FitzHugh-Nagumo
- Morris-Lecar
- Hindmarsh-Rose
- Rinzel, etc...

- El tiempo de integración es menor y pueden llegar a reproducir las bifurcaciones deseadas en un modelo realista.
- Permiten el análisis teórico en algunos casos y búsquedas paramétricas sencillas.

Modelo de FitzHugh-Nagumo

$$\frac{du}{dt} = u - \frac{1}{3}u^3 - w + I \quad (\tau = 1)$$

$$\frac{dw}{dt} = \varepsilon(b_0 + b_1u - w) \quad (\varepsilon = 1/\tau_w)$$





R. Fitzhugh en 1960

Modelo de Hindmarsh-Rose


$$\frac{dx_i(t)}{dt} = y_i(t) + 3x_i^2(t) - x_i^3(t) - z_i(t) + e_i$$

$$\frac{dy_i(t)}{dt} = 1 - 5x_i^2(t) - y_i(t), \quad \frac{1}{\mu} \frac{dz_i(t)}{dt} = -z_i(t) + S[x_i(t) + 1.6],$$







Modelos de integración y disparo

- Describen una variable que simula el potencial de membrana hasta que se supera un umbral.
- Cuando se sobrepasa el umbral (constante o dinámico) se genera un disparo instantáneo en forma de acción todo-o-nada.
- Después del disparo, la variable continúa su evolución subumbral.
- Muchos tipos: autómatas finitos, modelos estocásticos, integradores con pérdidas ante la falta de estímulo, realistas con la descripción del potencial de membrana subumbral, etc.
- El coste computacional bajo sobre cada unidad facilita la simulación de grandes redes con conectividad compleja.




Modelos abstractos

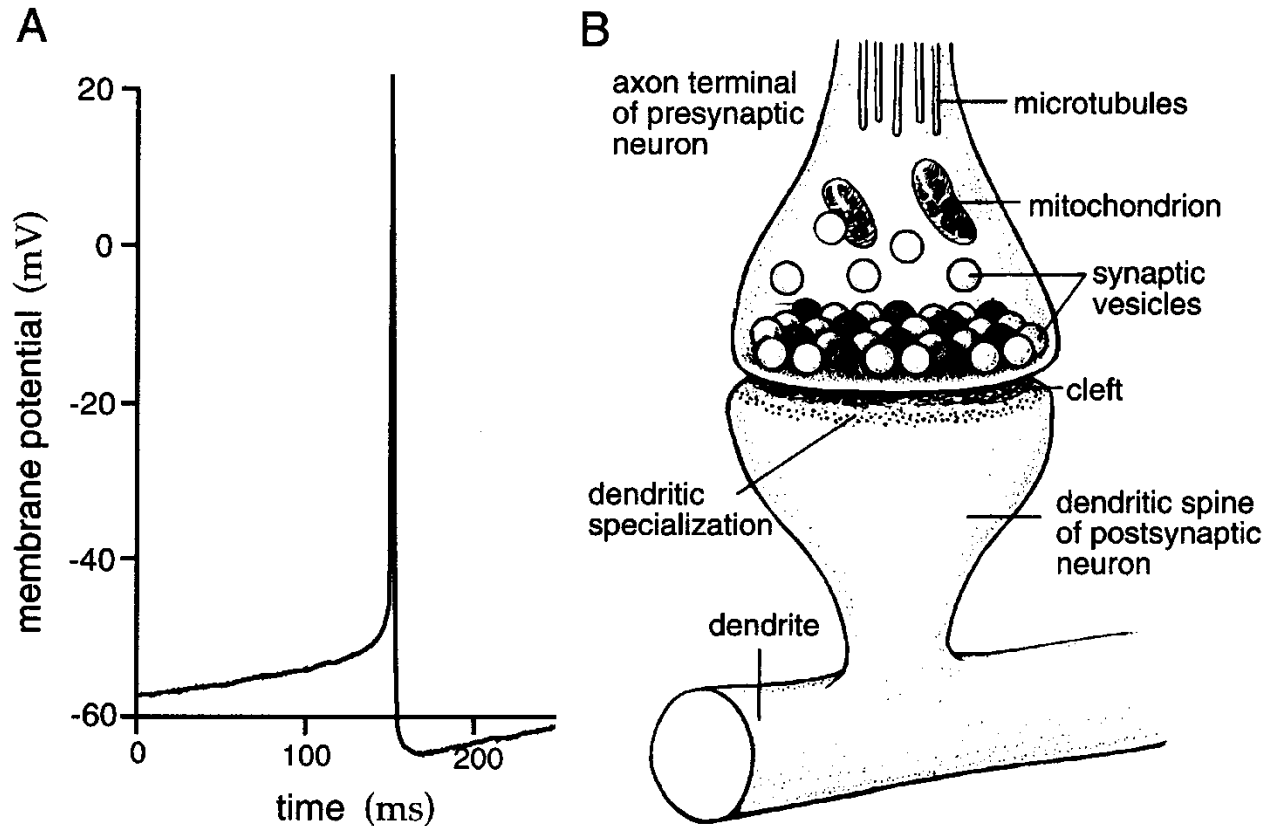
- Ningún parámetro real pero utilizan aspectos cualitativos observados en experimentos biológicos:
 - Oscilaciones, sincronía de actividad, auto-organización,
 - Conectividad realista,
 - Reglas de aprendizaje de inspiración biológica.
- Suelen permitir un análisis teórico para predecir su comportamiento en función de la arquitectura de la red, el modelo neuronal o la función de aprendizaje.



Recordando: las neuronas forman circuitos




Sinapsis



Cada potencial de acción provoca la liberación de neurotransmisores en las terminaciones axónicas

La acción de los receptores postsinápticos ante la llegada de los neurotransmisores es la generación de un *potencial postsináptico*



Modelos de sinapsis:


Forma general de la corriente: $I_{\text{syn}}(t) = g_{\text{syn}}(t) \cdot (V(t) - E_{\text{syn}})$

Modelos para la descripción de $g_{\text{syn}}(t)$:

- $g_{\text{syn}}(t) = g_{\text{max}} \cdot t \cdot e^{-(1-t/\tau)} / \tau$ (función alpha)
- $g_{\text{syn}}(t) = A \cdot g_{\text{max}} \cdot (e^{-t/\tau_1} - e^{-t/\tau_2}) / (\tau_1 - \tau_2)$, con $\tau_1 > \tau_2$


Cuando $\tau_1 = \tau_2 \equiv \tau$ se recupera la función alpha

A es una constante de normalización para que $\text{máx}(g_{\text{syn}}(t)) = g_{\text{max}}$




La neurona puede recibir varias sinapsis en un espacio corto de tiempo

$$C_m dV/dt + I_{ion} + g^{(1)}_{syn}(t) \cdot (V - E^{(1)}_{syn}) + g^{(2)}_{syn}(t) \cdot (V - E^{(2)}_{syn}) + \dots = 0$$



Modelos de sinapsis II:

Se puede describir la ligadura de las moléculas de neurotransmisor T a los receptores postsinápticos:



R representa el receptor postináptico

TR* es la forma ligada del receptor

α y β son las constantes que representan la tasa de ligadura/desligadura

Si r representa la fracción de receptores ligados y $[T]$ la concentración de transmisores, la cinética se puede describir con la EDO:

$$dr/dt = \alpha [T] \cdot (1-r) - \beta \cdot r$$

Modelos de sinapsis II:

$$dr/dt = \alpha [T] \cdot (1-r) - \beta \cdot r$$

La concentración de transmisores crece y decrece muy deprisa, se puede aproximar que ocurre como un pulso:



1- durante el pulso ($t_0 < t < t_1$), $[T]=T_{\max}$ y $r(t-t_0) = r_{\infty} + (r(t_0)-r_{\infty}) \cdot \exp[-(t-t_0)/\tau_r]$

donde $r_{\infty} = \alpha T_{\max} / (\alpha T_{\max} + \beta)$ y $\tau_r = 1 / (\alpha T_{\max} + \beta)$

2- después del pulso ($t > t_1$), $[T]=0$ y $r(t-t_1) = r(t_1) \cdot \exp[-\beta(t-t_1)]$

y la corriente sináptica: $I_{\text{syn}}(t) = g_{\text{syn}} r(t) [V_{\text{syn}}(t) - E_{\text{syn}}]$


Sinapsis excitatorias:



$$\alpha = 2 \text{ ms}^{-1} \text{ mM}^{-1} \quad \bar{g}_{syn} = 1 \text{ nS}, T_{max} = 1 \text{ mM}$$

$$\beta = 1 \text{ ms}^{-1}, E_{syn} = 0 \text{ mV} \quad (t_1 - t_0) = 1 \text{ msec}$$

Sinapsis inhibitorias:



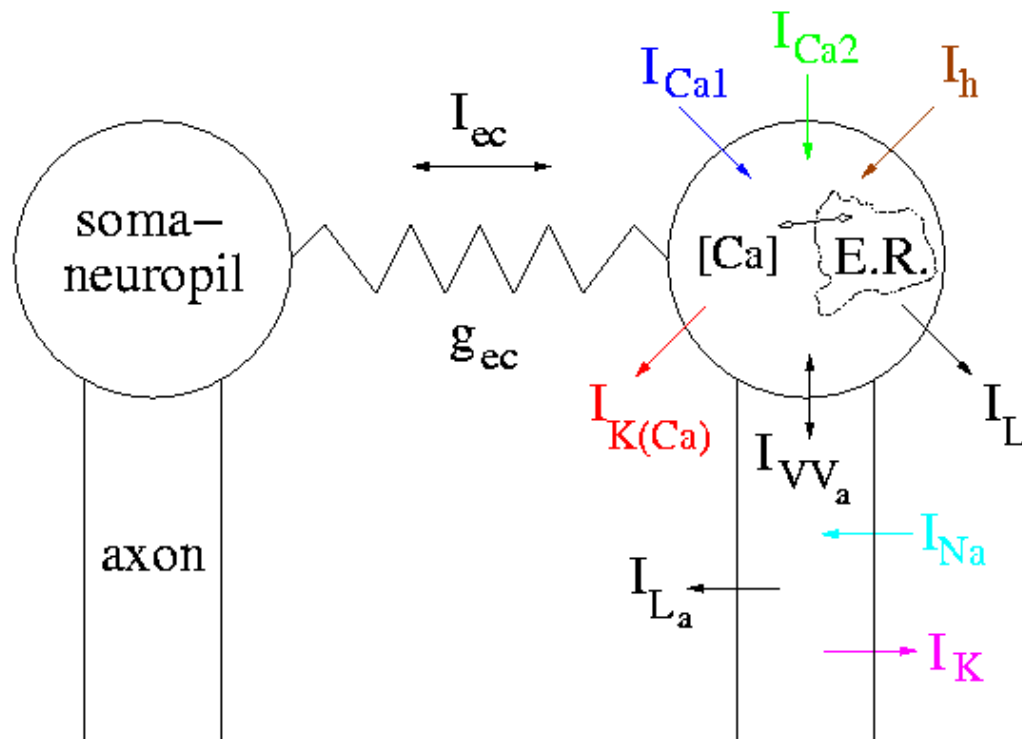
$$\alpha = 0.5 \text{ ms}^{-1} \text{ mM}^{-1}, \beta = 0.1 \text{ ms}^{-1}, E_{syn} = -80 \text{ mV}$$

$$\bar{g}_{syn} = 1 \text{ nS}, T_{max} = 1 \text{ mM} \quad (t_1 - t_0) = 1 \text{ msec.}$$

Sinápsis eléctricas o *gap junctions*

- Pueden ser rectificadoras o simétricas:


$$I_{ec} = g_{ec} (V_1 - V_2)$$



Sinápsis eléctricas o *gap junctions*

- En ocasiones la conductancia de acoplamiento depende del voltaje:

$$g_{ec} = g f(V)$$



Sinapsis graduales

Actúan liberando neurotransmisores incluso antes de que se produzca el potencial de acción:

$$I_{syn}(t) = g_{syn} S(t) (V_{rev} - x_{post}(t))$$

$$\tau \frac{dS(t)}{dt} = \frac{S_{\infty}(x(t)) - S(t)}{S_0 - S_{\infty}(x(t))}$$

$$S_{\infty}(x) = \begin{cases} \tanh[(x - V_{th}) / V_{slope}] & \text{if } V_{pre} > V_{th} \\ 0 & \text{if } V_{pre} \leq V_{th} \end{cases}$$



donde x (V_{pre}) es el potencial presináptico

Aprendizaje

- El proceso de aprendizaje neuronal puede ser sináptico o subcellular:
 1. Aprendizaje sináptico: se modifican las conexiones entre neuronas (se establecen nuevas conexiones, se eliminan conexiones existentes o se refuerzan o debilitan conexiones ya existentes).
 2. Aprendizaje subcellular: se modifican las propiedades que determinan el comportamiento de la neurona. Por ejemplo: número y eficacia de canales iónicos, su distribución a lo largo de la morfología de la neurona.
- El aprendizaje tiene lugar por la interacción neuronal y mediante la estimulación.







Modelos de aprendizaje/plasticidad

- **Aprendizaje sináptico:** modificación de la fuerza de la sinapsis
 - Modelo de Hebb (1949): Si dos neuronas están conectadas sinápticamente y sus disparos están relacionados causalmente, se refuerza la conexión $g_{\text{syn}}(t) \uparrow$
- **Aprendizaje subcelular:** modificación de las conductancias de los canales o su cinética



Donald O. Hebb
(1904-1985)

De la Neurociencia a la Tecnología y Vuelta:




Tema 1.3:



De la computación neuronal biológica a las redes neuronales artificiales

McCulloch & Pitts, 1943


"A logical calculus of the ideas immanent in nervous activity" I, Bulletin of Mathematical Biophysics 5:115-133.



Warren S. McCulloch, Neurofisiólogo





Walter Pitts, Matemático




Impacto de las Redes Neuronales Artificiales

- Las redes neuronales artificiales se aplican en la resolución de muchos problemas:
 - Aproximación de funciones, análisis de regresión, predicción de series temporales, modelado
 - Clasificación, reconocimiento de patrones y secuencias, detección de cambios, toma de decisiones
 - Procesamiento de datos, filtrado, agrupamiento, separación y compresión de datos.
 - Robótica y dispositivos prostéticos
- Sus áreas de aplicación incluyen:
 - Reconocimiento de patrones (biometría, detección de fraude, reconocimiento de objetos, radares)
 - Reconocimiento de secuencias (gestos, habla, caracteres manuscritos)
 - Diagnostico médico (cáncer, Alzheimer, esclerosis múltiple, etc)
 - Aplicaciones financieras
 - Aplicaciones en Nanotecnología
 - Sistemas de identificación y control (de vehículos o procesos)
 - Sistemas de toma de decisiones y Juegos.
 - Minería de datos, búsqueda y recuperación de información.



¿En qué consiste la bio-inspiración en las redes neuronales artificiales?

- Las unidades básicas de procesamiento son “neuronas”
- Las unidades reciben entradas de otras unidades con las que están conectadas
- Las unidades suman las entradas con unos pesos y deciden una salida
- La salida se transmite a otras unidades
- La red puede aprender mediante cambios en los pesos de las conexiones que se determinan con algoritmos supervisados o no supervisados
- Muchos algoritmos de aprendizaje se basan en la regla de Hebb (1949)



“Cuando la neurona A hace que la neurona B dispare, el peso de la conexión de $A \rightarrow B$ se incrementa”